



Marysia Nazarczuk

RACHUNEK PRAWDOPODOBIEŃSTWA I


Teoria prawdopodobieństwa od podstaw
z przykładami i zadaniami



$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$



$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$



$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i)$$

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}$$

Spis treści

1	Eksperyment losowy, zdarzenia i prawdopodobieństwo	1
1.1	Mapa tematu	1
1.2	Doświadczenie losowe i przestrzeń wyników	1
1.3	Zdarzenia jako zbiory wyników	2
1.4	Najprostszy schemat: prawdopodobieństwo klasyczne	2
1.5	Pułapka modelowania: przykład z urną	3
1.6	Działania na zdarzeniach	4
1.7	σ -ciało, czyli które zdarzenia dopuszczamy?	5
1.8	Aksjomaty Kołmogorowa	5
1.9	Podstawowe własności prawdopodobieństwa	6
1.9.1	Dlaczego wzór na sumę ma minus?	6
1.10	Prawdopodobieństwo geometryczne	7
1.11	Paradoks Bertranda, czyli dlaczego model jest wszystkim	8
1.12	Schematy rozwiązywania pierwszych zadań	8
1.13	Najczęstsze błędy	9
2	Kombinatoryka do rachunku prawdopodobieństwa	10
2.1	Mapa tematu	10
2.2	Dwie podstawowe reguły liczenia	10
2.2.1	Reguła dodawania	10
2.2.2	Reguła mnożenia	11
2.3	Silnia, czyli ustawianie różnych obiektów w kolejności	11
2.4	Permutacje z powtórzeniami	12
2.5	Kombinacje, czyli wybieranie bez kolejności	13
2.6	Losowanie bez zwracania i schemat klasyczny	13
2.7	Metoda gwiazdek i kresek	13
2.7.1	Rozwiązania nieujemne	14
2.7.2	Rozwiązania dodatnie	14
2.8	Brak sąsiednich elementów	15
2.9	Liczenie przez dopełnienie	16
2.10	Przykład z butami	16
2.11	Karty: kiedy trzeba uważać na nakładanie przypadków	17
2.12	Zasada włączeń i wyłączeń	18
2.13	Problem kopert, czyli nieporządki	19
2.14	Wszystkie osoby muszą się pojawić: lekcje i uczniowie	19
2.15	Zadania z samych własności prawdopodobieństwa	20
2.16	Jak rozpoznawać typ zadania?	21

2.17	Najczęstsze błędy	22
3	Prawdopodobieństwo warunkowe i niezależność zdarzeń	23
3.1	Mapa tematu	23
3.2	Pierwszy przykład: urna i dodatkowa informacja	23
3.3	Definicja prawdopodobieństwa warunkowego	24
3.4	Prawdopodobieństwo warunkowe jako nowa miara	25
3.5	Wzór mnożenia prawdopodobieństw	26
3.5.1	Wzór mnożenia dla wielu zdarzeń	26
3.6	Przykład: losowanie do pierwszej czarnej kuli	26
3.6.1	Bez zwracania	27
3.6.2	Ze zwracaniem	27
3.7	Rozbicie przestrzeni i prawdopodobieństwo całkowite	27
3.8	Wzór Bayesa	28
3.9	Przykład Bayesa: dwie urny	29
3.10	Przykład Bayesa: test medyczny	30
3.11	Niezależność zdarzeń	30
3.12	Rozłączność to nie to samo co niezależność	31
3.13	Niezależność dopełnień	32
3.14	Niezależność wielu zdarzeń	32
3.15	Niezależne doświadczenia i przestrzeń produktowa	33
3.16	Schemat Bernoulliego	33
3.17	Zdarzenia zachodzące nieskończenie wiele razy	35
3.18	Jak rozwiązywać zadania z warunkowania?	36
3.19	Zadania z rozwiązaniami	36
3.20	Najczęstsze błędy	38
4	Zmienne losowe i ich rozkłady	40
4.1	Mapa tematu	40
4.2	Od zdarzeń do zmiennych losowych	40
4.2.1	Dlaczego samo zdarzenie czasem nie wystarcza?	40
4.2.2	Formalna definicja	41
4.3	Rozkład zmiennej losowej	41
4.3.1	Co to znaczy, że znamy rozkład?	41
4.4	Dystrybuanta	42
4.4.1	Definicja i pierwsza intuicja	42
4.4.2	Własności dystrybucyj	43
4.5	Wektory losowe i rozkłady brzegowe	44
4.5.1	Wektor losowy	44
4.5.2	Rozkłady brzegowe	45
4.6	Niezależność zmiennych losowych	45

4.6.1	Definicja	45
4.7	Zmienne dyskretne	46
4.7.1	Definicja i funkcja masy	46
4.7.2	Najważniejsze rozkłady dyskretne	46
4.8	Zmienne ciągłe i gęstości	48
4.8.1	Gęstość jako „masa rozsmarowana”	48
4.8.2	Dystrybuanta zmiennej ciągłej	49
4.9	Najważniejsze rozkłady ciągłe	49
4.9.1	Rozkład jednostajny	49
4.9.2	Rozkład wykładniczy	50
4.9.3	Rozkład normalny	50
4.10	Gęstości brzegowe i niezależność w przypadku ciągłym	51
4.10.1	Gęstości brzegowe	51
4.10.2	Kryterium niezależności przez gęstości	51
4.11	Suma niezależnych zmiennych i splot	52
4.11.1	O co chodzi ze splotem?	52
4.12	Zadania z rozwiązaniami	53
4.13	Najczęstsze błędy	55
5	Wartość oczekiwana, wariancja i parametry rozkładu	57
5.1	Mapa tematu	57
5.2	Wartość oczekiwana: średnia ważona	57
5.3	Formalna definicja wartości oczekiwanej	58
5.4	Wartość oczekiwana dla zmiennej dyskretnej	58
5.5	Wartość oczekiwana dla zmiennej ciągłej	59
5.6	Kiedy wartość oczekiwana nie istnieje?	60
5.7	Liniowość wartości oczekiwanej	60
5.8	Momenty i przestrzenie L^p	60
5.9	Nierówność Czebyszewa i Markowa	61
5.10	Wariancja i odchylenie standardowe	61
5.11	Nierówność Czebyszewa dla wariancji	62
5.12	Najważniejsze średnie i wariancje rozkładów	63
5.13	Iloczyn wartości oczekiwanych i niezależność	63
5.14	Kowariancja	63
5.15	Wariancja sumy	64
5.16	Współczynnik korelacji	64
5.17	Wektor wartości oczekiwanej i macierz kowariancji	65
5.18	Regresja liniowa: najlepsze liniowe przybliżenie	66
5.19	Schematy rozwiązywania zadań	66
5.20	Zadania z rozwiązaniami	67
5.21	Najczęstsze błędy	68

6	Różne rodzaje zbieżności zmiennych losowych	70
6.1	Mapa tematu	70
6.2	Dlaczego w ogóle jest kilka zbieżności?	70
6.3	Zbieżność prawie na pewno	71
6.4	Zbieżność według prawdopodobieństwa	71
6.5	Zbieżność prawie na pewno implikuje zbieżność według prawdopodobieństwa . . .	72
6.6	Przykład: zbieżność według prawdopodobieństwa, ale nie prawie na pewno	72
6.7	Zbieżność w L^p	73
6.8	Relacje między zbieżnościami	74
6.9	Zbieżność w L^q daje zbieżność w L^p dla $q > p$	75
6.10	Warunek Cauchy'ego według prawdopodobieństwa	76
6.11	Podciąg zbieżny prawie na pewno	76
6.12	Jednostajna całkowalność	76
6.13	Zbieżność w L^p a jednostajna całkowalność	77
6.14	Krótką uwagę o zbieżności według rozkładu	78
6.15	Jak rozpoznawać typowe zadania?	78
6.16	Zadania z rozwiązaniami	79
6.17	Najczęstsze błędy	81
7	Prawa wielkich liczb	82
7.1	Mapa tematu	82
7.2	Średnia empiryczna i średnia teoretyczna	82
7.3	Słabe prawo wielkich liczb	83
7.3.1	Dowód słabego prawa krok po kroku	83
7.4	Przykład: częstość sukcesów w schemacie Bernoulliego	84
7.5	Mocne prawo wielkich liczb	84
7.5.1	Dlaczego mocne prawo jest trudniejsze?	85
7.6	Nierówność Kołmogorowa	85
7.7	Idea dowodu mocnego prawa	86
7.7.1	Wersja łatwiejsza: zmienne z drugim momentem	86
7.7.2	Wersja ogólna: tylko całkowalność	87
7.8	Co jeśli zmienna nie jest całkowalna?	87
7.9	Dystrybuenta empiryczna	87
7.10	Jak rozpoznawać zadania z praw wielkich liczb?	88
7.11	Zadania z rozwiązaniami	89
7.12	Najczęstsze błędy	90
8	Twierdzenie de Moivre'a-Laplace'a i przybliżenie normalne	92
8.1	Mapa tematu	92
8.2	Przypomnienie: rozkład Bernoulliego i rozkład dwumianowy	92
8.3	Dlaczego pojawia się rozkład normalny?	93

8.4	Lokalne twierdzenie de Moivre’a-Laplace’a	94
8.5	Integralne twierdzenie de Moivre’a-Laplace’a	95
8.6	Jak używać twierdzenia w zadaniach?	96
8.7	Przykłady z pełnym rozwiązaniem	97
8.8	Kiedy przybliżenie normalne działa dobrze?	99
8.9	Związek z centralnym twierdzeniem granicznym	100
8.10	Zadania z rozwiązaniami	100
8.11	Miniściaga	101
9	Warunkowa wartość oczekiwana	103
9.1	Mapa tematu	103
9.2	Najpierw przykład bez formalizmu	103
9.3	Warunkowanie względem skończonego podziału	104
9.4	Czym jest informacja w probablistyce?	105
9.5	Formalna definicja	105
9.6	Jak czytać warunek całkowity?	105
9.7	Warunkowanie względem zmiennej losowej	106
9.8	Przypadek dyskretny	106
9.9	Przypadek ciągły i gęstość warunkowa	107
9.10	Najważniejsze własności	108
9.10.1	Zachowanie średniej	109
9.10.2	Jeśli coś już wiemy, to nie uśredniamy tego ponownie	109
9.10.3	Jeśli czegoś nie widać, zostaje zwykła średnia	109
9.11	Własność wyciągania znanego czynnika	109
9.12	Własność wieży	110
9.13	Warunkowa wartość oczekiwana jako najlepsza prognoza	110
9.14	Regresja nieliniowa	111
9.15	Nierówność Jensena warunkowa	111
9.16	Typowe schematy liczenia	111
9.17	Najczęstsze błędy	112
9.18	Zadania z rozwiązaniami	113
9.19	Miniściaga	114

1. Eksperyment losowy, zdarzenia i prawdopodobieństwo

1.1 Mapa tematu

W tym rozdziale uczymy się pierwszej, absolutnie podstawowej rzeczy: jak zamienić niepewną sytuację z życia na obiekt matematyczny. Rachunek prawdopodobieństwa nie zaczyna się od wzorów. Zaczyna się od bardzo prostego pytania:

Co właściwie może się wydarzyć?

Dopiero potem pytamy:

Jaką szansę przypisujemy poszczególnym zdarzeniom?

Będziemy mówić o trzech poziomach opisu:

1. **wyniki elementarne** – najdrobniejsze możliwe wyniki doświadczenia;
2. **zdarzenia** – zbiory wyników elementarnych, czyli pytania typu „czy wynik należy do tego zbioru?”;
3. **prawdopodobieństwo** – funkcja przypisująca zdarzeniom liczby od 0 do 1.

Intuicja. Rachunek prawdopodobieństwa to nie jest magia przewidywania przyszłości. To język opisu sytuacji, w których wynik jest niepewny, ale umiemy zbudować sensowny model. Model mówi nam, co jest możliwe i jaką szansę ma każda grupa wyników.

1.2 Doświadczenie losowe i przestrzeń wyników

Definicja 1.1: Doświadczenie losowe. Doświadczeniem losowym nazywamy doświadczenie, którego wyniku nie znamy przed wykonaniem, ale umiemy opisać zbiór możliwych wyników.

Typowe doświadczenia losowe:

- rzut monetą,
- rzut kostką,
- losowanie karty z talii,
- losowanie kuli z urny,
- wybór losowego punktu z odcinka,
- rzucanie monetą aż do pierwszego orła.

Definicja 1.2: Przestrzeń wyników. Zbiór wszystkich możliwych najprostszych wyników doświadczenia oznaczamy przez

$$\Omega.$$

Elementy zbioru Ω nazywamy wynikami elementarnymi albo zdarzeniami elementarnymi. Zwykle oznaczamy je literą ω .

Przykład 1.1: Rzut monetą. Rzucamy monetą. Możliwe wyniki są dwa:


$$\Omega = \{O, R\},$$

gdzie

$$O = \text{orzeł}, \quad R = \text{reszka}.$$

Jeżeli moneta jest symetryczna, przyjmujemy

$$\mathbb{P}(\{O\}) = \frac{1}{2}, \quad \mathbb{P}(\{R\}) = \frac{1}{2}.$$



Uwaga. Samo zdanie „rzucamy monetą” nie wymusza jeszcze prawdopodobieństw $1/2$ i $1/2$. To jest dodatkowe założenie o symetrii monety. Gdyby moneta była spreparowana, moglibyśmy mieć na przykład $\mathbb{P}(O) = 0.8$ i $\mathbb{P}(R) = 0.2$.

1.3 Zdarzenia jako zbiory wyników

Często nie interesuje nas dokładny wynik doświadczenia, tylko to, czy wynik spełnia pewien warunek.

Przy rzucie kostką możemy nie pytać „czy wypadło dokładnie 4?”, tylko:

- czy wypadła liczba parzysta?
- czy wypadła liczba większa od 3?
- czy wypadła liczba podzielna przez 3?

Każde takie pytanie odpowiada pewnemu podzbiorowi Ω .

Definicja 1.3: Zdarzenie. Zdarzeniem nazywamy podzbiór przestrzeni wyników:

$$A \subseteq \Omega.$$

Jeżeli po wykonaniu doświadczenia otrzymamy wynik $\omega \in A$, mówimy, że zdarzenie A zaszło.

Przykład 1.2: Rzut kostką. Rzucamy kostką. Wtedy


$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Niech A oznacza zdarzenie „wypadła liczba podzielna przez 3”. Wtedy

$$A = \{3, 6\}.$$

Jeżeli kostka jest uczciwa, to każdy wynik ma prawdopodobieństwo $1/6$, więc

$$\mathbb{P}(A) = \mathbb{P}(\{3, 6\}) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}.$$



1.4 Najprostszy schemat: prawdopodobieństwo klasyczne

W wielu pierwszych zadaniach spotykamy sytuację, w której:

1. przestrzeń wyników Ω jest skończona;
2. wszystkie wyniki elementarne są jednakowo prawdopodobne.

Wtedy działa najprostszy wzór.

Twierdzenie 1.1: Schemat klasyczny. Jeżeli Ω jest zbiorem skończonym i wszystkie wyniki elementarne są jednakowo prawdopodobne, to dla każdego zdarzenia $A \subseteq \Omega$ mamy

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

Inaczej mówiąc:

$$\mathbb{P}(A) = \frac{\text{liczba wyników sprzyjających}}{\text{liczba wszystkich wyników}}.$$

Uwaga. Wzoru $\mathbb{P}(A) = |A|/|\Omega|$ wolno używać tylko wtedy, gdy wyniki elementarne są równoprawdopodobne. Jeśli wyniki mają różne szanse, sam iloraz licznosci da złą odpowiedź.

Przykład 1.3: Dwa rzuty kostką. Rzucamy dwa razy uczciwą kostką. Wynikiem jest para

$$(i, j),$$

gdzie i to wynik pierwszego rzutu, a j to wynik drugiego rzutu. Mamy więc

$$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}.$$

Stąd

$$|\Omega| = 6 \cdot 6 = 36.$$

Interesuje nas zdarzenie A : „w obu rzutach wypadła ta sama liczba oczek”. Wtedy

$$A = \{(1, 1), (2, 2), (3, 3), (4, 4), (5, 5), (6, 6)\},$$

więc $|A| = 6$. Zatem

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{6}{36} = \frac{1}{6}.$$

drugi rzut ↑

(1, 6)	(2, 6)	(3, 6)	(4, 6)	(5, 6)	(6, 6)
(1, 5)	(2, 5)	(3, 5)	(4, 5)	(5, 5)	(6, 5)
(1, 4)	(2, 4)	(3, 4)	(4, 4)	(5, 4)	(6, 4)
(1, 3)	(2, 3)	(3, 3)	(4, 3)	(5, 3)	(6, 3)
(1, 2)	(2, 2)	(3, 2)	(4, 2)	(5, 2)	(6, 2)
(1, 1)	(2, 1)	(3, 1)	(4, 1)	(5, 1)	(6, 1)

← pierwszy rzut →

wyniki sprzyjające

1.5 Pułapka modelowania: przykład z urną

Zobaczmy, dlaczego trzeba uważać przy wyborze przestrzeni wyników.

Przykład 1.4: Urna z kulami. W urnie jest jedna kula biała, dwie czarne i trzy zielone. Losujemy jedną kulę. Szukamy prawdopodobieństwa wylosowania kuli zielonej.

Możemy najpierw pomyśleć:

$$\Omega = \{B, C, Z\}.$$

Ale wtedy wyniki nie są jednakowo prawdopodobne, bo kul zielonych jest więcej niż białych. Mamy:

$$\mathbb{P}(B) = \frac{1}{6}, \quad \mathbb{P}(C) = \frac{2}{6} = \frac{1}{3}, \quad \mathbb{P}(Z) = \frac{3}{6} = \frac{1}{2}.$$

Wygodniej jest rozróżnić konkretne kule:


$$\Omega = \{B, C_1, C_2, Z_1, Z_2, Z_3\}.$$

Teraz każdy wynik odpowiada jednej konkretnej kuli i wszystkie wyniki są równoprawdopodobne. Zdarzenie „wylosowano kulę zieloną” to

$$A = \{Z_1, Z_2, Z_3\}.$$

Zatem

$$\mathbb{P}(A) = \frac{3}{6} = \frac{1}{2}.$$



Ważne. Najważniejsza lekcja: wynik elementarny powinien być dobrany tak, żeby model naprawdę odpowiadał doświadczeniu. Czasem „kolor kuli” nie jest dobrym wynikiem elementarnym, bo kolory nie mają równych szans. Konkretna kula bywa lepszym wynikiem elementarnym.

1.6 Działania na zdarzeniach

Ponieważ zdarzenia są zbiorami, możemy wykonywać na nich działania zbiorowe. Każde z tych działań ma interpretację probabilistyczną.

Zapis	Znaczenie probabilistyczne
Ω	zdarzenie pewne, czyli coś z przestrzeni wyników na pewno zajdzie
$\emptyset$	zdarzenie niemożliwe
$A \cap B$	zaszło jednocześnie A i B
$A \cup B$	zaszło A lub B (jedno, drugie albo oba)
A^c	nie zaszło A
$A \setminus B$	zaszło A , ale nie zaszło B
$A \subseteq B$	zajście A pociąga zajście B
$A \cap B = \emptyset$	zdarzenia A i B wykluczają się

Przykład 1.5: Działania na zdarzeniach przy rzucie kostką. Rzucamy kostką:

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Niech

$$A = \text{wypadła liczba parzysta} = \{2, 4, 6\},$$

$$B = \text{wypadła liczba większa od 3} = \{4, 5, 6\}.$$

Wtedy

$$A \cap B = \{4, 6\},$$

bo 4 i 6 są jednocześnie parzyste i większe od 3. Dalej

$$A \cup B = \{2, 4, 5, 6\},$$

$$A^c = \{1, 3, 5\},$$

$$A \setminus B = \{2\}.$$

1.7 σ -ciało, czyli które zdarzenia dopuszczamy?

W prostych skończonych przykładach zwykle dopuszczamy wszystkie podzbiory Ω . Czyli bierzemy

$$\mathcal{F} = 2^\Omega.$$

Dla rzutu kostką oznacza to, że każde pytanie typu „czy wynik należy do tego podzbioru?” jest dozwolonym zdarzeniem.

W bardziej zaawansowanych przykładach, zwłaszcza gdy Ω jest nieprzeliczalne, zbiór wszystkich podzbiorów może być zbyt duży. Wtedy wybiera się pewną dobrze zachowującą się rodzinę zdarzeń $\mathcal{F}$.

Definicja 1.4: σ -ciało. Rodzinę $\mathcal{F}$ podzbiorów Ω nazywamy σ -ciałem, jeżeli:

- (i) $\emptyset \in \mathcal{F}$;
- (ii) jeżeli $A \in \mathcal{F}$, to $A^c \in \mathcal{F}$;
- (iii) jeżeli $A_1, A_2, A_3, \dots \in \mathcal{F}$, to

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Parę $(\Omega, \mathcal{F})$ nazywamy przestrzenią mierzalną.

Intuicja. σ -ciało to lista zdarzeń, o których wolno nam mówić i którym wolno przypisywać prawdopodobieństwo. Warunki w definicji mówią, że jeśli umiemy mierzyć zdarzenia $A_1, A_2, \dots$, to umiemy też mierzyć ich sumę, dopełnienie i zdarzenia zbudowane z nich przez podstawowe operacje.

1.8 Aksjomaty Kołmogorowa

Pełny model probabilistyczny składa się z trzech elementów:

$$(\Omega, \mathcal{F}, \mathbb{P}).$$

Są to:

- Ω – przestrzeń wyników;
- $\mathcal{F}$ – rodzina dopuszczalnych zdarzeń;
- $\mathbb{P}$ – funkcja przypisująca zdarzeniom ich prawdopodobieństwa.

Definicja 1.5: Przestrzeń probabilistyczna. Niech $(\Omega, \mathcal{F})$ będzie przestrzenią mierzalną. Funkcję

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$$

nazywamy prawdopodobieństwem, jeżeli spełnia dwa warunki:

- (i)

$$\mathbb{P}(\Omega) = 1;$$

(ii) dla dowolnych parami rozłącznych zdarzeń $A_1, A_2, A_3, \dots \in \mathcal{F}$ zachodzi

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Trójkę $(\Omega, \mathcal{F}, \mathbb{P})$ nazywamy przestrzenią probabilistyczną.

Intuicja. Warunek $\mathbb{P}(\Omega) = 1$ mówi, że zdarzenie pewne ma prawdopodobieństwo 1. Drugi warunek mówi, że jeśli zdarzenia się wykluczają, to prawdopodobieństwo ich sumy jest sumą prawdopodobieństw. Czyli dla rozłącznych kawałków możemy po prostu dodawać szanse.

1.9 Podstawowe własności prawdopodobieństwa

Z aksjomatów Kołmogorowa wynikają wzory, których używa się w prawie każdym zadaniu.

Twierdzenie 1.2: Własności prawdopodobieństwa. Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną oraz niech $A, B, A_1, A_2, \dots \in \mathcal{F}$. Wtedy:

(a) $\mathbb{P}(\emptyset) = 0$;

(b) jeśli $A_1, \dots, A_n$ są parami rozłączne, to

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i);$$

(c)

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A);$$

(d) jeśli $A \subseteq B$, to

$$\mathbb{P}(A) \leq \mathbb{P}(B);$$

(e)

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B);$$

(f)


$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

1.9.1 Dlaczego wzór na sumę ma minus?

Najczęściej używany wzór z powyższego twierdzenia to

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Jeżeli dodamy $\mathbb{P}(A) + \mathbb{P}(B)$, to część wspólna $A \cap B$ zostanie policzona dwa razy. Dlatego odejmujemy ją raz.



$A \cap B$ jest w A i w B , więc przy dodawaniu $\mathbb{P}(A) + \mathbb{P}(B)$ liczymy je dwa razy.

Przykład 1.6: Wzór na sumę przy rzucie kostką. Rzucamy uczciwą kostką. Niech

$$A = \{2, 4, 6\}, \quad B = \{4, 5, 6\}.$$

Wtedy

$$A \cap B = \{4, 6\}.$$

Mamy

$$\mathbb{P}(A) = \frac{3}{6}, \quad \mathbb{P}(B) = \frac{3}{6}, \quad \mathbb{P}(A \cap B) = \frac{2}{6}.$$

Zatem

$$\mathbb{P}(A \cup B) = \frac{3}{6} + \frac{3}{6} - \frac{2}{6} = \frac{4}{6} = \frac{2}{3}.$$

Rzeczywiście,

$$A \cup B = \{2, 4, 5, 6\}.$$

1.10 Prawdopodobieństwo geometryczne

Nie zawsze przestrzeń wyników jest skończona. Czasem losujemy punkt z odcinka, koła, kwadratu albo innego obszaru. Wtedy nie liczymy liczby punktów, bo punktów jest nieskończenie wiele. Zamiast tego liczymy długość, pole albo objętość.

Twierdzenie 1.3: Prawdopodobieństwo geometryczne. Jeżeli losujemy punkt jednostajnie ze zbioru $\Omega \subseteq \mathbb{R}^d$, gdzie $0 < |\Omega| < \infty$, to dla odpowiednio mierzalnego zdarzenia $A \subseteq \Omega$ przyjmujemy

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

Tutaj $|\cdot|$ oznacza długość, pole, objętość albo ogólnie miarę Lebesgue'a w odpowiednim wymiarze.

Przykład 1.7: Losowanie z odcinka. Losujemy liczbę z odcinka

$$[-1, 2].$$

Szukamy prawdopodobieństwa, że wylosowana liczba będzie większa od 1.

Mamy


$$\Omega = [-1, 2], \quad A = [1, 2].$$

Długości wynoszą

$$|\Omega| = 3, \quad |A| = 1.$$

Zatem

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{1}{3}.$$



Uwaga. Samo zdanie „losujemy punkt z odcinka” zwykle oznacza losowanie jednostajne, ale matematycznie trzeba to dopowiedzieć. Można wymyślić losowanie z tego samego odcinka, które nie jest jednostajne, na przykład wybiera tylko punkty 0 i 1 po rzucie monetą.

1.11 Paradoks Bertranda, czyli dlaczego model jest wszystkim


Paradoks Bertranda pokazuje, że pytanie probabilistyczne bez precyzyjnego modelu może mieć kilka różnych poprawnych odpowiedzi.

Ważne. Pytanie „losujemy losową cięciwę okręgu” nie jest jeszcze pełnym modelem. Trzeba powiedzieć, co dokładnie znaczy „losowa cięciwa”: losujemy kąt? środek cięciwy? odległość środka cięciwy od środka okręgu? Każdy wybór daje inny model.

Dla okręgu o promieniu 1 można zapytać o prawdopodobieństwo, że losowa cięciwa jest dłuższa niż bok trójkąta równobocznego wpisanego w ten okrąg. W zależności od sposobu losowania otrzymuje się wyniki:

$$\frac{1}{3}, \quad \frac{1}{4}, \quad \frac{1}{2}.$$

To nie jest sprzeczność. To są trzy różne modele probabilistyczne.



Losowanie cięciwy można opisać różnymi parametrami. Zmieniamy parametr – zmieniamy przestrzeń probabilistyczną.

1.12 Schematy rozwiązywania pierwszych zadań

Ważne. Jeżeli widzisz zadanie z kostką, kartami, kulami, ustawieniami albo losowaniem bez dodatkowych wag, zwykle sprawdź:

1. Co jest wynikiem elementarnym?
2. Ile jest wszystkich wyników, czyli ile wynosi $|\Omega|$?
3. Ile wyników sprzyja zdarzeniu A , czyli ile wynosi $|A|$?
4. Czy wyniki są naprawdę równoprawdopodobne?
5. Jeśli tak, użyj

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

Ważne. Jeżeli zdarzenie A jest opisane słowami „co najmniej jeden”, „nie wszystkie”, „przynajmniej raz”, często łatwiej policzyć zdarzenie przeciwne A^c i użyć wzoru

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c).$$

Zadanie z rozwiązaniem. Treść. Rzucamy uczciwą kostką dwa razy. Oblicz prawdopodobieństwo, że suma oczek wynosi 4.

Rozwiązanie. Wynikiem elementarnym jest para (i, j) , gdzie $i, j \in \{1, 2, 3, 4, 5, 6\}$. Zatem

$$|\Omega| = 36.$$

Suma oczek wynosi 4 dla par

$$(1, 3), \quad (2, 2), \quad (3, 1).$$

Mamy więc $|A| = 3$. Wszystkie pary są równoprawdopodobne, zatem

$$\mathbb{P}(A) = \frac{3}{36} = \frac{1}{12}.$$

Zadanie z rozwiązaniem. Treść. Rzucamy uczciwą kostką. Oblicz prawdopodobieństwo, że wypadnie liczba parzysta lub większa od 3.

Rozwiązanie. Niech

$$A = \{2, 4, 6\}, \quad B = \{4, 5, 6\}.$$

Szukamy $\mathbb{P}(A \cup B)$. Mamy

$$A \cap B = \{4, 6\}.$$

Stąd

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) = \frac{3}{6} + \frac{3}{6} - \frac{2}{6} = \frac{4}{6} = \frac{2}{3}.$$

1.13 Najczęstsze błędy

Uwaga. Nie wolno automatycznie pisać $\mathbb{P}(A) = |A|/|\Omega|$. Najpierw trzeba sprawdzić, czy wyniki elementarne są jednakowo prawdopodobne.

Uwaga. W matematyce $A \cup B$ oznacza: zaszło A lub B , przy czym dopuszczamy, że zaszły oba naraz. Jeśli zdarzenia mogą zajść jednocześnie, trzeba odjąć część wspólną.

Uwaga. Przed liczeniem trzeba jasno powiedzieć, czym jest pojedynczy wynik. Przy dwóch rzutach kostką wynikiem nie jest liczba od 1 do 6, tylko para (i, j) .

Podsumowanie.

1. Przestrzeń wyników oznaczamy przez Ω .
2. Wynik elementarny oznaczamy zwykle przez $\omega \in \Omega$.
3. Zdarzenie to podzbiór $A \subseteq \Omega$.
4. Pełny model probabilistyczny to trójka

$$(\Omega, \mathcal{F}, \mathbb{P}).$$

5. Jeśli Ω jest skończone i wyniki są równoprawdopodobne, to

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

6. Zdarzenie przeciwne liczymy ze wzoru

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A).$$

7. Dla dwóch zdarzeń

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

8. Jeżeli $A \cap B = \emptyset$, to

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

9. W prawdopodobieństwie geometrycznym liczymy stosunek miar:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

10. Największa pułapka: bez dobrze określonego modelu nie ma jednej odpowiedzi na pytanie probabilistyczne.

2. Kombinatoryka do rachunku prawdopodobieństwa

2.1 Mapa tematu

W poprzednim rozdziale nauczyliśmy się budować model probabilistyczny: wybieramy przestrzeń wyników Ω , opisujemy zdarzenia i przypisujemy im prawdopodobieństwa. W bardzo wielu zadaniach następny krok jest brutalnie prosty:

trzeba dobrze policzyć, ile jest możliwości.

Jeżeli jesteśmy w schemacie klasycznym, czyli wszystkie wyniki elementarne są jednakowo prawdopodobne, to używamy wzoru

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}.$$

Cała trudność polega wtedy na policzeniu dwóch liczb:

$$|\Omega| \quad \text{oraz} \quad |A|.$$

Intuicja. Kombinatoryka w prawdopodobieństwie jest jak liczenie miejsc na parkingu. Najpierw pytamy: ile jest wszystkich miejsc? Potem: ile z nich spełnia warunek z zadania? Prawdopodobieństwo to proporcja dobrych miejsc do wszystkich miejsc.

W tym rozdziale uczymy się narzędzi, które pojawiają się ciągle:

- reguła mnożenia i reguła dodawania,
- permutacje,
- permutacje z powtórzeniami,
- wariacje,
- kombinacje,
- metoda „gwiazdek i kresek”,
- liczenie przez dopełnienie,
- zasada włączeń i wyłączeń.

2.2 Dwie podstawowe reguły liczenia

2.2.1 Reguła dodawania

Twierdzenie 2.1: Reguła dodawania. Jeżeli pewien wybór można wykonać na jeden z rozłącznych sposobów:

$$A_1, A_2, \dots, A_m,$$

i liczby możliwości wynoszą odpowiednio

$$|A_1|, |A_2|, \dots, |A_m|,$$

to łączna liczba możliwości wynosi

$$|A_1| + |A_2| + \dots + |A_m|.$$

Intuicja. Reguły dodawania używamy, gdy mamy sytuację typu: albo przypadek pierwszy, albo przypadek drugi, albo przypadek trzeci. Ważne: przypadki nie mogą się nakładać, bo wtedy policzylibyśmy coś podwójnie.

Przykład 2.1: Prosty przykład. W pudełku są 3 długopisy niebieskie i 5 długopisów czarnych. Na ile sposobów można wybrać jeden długopis?

Możemy wybrać:

- jeden z 3 niebieskich,
- albo jeden z 5 czarnych.

Razem:

$$3 + 5 = 8.$$

2.2.2 Reguła mnożenia

Twierdzenie 2.2: Reguła mnożenia. Jeżeli wybór wykonujemy etapami i:

- pierwszy etap można wykonać na n_1 sposobów,
- drugi etap na n_2 sposobów,
- m -ty etap na n_m sposobów,

to łączna liczba możliwości wynosi

$$n_1 \cdot n_2 \cdots n_m.$$

Intuicja. Reguły mnożenia używamy, gdy decyzje robimy po kolei. Na przykład: najpierw wybieram bluzkę, potem spodnie, potem buty. Każdy komplet powstaje z połączenia wyborów z kolejnych etapów.

Przykład 2.2: Dwa rzuty kostką. Rzucamy dwa razy kostką. Pierwszy rzut ma 6 możliwości, drugi też ma 6 możliwości. Zatem liczba par wyników wynosi

$$6 \cdot 6 = 36.$$

Dlatego dla dwóch rzutów kostką piszemy

$$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}$$

i

$$|\Omega| = 36.$$

Uwaga. Nie mieszamy reguły dodawania i mnożenia na ślepo. Jeżeli wybieramy „jedno albo drugie”, zwykle dodajemy. Jeżeli wybieramy „najpierw jedno, potem drugie”, zwykle mnożymy.

2.3 Silnia, czyli ustawianie różnych obiektów w kolejności

Definicja 2.1: Silnia. Dla liczby naturalnej n definiujemy

$$n! = 1 \cdot 2 \cdot 3 \cdots n.$$

Przyjmujemy też

$$0! = 1.$$


Intuicja. Liczba $n!$ mówi, na ile sposobów można ustawić w kolejce n różnych obiektów. Na pierwszym miejscu mamy n wyborów, na drugim $n - 1$, potem $n - 2$, aż zostanie jeden wybór. Dlatego

$$n! = n(n - 1)(n - 2) \cdots 1.$$

Przykład 2.3: Ustawianie trzech osób. Mamy trzy osoby: Anię, Basię i Celinę. Na ile sposobów można ustawić je w kolejce?

Na pierwsze miejsce mamy 3 wybory. Na drugie zostają 2 osoby. Na trzecie zostaje 1 osoba. Razem:

$$3 \cdot 2 \cdot 1 = 3! = 6.$$



2.4 Permutacje z powtórzeniami

Często nie wszystkie obiekty są różne. Na przykład ustawiamy w ciąg litery, wśród których kilka jest takich samych, albo cyfry z powtórzeniami. Wtedy zwykle $n!$ liczy za dużo.

Twierdzenie 2.3: Permutacje z powtórzeniami. Jeżeli mamy łącznie n obiektów, wśród których:

- obiektów pierwszego typu jest n_1 ,
- obiektów drugiego typu jest n_2 ,
- ...
- obiektów r -tego typu jest n_r ,

przy czym

$$n_1 + n_2 + \dots + n_r = n,$$

to liczba różnych ustawień wynosi

$$\frac{n!}{n_1! n_2! \dots n_r!}.$$

Intuicja. Gdyby wszystkie obiekty były różne, byłyby $n!$ ustawień. Ale jeśli na przykład sześć jedynek jest nierozróżnialnych, to przestawianie tych jedynek między sobą nie daje nowego ustawienia. Dlatego dzielimy przez silnie licznosci powtórzeń.

Zadanie z rozwiązaniem. Na ile sposobów można ustawić w ciąg sześć jedynek, pięć dwójek oraz cztery trójki?

Rozwiązanie.

Mamy łącznie

$$6 + 5 + 4 = 15$$

znaków. Gdyby wszystkie były różne, byłyby $15!$ ustawień. Ale jedynki są między sobą nierozróżnialne, dwójki też i trójki też. Dlatego dzielimy przez

$$6!, \quad 5!, \quad 4!.$$

Odpowiedź:

$$\frac{15!}{6!5!4!}.$$

2.5 Kombinacje, czyli wybieranie bez kolejności

Definicja 2.2: Symbol Newtona. Liczbę sposobów wyboru k elementów spośród n elementów, bez zwracania uwagi na kolejność, oznaczamy przez

$$\binom{n}{k}$$

i obliczamy ze wzoru

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

Intuicja. Symbol $\binom{n}{k}$ odpowiada pytaniu: na ile sposobów mogę wybrać drużynę k osób z grupy n osób? Kolejność w drużynie nie ma znaczenia. Drużyna {Ala, Bartek} jest tą samą drużyną co {Bartek, Ala}.

Przykład 2.4: Wybór komisji. Z grupy 10 osób wybieramy komisję 3-osobową. Liczba możliwości wynosi

$$\binom{10}{3} = \frac{10!}{3!7!} = 120.$$

Uwaga. To jest najważniejsze pytanie w kombinatoryce. Jeżeli wybieramy podium: pierwsze, drugie i trzecie miejsce, kolejność ma znaczenie. Jeżeli wybieramy trzy osoby do komisji, kolejność nie ma znaczenia.

2.6 Losowanie bez zwracania i schemat klasyczny

W wielu zadaniach losujemy pewien podzbiór, na przykład karty z talii albo liczby w Totolotku. Wtedy przestrzeń wyników często ma postać zbioru wszystkich k -elementowych podzbiorów.

Ważne. Jeżeli losujemy k elementów z n bez zwracania i nie interesuje nas kolejność losowania, to liczba wszystkich wyników wynosi

$$\binom{n}{k}.$$

Przykład 2.5: Totolotek jako model. W standardowym modelu losowania sześciu liczb z 49 liczb przestrzeń wyników ma licznosc

$$|\Omega| = \binom{49}{6}.$$

Każdy wynik to jeden sześcioliterowy zbiór, na przykład

$$\{3, 7, 12, 18, 31, 44\}.$$

Kolejność nie ma znaczenia.

2.7 Metoda gwiazdek i kresek

Teraz zajmijmy się klasycznym pytaniem: ile jest rozwiązań równania

$$x_1 + x_2 + \cdots + x_m = n$$

w liczbach całkowitych nieujemnych albo dodatnich.

2.7.1 Rozwiązania nieujemne

Twierdzenie 2.4: Gwiazdki i kreski - wersja nieujemna. Liczba rozwiązań równania

$$x_1 + x_2 + \cdots + x_m = n$$

w liczbach całkowitych nieujemnych wynosi

$$\binom{n+m-1}{m-1}.$$

Intuicja. Wyobraź sobie, że mamy n identycznych cukierków i chcemy rozdzielić je między m pudełek. Liczba x_i mówi, ile cukierków trafia do i -tego pudełka. Żeby opisać podział, ustawiamy n gwiazdek i wstawiamy między nie $m-1$ kresek oddzielających pudełka.

Dla przykładu zapis

$$\star\star || \star\star\star | \star$$

odpowiada rozwiązaniu

$$(x_1, x_2, x_3, x_4) = (2, 0, 3, 1).$$

Mamy łącznie n gwiazdek i $m-1$ kresek, czyli $n+m-1$ miejsc. Wybieramy, gdzie stoją kreski:

$$\binom{n+m-1}{m-1}.$$

2.7.2 Rozwiązania dodatnie

Jeżeli chcemy, aby wszystkie zmienne były dodatnie, podstawiamy

$$y_i = x_i - 1.$$

Wtedy $y_i \geq 0$. Równanie

$$x_1 + \cdots + x_m = n$$

przechodzi w

$$y_1 + \cdots + y_m = n - m.$$

Stąd liczba rozwiązań dodatnich wynosi

$$\binom{n-1}{m-1}.$$

Zadanie z rozwiązaniem. Wyznaczyć liczbę rozwiązań równania

$$x_1 + x_2 + x_3 + x_4 = 50.$$

a) W liczbach całkowitych nieujemnych.

Mamy $n = 50$ oraz $m = 4$. Zatem

$$\# = \binom{50+4-1}{4-1} = \binom{53}{3}.$$

b) W liczbach całkowitych dodatnich.

Podstawiamy

$$y_i = x_i - 1.$$

Wtedy

$$y_1 + y_2 + y_3 + y_4 = 50 - 4 = 46$$

i $y_i \geq 0$. Stąd

$$\# = \binom{46 + 4 - 1}{4 - 1} = \binom{49}{3}.$$

Odpowiedzi:

$$\boxed{\binom{53}{3}} \quad \text{oraz} \quad \boxed{\binom{49}{3}}.$$

2.8 Brak sąsiednich elementów

Bardzo ważny typ zadań brzmi: wybieramy kilka liczb, ale żadne dwie nie mogą być kolejne. Wtedy używa się małego triku z przesunięciem.

Twierdzenie 2.5: Wybór bez sąsiadów. Liczba sposobów wyboru k liczb ze zbioru

$$\{1, 2, \dots, n\}$$

tak, aby żadne dwie wybrane liczby nie były kolejne, wynosi

$$\binom{n - k + 1}{k}.$$

Intuicja. Jeżeli wybieramy liczby

$$a_1 < a_2 < \dots < a_k$$

i żadna para nie jest sąsiednia, to mamy

$$a_{i+1} \geq a_i + 2.$$

Robimy przesunięcie

$$b_i = a_i - (i - 1).$$

To usuwa obowiązkowe przerwy między wybranymi liczbami. Wtedy wybieramy zwykle k liczb ze zbioru mniejszego o $k - 1$ miejsc.

Zadanie z rozwiązaniem. Ile jest takich „szóstek” w Totolotku, że żadne dwie z wylosowanych liczb nie są kolejne?

Rozwiązanie.

W standardowym modelu wybieramy 6 liczb ze zbioru

$$\{1, 2, \dots, 49\}.$$

Chcemy, aby żadne dwie nie były kolejne. Korzystamy ze wzoru

$$\binom{n - k + 1}{k}.$$

Tutaj $n = 49$ oraz $k = 6$, więc liczba takich szóstek wynosi

$$\boxed{\binom{49 - 6 + 1}{6} = \binom{44}{6}}.$$

2.9 Liczenie przez dopełnienie

Czasem dużo łatwiej policzyć zdarzenie przeciwne. Zamiast liczyć bezpośrednio

$$\mathbb{P}(A),$$

liczymy

$$\mathbb{P}(A^c)$$

i używamy wzoru

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c).$$

Intuicja. Jeżeli pytanie brzmi „co najmniej jeden”, bardzo często warto pomyśleć o dopełnieniu, czyli „ani jeden”. Na przykład: prawdopodobieństwo, że wśród wyjętych butów jest co najmniej jedna para, łatwiej policzyć jako 1 minus prawdopodobieństwo, że nie ma żadnej pary.

2.10 Przykład z butami

Zadanie z rozwiązaniem. W szafie jest n par butów. Wyjmujemy na chybił trafił k butów, gdzie $k \leq n$. Obliczyć prawdopodobieństwo tego, że:

- wśród wyjętych butów jest co najmniej jedna para,
- wśród wyjętych butów jest dokładnie jedna para.

Rozwiązanie.

Mamy $2n$ pojedynczych butów. Losujemy k butów, więc liczba wszystkich wyników wynosi

$$|\Omega| = \binom{2n}{k}.$$

a) Co najmniej jedna para.

Liczymy przez dopełnienie. Zdarzenie przeciwne to: nie ma żadnej pełnej pary. Wtedy najpierw wybieramy k par, z których weźmiemy po jednym bucie:

$$\binom{n}{k}.$$

Z każdej wybranej pary wybieramy lewy albo prawy but, czyli mamy 2^k możliwości. Zatem

$$\#(\text{brak pary}) = \binom{n}{k} 2^k.$$

Stąd

$$\mathbb{P}(\text{co najmniej jedna para}) = 1 - \frac{\binom{n}{k} 2^k}{\binom{2n}{k}}.$$

b) Dokładnie jedna para.

Najpierw wybieramy parę, która ma być kompletna:

$$\binom{n}{1} = n.$$

Zostaje nam dobrać jeszcze $k - 2$ butów, ale tak, aby nie utworzyć żadnej kolejnej pary. Wybieramy więc $k - 2$ par spośród pozostałych $n - 1$ par:

$$\binom{n-1}{k-2},$$

a z każdej z nich wybieramy jeden z dwóch butów:

$$2^{k-2}.$$

Zatem dla $k \geq 2$ liczba dobrych wyborów wynosi

$$n \binom{n-1}{k-2} 2^{k-2}.$$

Czyli

$$\mathbb{P}(\text{dokładnie jedna para}) = \frac{n \binom{n-1}{k-2} 2^{k-2}}{\binom{2n}{k}}.$$

Dla $k < 2$ prawdopodobieństwo dokładnie jednej pary wynosi 0.

2.11 Karty: kiedy trzeba uważać na nakładanie przypadków

W zadaniach z kartami często pojawia się sformułowanie „istnieje kolor”. W talii 52 kart mamy 4 kolory, po 13 kart w każdym kolorze. Losujemy 13 kart.

Uwaga. Jeżeli pytamy, czy istnieje kolor z pewną liczbą kart, trzeba sprawdzić, czy dwa kolory jednocześnie mogą spełnić warunek. Jeśli mogą, proste pomnożenie przez 4 może liczyć niektóre ręce podwójnie.

Zadanie z rozwiązaniem. Z talii 52 kart wylosowano 13 kart. Jakie jest prawdopodobieństwo tego, że istnieje kolor, w którym dokładnie siedem kart jest tego samego koloru?

Rozwiązanie.

Liczba wszystkich rąk trzynastokartowych wynosi

$$\binom{52}{13}.$$

Chcemy, aby pewien kolor wystąpił dokładnie 7 razy. Najpierw wybieramy ten kolor: 4 możliwości. Potem wybieramy 7 kart z 13 kart tego koloru:

$$\binom{13}{7}.$$

Pozostałe 6 kart wybieramy z kart nienależących do tego koloru, czyli z 39 kart:

$$\binom{39}{6}.$$

Czy przypadki dla różnych kolorów mogą się nakładać? Nie, bo nie da się mieć jednocześnie dokładnie 7 kart jednego koloru i dokładnie 7 kart drugiego koloru w ręce złożonej tylko z 13 kart. Byłoby ich co najmniej 14.

Zatem

$$\mathbb{P} = \frac{4 \binom{13}{7} \binom{39}{6}}{\binom{52}{13}}.$$

Zadanie z rozwiązaniem. Z talii 52 kart wylosowano 13 kart. Jakie jest prawdopodobieństwo tego, że istnieje kolor, w którym dokładnie sześć kart jest tego samego koloru?

Rozwiązanie.

Tutaj trzeba uważać. Dwa różne kolory mogą jednocześnie wystąpić dokładnie po 6 razy, bo

$$6 + 6 + 1 = 13.$$

Dlatego używamy zasady włączeń i wyłączeń.

Niech A_i oznacza zdarzenie, że w i -tym kolorze mamy dokładnie 6 kart. Chcemy policzyć

$$\mathbb{P}(A_1 \cup A_2 \cup A_3 \cup A_4).$$

Dla jednego ustalonego koloru liczba rąk wynosi

$$\binom{13}{6} \binom{39}{7}.$$

Suma po kolorach daje

$$4 \binom{13}{6} \binom{39}{7}.$$

Teraz odejmujemy ręce policzone podwójnie, czyli takie, w których dwa ustalone kolory mają po 6 kart. Wybieramy parę kolorów:

$$\binom{4}{2}.$$

Z każdego z nich wybieramy po 6 kart:

$$\binom{13}{6}^2.$$

Ostatnią, trzynastą kartę wybieramy z pozostałych dwóch kolorów, czyli z 26 kart:

$$\binom{26}{1} = 26.$$

Trzy kolory nie mogą mieć po 6 kart, bo $18 > 13$. Zatem liczba dobrych rąk wynosi

$$4 \binom{13}{6} \binom{39}{7} - \binom{4}{2} \binom{13}{6}^2 \binom{26}{1}.$$

Ostatecznie

$$\mathbb{P} = \frac{4 \binom{13}{6} \binom{39}{7} - \binom{4}{2} \binom{13}{6}^2 \binom{26}{1}}{\binom{52}{13}}.$$

2.12 Zasada włączeń i wyłączeń

Twierdzenie 2.6: Zasada włączeń i wyłączeń. Dla zdarzeń $A_1, \dots, A_n$ zachodzi

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_i \mathbb{P}(A_i) - \sum_{i < j} \mathbb{P}(A_i \cap A_j) + \sum_{i < j < k} \mathbb{P}(A_i \cap A_j \cap A_k) - \dots.$$

Analogiczny wzór działa dla liczości zbiorów:

$$\left|\bigcup_{i=1}^n A_i\right| = \sum_i |A_i| - \sum_{i < j} |A_i \cap A_j| + \sum_{i < j < k} |A_i \cap A_j \cap A_k| - \dots.$$

Intuicja. Najpierw dodajemy wszystkie przypadki osobno. Wtedy przecięcia policzyliśmy za dużo razy, więc je odejmujemy. Ale przecięcia potrójne odjęliśmy za dużo, więc je znowu dodajemy. I tak dalej.

2.13 Problem kopert, czyli nieporządki

Zadanie z rozwiązaniem. Jest N listów i N zaadresowanych kopert z różnymi adresami. Każdy list odpowiada dokładnie jednej kopercie. Włożono listy do kopert na chybił trafił, po jednym liście do każdej koperty. Obliczyć prawdopodobieństwo, że żaden list nie trafił do właściwej koperty.

Rozwiązanie.

Wszystkich możliwych przyporządkowań listów do kopert jest

$$N!.$$

Niech A_i oznacza zdarzenie:

$$A_i = i\text{-ty list trafił do właściwej koperty.}$$

Szukamy prawdopodobieństwa zdarzenia

$$(A_1 \cup \dots \cup A_N)^c,$$

czyli sytuacji, w której żadne A_i nie zaszło.

Policzmy liczbę ustawień, w których żaden list nie jest na swoim miejscu. Z zasady włączeń i wyłączeń liczba takich permutacji wynosi

$$!N = N! \sum_{k=0}^N \frac{(-1)^k}{k!}.$$

Zatem szukane prawdopodobieństwo wynosi

$$\boxed{\frac{!N}{N!} = \sum_{k=0}^N \frac{(-1)^k}{k!}}.$$

Dla dużego N ta liczba jest bliska

$$\frac{1}{e}.$$

Ważne. Liczbę $!N$ czyta się czasem jako „subsilnia” albo liczbę nieporządków. Oznacza liczbę permutacji N elementów bez punktów stałych.

2.14 Wszystkie osoby muszą się pojawić: lekcje i uczniowie

Zadanie z rozwiązaniem. Klasa liczy 15 uczniów. Nauczyciel wybiera na każdej lekcji na chybił trafił jednego ucznia do odpowiedzi. Obliczyć prawdopodobieństwo tego, że w ciągu 16 lekcji każdy uczeń będzie przepytany.

Rozwiązanie.

Na każdej lekcji nauczyciel ma 15 możliwości wyboru. Lekcji jest 16, więc wszystkich możliwych ciągów wyborów jest

$$15^{16}.$$

Chcemy, aby każdy z 15 uczniów pojawił się co najmniej raz w ciągu 16 lekcji. Skoro mamy 16 wyborów i 15 uczniów, to dokładnie jeden uczeń musi zostać wybrany dwa razy, a każdy pozostały dokładnie raz.

Liczymy dobre ciągi:

1. wybieramy ucznia, który odpowiada dwa razy: 15 sposobów;
2. wybieramy dwie lekcje, na których on odpowiada: $\binom{16}{2}$ sposobów;
3. pozostałych 14 uczniów ustawiamy na pozostałych 14 lekcjach: $14!$ sposobów.

Zatem liczba dobrych ciągów wynosi

$$15 \binom{16}{2} 14!.$$

Szukane prawdopodobieństwo to

$$\mathbb{P} = \frac{15 \binom{16}{2} 14!}{15^{16}} = \frac{\binom{16}{2} 15!}{15^{16}}.$$

2.15 Zadania z samych własności prawdopodobieństwa

Nie każde zadanie w tym miejscu wymaga kombinatoryki. Czasami trzeba jedynie rozłożyć zdarzenia na kawałki i użyć wzorów z poprzedniego rozdziału.

Zadanie z rozwiązaniem. Załóżmy, że

$$\mathbb{P}(A \cup B) = \frac{1}{2}, \quad \mathbb{P}(A \cap B) = \frac{1}{4}, \quad \mathbb{P}(A \setminus B) = \mathbb{P}(B \setminus A).$$

Obliczyć $\mathbb{P}(A)$ oraz $\mathbb{P}(B \setminus A)$.

Rozwiązanie.

Rozbijamy sumę $A \cup B$ na trzy rozłączne kawałki:

$$A \cup B = (A \setminus B) \cup (B \setminus A) \cup (A \cap B).$$

Oznaczmy

$$x = \mathbb{P}(A \setminus B) = \mathbb{P}(B \setminus A).$$

Wtedy

$$\mathbb{P}(A \cup B) = x + x + \frac{1}{4} = 2x + \frac{1}{4}.$$

Z warunku

$$2x + \frac{1}{4} = \frac{1}{2},$$

więc

$$2x = \frac{1}{4}, \quad x = \frac{1}{8}.$$

Zatem

$$\mathbb{P}(B \setminus A) = \frac{1}{8}.$$

A ponieważ

$$A = (A \setminus B) \cup (A \cap B),$$

to

$$\mathbb{P}(A) = \frac{1}{8} + \frac{1}{4} = \frac{3}{8}.$$

Odpowiedź:

$$\mathbb{P}(A) = \frac{3}{8}, \quad \mathbb{P}(B \setminus A) = \frac{1}{8}.$$

Zadanie z rozwiązaniem. Załóżmy, że

$$\mathbb{P}(A) \geq \frac{2}{3}, \quad \mathbb{P}(B) \geq \frac{2}{3}, \quad \mathbb{P}(C) \geq \frac{2}{3}, \quad \mathbb{P}(A \cap B \cap C) = 0.$$

Obliczyć $\mathbb{P}(A)$.

Rozwiązanie.

Skoro

$$A \cap B \cap C = \emptyset,$$

to żaden punkt przestrzeni nie należy jednocześnie do wszystkich trzech zdarzeń. Równoważnie każdy wynik należy do co najmniej jednego z dopełnień:

$$\Omega = A^c \cup B^c \cup C^c.$$

Zatem

$$1 = \mathbb{P}(\Omega) = \mathbb{P}(A^c \cup B^c \cup C^c) \leq \mathbb{P}(A^c) + \mathbb{P}(B^c) + \mathbb{P}(C^c).$$

Ale z założeń

$$\mathbb{P}(A^c) \leq \frac{1}{3}, \quad \mathbb{P}(B^c) \leq \frac{1}{3}, \quad \mathbb{P}(C^c) \leq \frac{1}{3}.$$

Dostajemy łańcuch nierówności

$$1 \leq \mathbb{P}(A^c) + \mathbb{P}(B^c) + \mathbb{P}(C^c) \leq 1.$$

Wszystkie nierówności muszą być równościami. W szczególności

$$\mathbb{P}(A^c) = \frac{1}{3}.$$

Stąd

$$\boxed{\mathbb{P}(A) = \frac{2}{3}}.$$

2.16 Jak rozpoznawać typ zadania?

Ważne. Przed liczeniem zadaj sobie po kolei pytania:

1. Czy wszystkie wyniki są jednakowo prawdopodobne? Jeśli tak, prawdopodobnie użyjemy $|A|/|\Omega|$.
2. Czy kolejność ma znaczenie? Jeśli tak, myślimy o permutacjach albo wariacjach. Jeśli nie, myślimy o kombinacjach.
3. Czy obiekty się powtarzają? Jeśli tak, może trzeba użyć permutacji z powtórzeniami.
4. Czy pojawia się warunek „co najmniej jeden”? Jeśli tak, sprawdź dopełnienie.
5. Czy pojawia się słowo „istnieje”? Sprawdź, czy przypadki się nie nakładają.
6. Czy chodzi o równanie w liczbach nieujemnych? Prawdopodobnie gwiazdki i kreski.
7. Czy jest zakaz sąsiedztwa? Spróbuj przesunięcia $b_i = a_i - (i - 1)$.

2.17 Najczęstsze błędy

Uwaga. W Totolotku zestaw $\{1, 2, 3, 4, 5, 6\}$ jest tym samym wynikiem niezależnie od kolejności losowania. Dlatego używamy $\binom{49}{6}$, a nie $49 \cdot 48 \cdots 44$.

Uwaga. Jeżeli pytanie brzmi „istnieje kolor z dokładnie sześcioma kartami”, to dwa kolory mogą naraz mieć po sześć kart. Wtedy trzeba użyć włączeń i wyłączeń.

Uwaga. Zdarzenia typu „co najmniej jedna para” albo „co najmniej jeden sukces” często liczy się najłatwiej jako 1 minus „żadna para” albo 1 minus „żaden sukces”.

Uwaga. W równaniu $x_1 + \cdots + x_m = n$ warunek $x_i \geq 0$ daje inny wynik niż $x_i > 0$. Dla dodatnich najpierw odejmujemy po 1 od każdej zmiennej.

Podsumowanie.

1. Reguła dodawania: przypadki rozłączne dodajemy.
2. Reguła mnożenia: kolejne etapy mnożymy.
3. Liczba ustawień n różnych obiektów:

$$n!.$$

4. Permutacje z powtórzeniami:

$$\frac{n!}{n_1!n_2! \cdots n_r!}.$$

5. Kombinacje:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

6. Rozwiązania nieujemne równania $x_1 + \cdots + x_m = n$:

$$\binom{n+m-1}{m-1}.$$

7. Rozwiązania dodatnie równania $x_1 + \cdots + x_m = n$:

$$\binom{n-1}{m-1}.$$

8. Wybór k liczb z $\{1, \dots, n\}$ bez sąsiednich:

$$\binom{n-k+1}{k}.$$

9. Dopełnienie:

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c).$$

10. Włączenia i wyłączenia pomagają wtedy, gdy przypadki się nakładają.

3. Prawdopodobieństwo warunkowe i niezależność zdarzeń

3.1 Mapa tematu

W poprzednich rozdziałach nauczyliśmy się dwóch rzeczy: jak opisywać doświadczenie losowe oraz jak liczyć przypadki, gdy wyniki są równoprawdopodobne. Teraz pojawia się nowa idea: **dodatkowa informacja**. Czasem nie pytamy już po prostu o prawdopodobieństwo zdarzenia A , tylko o prawdopodobieństwo zdarzenia A , gdy wiemy, że zaszło inne zdarzenie B .

Ten rozdział jest bardzo ważny, bo właśnie tutaj zaczyna się prawdziwe myślenie probabilistyczne. Będziemy mówić o:

1. prawdopodobieństwie warunkowym $\mathbb{P}(A \mid B)$,
2. wzorze mnożenia prawdopodobieństw,
3. wzorze na prawdopodobieństwo całkowite,
4. wzorze Bayesa,
5. niezależności zdarzeń,
6. niezależności parami i niezależności łącznej,
7. schemacie Bernoulliego,
8. lematach Borela-Cantellego, czyli o tym, kiedy coś zdarza się nieskończenie wiele razy.

Intuicja. Prawdopodobieństwo warunkowe to matematyczna wersja zdania:

„liczę szansę zdarzenia, ale już po zawężeniu świata do sytuacji, w których wiem, że zaszło B .”

Czyli B staje się nowym światem, nową przestrzenią możliwych wyników.

3.2 Pierwszy przykład: urna i dodatkowa informacja

Przykład 3.1: Uрна z kulami numerowanymi. W urnie jest pięć białych kul ponumerowanych liczbami

1, 2, 3, 4, 5

oraz trzy czarne kule ponumerowane liczbami

1, 2, 3.

Losujemy jedną kulę.

- a) Jakie jest prawdopodobieństwo, że numer na kuli jest parzysty?
- b) Wiadomo, że wylosowana kula jest biała. Jakie jest prawdopodobieństwo, że numer na niej jest parzysty?

Cała przestrzeń wyników wygląda tak:

$$\Omega = \{(1, b), (2, b), (3, b), (4, b), (5, b), (1, c), (2, c), (3, c)\}.$$

Mamy osiem kul. Numery parzyste mają kule:

$$(2, b), \quad (4, b), \quad (2, c).$$

Zatem w podpunkcie a):

$$\mathbb{P}(\text{numer parzysty}) = \frac{3}{8}.$$

W podpunkcie b) wiemy, że kula jest biała. To oznacza, że nie patrzymy już na wszystkie osiem kul. Patrzymy tylko na kule białe:

$$(1, b), (2, b), (3, b), (4, b), (5, b).$$


Wśród nich parzyste numery mają dwie kule:

$$(2, b), (4, b).$$

Stąd

$$\mathbb{P}(\text{numer parzysty} \mid \text{kula biała}) = \frac{2}{5}.$$

Intuicja. Informacja „kula jest biała” działa jak filtr. Z całego świata Ω zostają tylko wyniki zgodne z tą informacją. Dopiero w tym mniejszym świecie liczymy, ile wyników sprzyja zdarzeniu, które nas interesuje.



Pomarańczowe ramki oznaczają zdarzenie A : numer parzysty. Zielone kule oznaczają zdarzenie B : kula biała. Po warunku B patrzymy tylko na pięć zielonych kul.

3.3 Definicja prawdopodobieństwa warunkowego

Niech A i B będą zdarzeniami. Chcemy policzyć prawdopodobieństwo A pod warunkiem, że zaszło B . Skoro wiemy, że zaszło B , to interesują nas tylko wyniki z B . Zdarzenie A zachodzi w tym zawężonym świecie dokładnie wtedy, gdy wynik należy do części wspólnej $A \cap B$.

Definicja 3.1: Prawdopodobieństwo warunkowe. Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną oraz niech $A, B \in \mathcal{F}$, gdzie

$$\mathbb{P}(B) > 0.$$

Prawdopodobieństwem warunkowym zdarzenia A pod warunkiem zdarzenia B nazywamy liczbę

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Warunek $\mathbb{P}(B) > 0$ jest konieczny, bo nie wolno dzielić przez zero. Intuicyjnie: nie możemy sensownie pytać „co się dzieje, jeśli zaszło B ”, gdy B jest zdarzeniem niemożliwym w sensie probabilistycznym.

Ważne. Wzór

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

czytamy tak:

spośród sytuacji, w których zaszło B , jaka część to sytuacje, w których jednocześnie zaszło A ?

Przykład 3.2: Rzut kostką. Rzucamy uczciwą kostką. Niech

$$A = \{\text{wypadła liczba parzysta}\} = \{2, 4, 6\},$$

$$B = \{\text{wypadła liczba większa niż } 3\} = \{4, 5, 6\}.$$

Policzmy $\mathbb{P}(A \mid B)$.

Mamy

$$A \cap B = \{4, 6\},$$

więc

$$\mathbb{P}(A \cap B) = \frac{2}{6}, \quad \mathbb{P}(B) = \frac{3}{6}.$$

Zatem

$$\mathbb{P}(A \mid B) = \frac{2/6}{3/6} = \frac{2}{3}.$$

Intuicyjnie: skoro wiemy, że wynik jest większy niż 3, to możliwe wyniki to tylko

$$4, 5, 6.$$

Spośród nich parzyste są 4 i 6, czyli dwa z trzech.

3.4 Prawdopodobieństwo warunkowe jako nowa miara

Ustalmy zdarzenie B takie, że $\mathbb{P}(B) > 0$. Wtedy funkcja

$$A \mapsto \mathbb{P}(A \mid B)$$

jest nowym prawdopodobieństwem. To znaczy, że spełnia aksjomaty Kołmogorowa, tylko patrzymy na świat „po informacji B ”.

Twierdzenie 3.1: Warunkowanie daje nowe prawdopodobieństwo. Jeżeli $\mathbb{P}(B) > 0$, to funkcja

$$\mathbb{P}_B(A) = \mathbb{P}(A \mid B)$$

jest prawdopodobieństwem na $(\Omega, \mathcal{F})$.

Dowód. Sprawdzamy najważniejsze własności.

Po pierwsze,

$$\mathbb{P}_B(\Omega) = \mathbb{P}(\Omega \mid B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1.$$

Po drugie, jeśli $A_1, A_2, \dots$ są parami rozłączne, to

$$\mathbb{P}_B\left(\bigcup_{n=1}^{\infty} A_n\right) = \frac{\mathbb{P}\left(\left(\bigcup_{n=1}^{\infty} A_n\right) \cap B\right)}{\mathbb{P}(B)}.$$

Ponieważ

$$\left(\bigcup_{n=1}^{\infty} A_n\right) \cap B = \bigcup_{n=1}^{\infty} (A_n \cap B),$$

a zbiory $A_n \cap B$ są parami rozłączne, dostajemy

$$\mathbb{P}_B\left(\bigcup_{n=1}^{\infty} A_n\right) = \frac{\sum_{n=1}^{\infty} \mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_{n=1}^{\infty} \mathbb{P}(A_n \mid B).$$

Czyli warunkowanie naprawdę tworzy nową miarę probabilistyczną. □

3.5 Wzór mnożenia prawdopodobieństw

Definicja prawdopodobieństwa warunkowego daje od razu wzór:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Po przemnożeniu przez $\mathbb{P}(B)$ otrzymujemy:

$$\boxed{\mathbb{P}(A \cap B) = \mathbb{P}(A | B)\mathbb{P}(B).}$$

To jest wzór, którego używamy w zadaniach wieloetapowych.

Twierdzenie 3.2: Wzór mnożenia dla dwóch zdarzeń. Jeśli $\mathbb{P}(B) > 0$, to

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B)\mathbb{P}(B).$$

Jeśli $\mathbb{P}(A) > 0$, to równoważnie

$$\mathbb{P}(A \cap B) = \mathbb{P}(B | A)\mathbb{P}(A).$$

Intuicja. Wzór mnożenia mówi:

żeby zaszło B i potem A, najpierw musi zajść B, a potem w świecie po B musi zajść A.

Dlatego mnożymy:

$$\mathbb{P}(B) \cdot \mathbb{P}(A | B).$$

3.5.1 Wzór mnożenia dla wielu zdarzeń

Dla zdarzeń $A_1, A_2, \dots, A_n$ mamy uogólnienie:

Twierdzenie 3.3: Wzór łańcuchowy. Jeżeli odpowiednie prawdopodobieństwa warunkowe są określone, to

$$\boxed{\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_1)\mathbb{P}(A_2 | A_1)\mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}).}$$

Ważne. Jeżeli doświadczenie dzieje się etapami, to zwykle liczymy:

$$\mathbb{P}(\text{cała ścieżka}) = \text{iloczyn prawdopodobieństw po gałęziach drzewa}.$$

3.6 Przykład: losowanie do pierwszej czarnej kuli

Przykład 3.3: Jedna czarna kula i wiele białych. W urnie jest $n - 1$ kul białych i jedna kula czarna. Losujemy po jednej kuli aż do momentu wylosowania czarnej.

Jakie jest prawdopodobieństwo, że wykonamy dokładnie k losowań?

Rozważymy dwa przypadki:

- a) losowanie bez zwracania,
- b) losowanie ze zwracaniem.

Wykonanie dokładnie k losowań oznacza:

$$\underbrace{\text{biała}, \dots, \text{biała}}_{k-1 \text{ razy}}, \text{czarna}.$$

3.6.1 Bez zwracania

Jeśli losujemy bez zwracania, to po każdym wylosowaniu białej kuli w urnie zostaje mniej kul. Prawdopodobieństwo ścieżki wynosi:

$$\frac{n-1}{n} \cdot \frac{n-2}{n-1} \cdot \frac{n-3}{n-2} \cdots \frac{n-k+1}{n-k+2} \cdot \frac{1}{n-k+1}.$$

Wszystko się skraca:

$$\mathbb{P}(\text{czarna w } k\text{-tym losowaniu}) = \frac{1}{n}.$$

Intuicja. Bez zwracania każda pozycja czarnej kuli w losowej kolejności wszystkich n kul jest tak samo prawdopodobna. Czarna kula może być pierwsza, druga, trzecia, ..., albo n -ta. Każda pozycja ma prawdopodobieństwo $1/n$.

3.6.2 Ze zwracaniem

Jeśli losujemy ze zwracaniem, to za każdym razem sytuacja jest taka sama. Prawdopodobieństwo białej kuli wynosi


$$\frac{n-1}{n},$$

a prawdopodobieństwo czarnej wynosi

$$\frac{1}{n}.$$

Zatem

$$\mathbb{P}(\text{czarna w } k\text{-tym losowaniu}) = \left(\frac{n-1}{n}\right)^{k-1} \cdot \frac{1}{n}.$$



3.7 Rozbicie przestrzeni i prawdopodobieństwo całkowite

W wielu zadaniach najłatwiej rozbić sytuację na przypadki. Na przykład:


- najpierw wybieramy urnę I albo urnę II,
- najpierw testowany człowiek jest chory albo zdrowy,
- najpierw wylosowano kartę czerwoną albo czarną,
- najpierw maszyna wyprodukowała część w fabryce A, B albo C.

Formalnie takie przypadki tworzą rozbicie przestrzeni.

Definicja 3.2: Rozbicie przestrzeni. Rodzina zdarzeń $B_1, B_2, \dots, B_n$ jest rozbiciem przestrzeni Ω , jeśli:

1. $B_i \cap B_j = \emptyset$ dla $i \neq j$,
2. $B_1 \cup B_2 \cup \dots \cup B_n = \Omega$.

Analogicznie definiuje się rozbicie przeliczalne.



Twierdzenie 3.4: Wzór na prawdopodobieństwo całkowite. Niech $B_1, B_2, \dots$ będzie rozbi-
ciem Ω oraz niech $\mathbb{P}(B_k) > 0$. Wtedy dla każdego zdarzenia A :

$$\mathbb{P}(A) = \sum_k \mathbb{P}(A \mid B_k) \mathbb{P}(B_k).$$

W przypadku skończonym:

$$\mathbb{P}(A) = \mathbb{P}(A \mid B_1) \mathbb{P}(B_1) + \dots + \mathbb{P}(A \mid B_n) \mathbb{P}(B_n).$$

Dowód. Zdarzenie A rozkłada się na rozłączne kawałki:

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots$$

Z addytywności prawdopodobieństwa:

$$\mathbb{P}(A) = \sum_k \mathbb{P}(A \cap B_k).$$

Ale ze wzoru mnożenia:

$$\mathbb{P}(A \cap B_k) = \mathbb{P}(A \mid B_k) \mathbb{P}(B_k).$$

Po podstawieniu dostajemy wzór. □

Intuicja. Wzór całkowity mówi: aby policzyć prawdopodobieństwo A , rozbijam świat na przypadki B_k , a potem sumuję:

szansa przypadku $\times$ szansa A w tym przypadku.

3.8 Wzór Bayesa

Wzór Bayesa jest jednym z najważniejszych wzorów w całym rachunku prawdopodobieństwa. Pozwala odwracać warunkowanie.

Często znamy prawdopodobieństwa typu:

$$\mathbb{P}(A \mid B_k),$$

czyli: jaka jest szansa zaobserwowania efektu A , jeśli prawdziwa była przyczyna B_k .

A chcemy policzyć:

$$\mathbb{P}(B_k \mid A),$$

czyli: skoro zobaczyliśmy efekt A , jaka jest szansa, że przyczyną było B_k ?

Twierdzenie 3.5: Wzór Bayesa. Niech $B_1, B_2, \dots, B_n$ będzie rozbiem Ω oraz niech $\mathbb{P}(B_k) > 0$. Jeśli $\mathbb{P}(A) > 0$, to

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k) \mathbb{P}(B_k)}{\sum_{j=1}^n \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}.$$

Ponieważ mianownik jest równy $\mathbb{P}(A)$, można też pisać:

$$\mathbb{P}(B_k | A) = \frac{\mathbb{P}(A | B_k)\mathbb{P}(B_k)}{\mathbb{P}(A)}.$$

Dowód. Z definicji prawdopodobieństwa warunkowego:

$$\mathbb{P}(B_k | A) = \frac{\mathbb{P}(B_k \cap A)}{\mathbb{P}(A)}.$$

Ze wzoru mnożenia:

$$\mathbb{P}(B_k \cap A) = \mathbb{P}(A | B_k)\mathbb{P}(B_k).$$

Ze wzoru całkowitego:

$$\mathbb{P}(A) = \sum_{j=1}^n \mathbb{P}(A | B_j)\mathbb{P}(B_j).$$

Podstawiamy i otrzymujemy tezę. □

Ważne. Bayes robi aktualizację przekonań:

$$\text{posterior} = \frac{\text{wiarygodność informacji} \cdot \text{prior}}{\text{łączna szansa informacji}}.$$

Innymi słowy: po zobaczeniu nowej informacji wzmacniamy te przyczyny, które dobrze tę informację tłumaczą, ale nadal pamiętamy, jak prawdopodobne były przed obserwacją.

3.9 Przykład Bayesa: dwie urny

Przykład 3.4: Dwie urny. Są dwie urny. W urnie I jest b_1 kul białych i c_1 czarnych. W urnie II jest b_2 kul białych i c_2 czarnych. Najpierw losujemy jedną z urn z prawdopodobieństwem $1/2$, a potem losujemy z niej jedną kulę.

a) Jakie jest prawdopodobieństwo, że kula jest biała?

b) Wiadomo, że kula jest biała. Jakie jest prawdopodobieństwo, że pochodziła z urny I?

Niech:

$$A = \{\text{wylosowano białą kulę}\},$$

$$B_1 = \{\text{wybrano urnę I}\}, \quad B_2 = \{\text{wybrano urnę II}\}.$$

Mamy

$$\mathbb{P}(B_1) = \mathbb{P}(B_2) = \frac{1}{2}.$$

Ponadto

$$\mathbb{P}(A | B_1) = \frac{b_1}{b_1 + c_1}, \quad \mathbb{P}(A | B_2) = \frac{b_2}{b_2 + c_2}.$$

Zatem z prawdopodobieństwa całkowitego:

$$\mathbb{P}(A) = \frac{1}{2} \cdot \frac{b_1}{b_1 + c_1} + \frac{1}{2} \cdot \frac{b_2}{b_2 + c_2}.$$

A z Bayesa:

$$\mathbb{P}(B_1 | A) = \frac{\mathbb{P}(A | B_1)\mathbb{P}(B_1)}{\mathbb{P}(A)}.$$

Po skróceniu czynnika $1/2$ dostajemy:

$$\mathbb{P}(B_1 | A) = \frac{\frac{b_1}{b_1+c_1}}{\frac{b_1}{b_1+c_1} + \frac{b_2}{b_2+c_2}}.$$

Intuicja. Jeśli biała kula jest dużo bardziej typowa dla urny I niż dla urny II, to po zobaczeniu białej kuli zwiększa się nasza wiara, że losowaliśmy z urny I.

3.10 Przykład Bayesa: test medyczny

Zadanie z rozwiązaniem. Pewna choroba występuje u 1% populacji. Test wykrywa chorobę u chorej osoby z prawdopodobieństwem 0,99, ale u zdrowej osoby daje wynik fałszywie dodatni z prawdopodobieństwem 0,05.

Osoba ma pozytywny wynik testu. Jakie jest prawdopodobieństwo, że naprawdę jest chora?

Rozwiązanie.

Niech

$$C = \{\text{osoba jest chora}\}, \quad T = \{\text{test dodatni}\}.$$

Mamy

$$\begin{aligned} \mathbb{P}(C) &= 0,01, & \mathbb{P}(C^c) &= 0,99, \\ \mathbb{P}(T | C) &= 0,99, & \mathbb{P}(T | C^c) &= 0,05. \end{aligned}$$

Szukamy $\mathbb{P}(C | T)$. Ze wzoru Bayesa:

$$\mathbb{P}(C | T) = \frac{\mathbb{P}(T | C)\mathbb{P}(C)}{\mathbb{P}(T | C)\mathbb{P}(C) + \mathbb{P}(T | C^c)\mathbb{P}(C^c)}.$$

Podstawiamy:

$$\mathbb{P}(C | T) = \frac{0,99 \cdot 0,01}{0,99 \cdot 0,01 + 0,05 \cdot 0,99}.$$

Czyli

$$\mathbb{P}(C | T) = \frac{0,0099}{0,0099 + 0,0495} = \frac{0,0099}{0,0594} = \frac{1}{6}.$$

Zatem prawdopodobieństwo choroby po pozytywnym teście wynosi około

$$\boxed{16,7\%}.$$

Komentarz. To może być zaskakujące. Test jest dobry, ale choroba jest rzadka, więc wśród pozytywnych wyników sporo pochodzi od osób zdrowych.

3.11 Niezależność zdarzeń

Teraz przechodzimy do drugiej głównej idei rozdziału.

Dwa zdarzenia są niezależne, jeśli informacja o jednym nie zmienia prawdopodobieństwa drugiego.

Czyli intuicyjnie:

$$\mathbb{P}(A | B) = \mathbb{P}(A).$$

Z definicji prawdopodobieństwa warunkowego:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Warunek $\mathbb{P}(A | B) = \mathbb{P}(A)$ daje więc:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

To przyjmujemy jako definicję, bo działa także wtedy, gdy nie chcemy dzielić przez $\mathbb{P}(B)$.

Definicja 3.3: Niezależność dwóch zdarzeń. Zdarzenia A i B nazywamy niezależnymi, jeśli

$$\boxed{\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)}.$$

Intuicja. Niezależność nie znaczy, że zdarzenia nie mogą zajść razem. Niezależność znaczy, że zajście jednego nie zmienia szansy drugiego.

Przykład 3.5: Dwa rzuty kostką. Rzucamy dwa razy kostką. Niech

$$A = \{\text{w pierwszym rzucie wypadła 6}\},$$

$$B = \{\text{w drugim rzucie wypadła liczba parzysta}\}.$$

Mamy

$$\mathbb{P}(A) = \frac{1}{6}, \quad \mathbb{P}(B) = \frac{1}{2}.$$

Ponieważ rzuty są niezależne,

$$\mathbb{P}(A \cap B) = \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{12}.$$

Można też sprawdzić klasycznie: wszystkich wyników jest 36, a sprzyjające to

$$(6, 2), (6, 4), (6, 6),$$

czyli 3 wyniki. Zatem

$$\mathbb{P}(A \cap B) = \frac{3}{36} = \frac{1}{12}.$$

3.12 Rozłączność to nie to samo co niezależność

To jest jedna z najczęstszych pułapek.

Uwaga. Zdarzenia rozłączne spełniają

$$A \cap B = \emptyset.$$

Zdarzenia niezależne spełniają

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

To są zupełnie inne pojęcia.

Jeśli A i B są rozłączne oraz mają dodatnie prawdopodobieństwa, to nie mogą być niezależne. Dlaczego?

Jeśli są rozłączne, to

$$\mathbb{P}(A \cap B) = 0.$$

Ale jeśli $\mathbb{P}(A) > 0$ i $\mathbb{P}(B) > 0$, to

$$\mathbb{P}(A)\mathbb{P}(B) > 0.$$

Więc nie może zachodzić

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Przykład 3.6: Kostka. Rzucamy kostką. Niech

$$A = \{1\}, \quad B = \{2\}.$$

Zdarzenia są rozłączne, bo nie może jednocześnie выпаść 1 i 2.

Mamy

$$\mathbb{P}(A \cap B) = 0,$$

ale

$$\mathbb{P}(A)\mathbb{P}(B) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}.$$

Zatem A i B nie są niezależne.

3.13 Niezależność dopełnień

Jeśli dwa zdarzenia są niezależne, to niezależne są też ich dopełnienia.

Twierdzenie 3.6: Niezależność przechodzi na dopełnienia. Jeśli A i B są niezależne, to niezależne są także pary:

$$A^c \text{ i } B, \quad A \text{ i } B^c, \quad A^c \text{ i } B^c.$$

Dowód. Pokażemy pierwszą parę. Mamy rozłączny rozkład

$$B = (A \cap B) \cup (A^c \cap B).$$

Stąd

$$\mathbb{P}(A^c \cap B) = \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Z niezależności A i B :

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Zatem

$$\mathbb{P}(A^c \cap B) = \mathbb{P}(B) - \mathbb{P}(A)\mathbb{P}(B) = (1 - \mathbb{P}(A))\mathbb{P}(B) = \mathbb{P}(A^c)\mathbb{P}(B).$$

Czyli A^c i B są niezależne. Pozostałe przypadki robi się analogicznie. $\square$

3.14 Niezależność wielu zdarzeń

Dla dwóch zdarzeń sprawa jest prosta. Dla wielu zdarzeń trzeba uważać.

Definicja 3.4: Niezależność łączna. Zdarzenia $A_1, A_2, \dots, A_n$ są niezależne, jeśli dla każdego wyboru indeksów

$$1 \leq i_1 < i_2 < \dots < i_k \leq n,$$

gdzie $k \geq 2$, zachodzi

$$\mathbb{P}(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1})\mathbb{P}(A_{i_2}) \dots \mathbb{P}(A_{i_k}).$$

Dla trzech zdarzeń A, B, C trzeba sprawdzić wszystkie warunki:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B),$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(A)\mathbb{P}(C),$$

$$\mathbb{P}(B \cap C) = \mathbb{P}(B)\mathbb{P}(C),$$

oraz

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

Definicja 3.5: Niezależność parami. Zdarzenia $A_1, A_2, \dots, A_n$ są niezależne parami, jeśli każde dwa różne zdarzenia z tej rodziny są niezależne.

Uwaga. Niezależność parami nie musi oznaczać niezależności łącznej. Dla trzech zdarzeń może się zdarzyć, że każde dwa są niezależne, ale cała trójka nie jest niezależna.

Przykład 3.7: Niezależne parami, ale nie łącznie. Rzucamy dwa razy uczciwą kostką. Niech:

$$A = \{\text{pierwszy wynik jest parzysty}\},$$

$$B = \{\text{drugi wynik jest parzysty}\},$$

$$C = \{\text{suma wyników jest parzysta}\}.$$

Mamy

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

Ponadto

$$\mathbb{P}(A \cap B) = \frac{1}{4}, \quad \mathbb{P}(A \cap C) = \frac{1}{4}, \quad \mathbb{P}(B \cap C) = \frac{1}{4}.$$

Czyli każde dwie pary są niezależne.

Ale jeśli zaszły A i B , to oba wyniki są parzyste, więc suma na pewno jest parzysta. Zatem

$$A \cap B \subseteq C,$$

a więc

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A \cap B) = \frac{1}{4}.$$

Natomiast

$$\mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}.$$

Ponieważ

$$\frac{1}{4} \neq \frac{1}{8},$$

zdarzenia A, B, C nie są niezależne łącznie.

3.15 Niezależne doświadczenia i przestrzeń produktowa

Jeśli wykonujemy kilka doświadczeń niezależnie, to całe doświadczenie opisujemy przez iloczyn przestrzeni wyników.

Na przykład dwa rzuty kostką:

$$\Omega = \{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}.$$

Wyniki mają postać par:

$$(i, j).$$

Jeśli kostka jest uczciwa i rzuty są niezależne, to

$$\mathbb{P}((i, j)) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}.$$

Ważne. Jeśli doświadczenia są niezależne, to prawdopodobieństwo konkretnej kombinacji wyników jest iloczynem prawdopodobieństw wyników w poszczególnych doświadczeniach.

3.16 Schemat Bernoulliego

Schemat Bernoulliego opisuje serię niezależnych prób, w których mamy tylko dwa wyniki:

- sukces, oznaczany zwykle przez 1,
- porażka, oznaczana zwykle przez 0.

Prawdopodobieństwo sukcesu w każdej próbie jest takie samo i wynosi p . Prawdopodobieństwo porażki wynosi $1 - p$.

Definicja 3.6: Próba Bernoulliego i schemat Bernoulliego. Próbą Bernoulliego nazywamy doświadczenie z dwoma wynikami: sukcesem i porażką. Jeśli wykonujemy N niezależnych prób Bernoulliego, każda z prawdopodobieństwem sukcesu p , to mówimy o schemacie Bernoulliego.

Jeśli w N próbach chcemy mieć dokładnie k sukcesów, to:

- wybieramy, w których k miejscach są sukcesy: $\binom{N}{k}$ możliwości,
- każda konkretna sekwencja z k sukcesami i $N - k$ porażkami ma prawdopodobieństwo

$$p^k(1 - p)^{N-k}.$$

Dostajemy wzór:

Twierdzenie 3.7: Liczba sukcesów w schemacie Bernoulliego. W schemacie Bernoulliego z N próbami i prawdopodobieństwem sukcesu p prawdopodobieństwo dokładnie k sukcesów wynosi

$$\binom{N}{k} p^k (1 - p)^{N-k}.$$

Przykład 3.8: Trzy rzuty monetą. Rzucamy trzy razy uczciwą monetą. Sukcesem jest orzeł. Mamy

$$N = 3, \quad p = \frac{1}{2}.$$

Prawdopodobieństwo dokładnie dwóch orłów wynosi

$$\binom{3}{2} \left(\frac{1}{2}\right)^2 \left(\frac{1}{2}\right)^1 = 3 \cdot \frac{1}{8} = \frac{3}{8}.$$

Możliwe sekwencje to:

$$OOR, \quad ORO, \quad ROO.$$

Każda ma prawdopodobieństwo $1/8$.

Zadanie z rozwiązaniem. Prawdopodobieństwo trafienia do celu w jednym strzale wynosi $0,2$. Strzelamy 5 razy niezależnie. Jakie jest prawdopodobieństwo, że trafimy co najmniej raz?

Rozwiązanie.

Najłatwiej policzyć dopełnienie. Zdarzenie przeciwne to: nie trafiliśmy ani razu.

Prawdopodobieństwo pudła w jednym strzale wynosi

$$1 - 0,2 = 0,8.$$

Ponieważ strzały są niezależne,

$$\mathbb{P}(\text{zero trafień}) = 0,8^5.$$

Zatem

$$\mathbb{P}(\text{co najmniej jedno trafienie}) = 1 - 0,8^5.$$

Czyli

$$\mathbb{P} = 1 - 0,32768 = 0,67232.$$

3.17 Zdarzenia zachodzące nieskończenie wiele razy

Ta część jest trochę bardziej teoretyczna, ale bardzo przydatna. Załóżmy, że mamy ciąg zdarzeń

$$A_1, A_2, A_3, \dots$$

Na przykład:

- A_n – w n -tym rzucie monetą wypadł orzeł,
- A_n – w n -tym dniu padał deszcz,
- A_n – w n -tej próbie wystąpił błąd.

Zdarzenie „zaszło nieskończenie wiele spośród zdarzeń A_n ” zapisujemy jako

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m.$$

Intuicja. Zapis

$$\bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m$$

znaczy: nieważne jak daleko pójdziemy w ciągu, zawsze jeszcze kiedyś pojawi się któreś A_m . Czyli zdarzenia A_n zachodzą nieskończenie wiele razy.

Twierdzenie 3.8: Lemat Borela-Cantellego. Niech $A_1, A_2, \dots$ będą zdarzeniami.

(i) Jeśli

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

to

$$\mathbb{P}(A_n \text{ zachodzi nieskończenie wiele razy}) = 0.$$

(ii) Jeśli zdarzenia $A_1, A_2, \dots$ są niezależne oraz

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty,$$

to

$$\mathbb{P}(A_n \text{ zachodzi nieskończenie wiele razy}) = 1.$$

Intuicja. Jeśli suma prawdopodobieństw jest skończona, to zdarzenia są łącznie „za rzadkie”, żeby występować nieskończenie często. Jeśli suma jest nieskończona i mamy niezależność, to zdarzenia mają na tyle dużo okazji, że wystąpią nieskończenie wiele razy z prawdopodobieństwem 1.

Przykład 3.9: Rzuty monetą. Rzucamy uczciwą monetą nieskończenie wiele razy. Niech

$$A_n = \{\text{w } n\text{-tym rzucie wypadł orzeł}\}.$$

Wtedy

$$\mathbb{P}(A_n) = \frac{1}{2}.$$

Zatem

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \frac{1}{2} = \infty.$$

Zdarzenia A_n są niezależne, więc z drugiej części lematu Borela-Cantellego:

$$\mathbb{P}(\text{orzeł wypadnie nieskończenie wiele razy}) = 1.$$

3.18 Jak rozwiązywać zadania z warunkowania?

Ważne. Jeśli znasz przestrzeń wyników i wszystkie wyniki są równoprawdopodobne:

1. wypisz albo opisz zdarzenia A i B ,
2. policz $|A \cap B|$,
3. policz $|B|$,
4. użyj

$$\mathbb{P}(A \mid B) = \frac{|A \cap B|}{|B|}.$$

Ważne. Jeśli zadanie jest wieloetapowe:

1. narysuj etapy jako drzewo,
2. wpisz prawdopodobieństwa na gałęziach,
3. prawdopodobieństwo ścieżki licz jako iloczyn po gałęziach,
4. jeśli zdarzenie ma kilka ścieżek, dodaj ich prawdopodobieństwa.

Ważne. Jeśli zadanie brzmi mniej więcej:

wiadomo, że zaszedł efekt; jaka była przyczyna?

to prawdopodobnie użyj Bayesa:

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k)\mathbb{P}(B_k)}{\sum_j \mathbb{P}(A \mid B_j)\mathbb{P}(B_j)}.$$

3.19 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Rzucamy kostką. Oblicz prawdopodobieństwo, że wypadła liczba parzysta, jeśli wiadomo, że wypadła liczba większa niż 2.

Rozwiązanie.

Niech

$$A = \{2, 4, 6\}, \quad B = \{3, 4, 5, 6\}.$$

Wtedy

$$A \cap B = \{4, 6\}.$$

Zatem

$$\mathbb{P}(A \mid B) = \frac{|A \cap B|}{|B|} = \frac{2}{4} = \frac{1}{2}.$$

Zadanie z rozwiązaniem. W fabryce są dwie maszyny. Maszyna I produkuje 60% części i ma wadliwość 2%. Maszyna II produkuje 40% części i ma wadliwość 5%. Losujemy jedną część. Jakie jest prawdopodobieństwo, że jest wadliwa?

Rozwiązanie.

Niech

$$W = \{\text{część wadliwa}\},$$

$$M_1 = \{\text{część z maszyny I}\}, \quad M_2 = \{\text{część z maszyny II}\}.$$

Mamy

$$\begin{aligned}\mathbb{P}(M_1) &= 0,6, & \mathbb{P}(M_2) &= 0,4, \\ \mathbb{P}(W \mid M_1) &= 0,02, & \mathbb{P}(W \mid M_2) &= 0,05.\end{aligned}$$

Ze wzoru całkowitego:

$$\mathbb{P}(W) = 0,02 \cdot 0,6 + 0,05 \cdot 0,4 = 0,012 + 0,020 = 0,032.$$

Zatem

$$\boxed{\mathbb{P}(W) = 3,2\%}.$$

Zadanie z rozwiązaniem. W sytuacji z poprzedniego zadania okazało się, że część jest wadliwa. Jakie jest prawdopodobieństwo, że pochodzi z maszyny II?

Rozwiązanie.

Szukamy

$$\mathbb{P}(M_2 \mid W).$$

Ze wzoru Bayesa:

$$\mathbb{P}(M_2 \mid W) = \frac{\mathbb{P}(W \mid M_2)\mathbb{P}(M_2)}{\mathbb{P}(W)}.$$

Z poprzedniego zadania $\mathbb{P}(W) = 0,032$. Zatem

$$\mathbb{P}(M_2 \mid W) = \frac{0,05 \cdot 0,4}{0,032} = \frac{0,020}{0,032} = 0,625.$$

Czyli

$$\boxed{\mathbb{P}(M_2 \mid W) = 62,5\%}.$$

Zadanie z rozwiązaniem. Rzucamy kostką. Niech

$$A = \{\text{wynik jest parzysty}\} = \{2, 4, 6\},$$

$$B = \{\text{wynik jest większy niż 3}\} = \{4, 5, 6\}.$$

Czy A i B są niezależne?

Rozwiązanie.

Liczymy:

$$\mathbb{P}(A) = \frac{3}{6} = \frac{1}{2}, \quad \mathbb{P}(B) = \frac{3}{6} = \frac{1}{2}.$$

Dalej

$$A \cap B = \{4, 6\},$$

więc

$$\mathbb{P}(A \cap B) = \frac{2}{6} = \frac{1}{3}.$$

Natomiast

$$\mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Ponieważ

$$\frac{1}{3} \neq \frac{1}{4},$$

zdarzenia nie są niezależne.

Zadanie z rozwiązaniem. Rzucamy 10 razy monetą, która daje orła z prawdopodobieństwem $p = 0,3$. Jakie jest prawdopodobieństwo dokładnie 4 orłów?

Rozwiązanie.

Mamy schemat Bernoulliego:

$$N = 10, \quad k = 4, \quad p = 0,3.$$

Zatem

$$\mathbb{P}(\text{dokładnie 4 orły}) = \binom{10}{4} (0,3)^4 (0,7)^6.$$

Czyli

$$\mathbb{P} = 210 \cdot (0,3)^4 (0,7)^6.$$

3.20 Najczęstsze błędy

Uwaga. To zwykle są różne liczby. Przykładowo:

$$\mathbb{P}(\text{test dodatni} \mid \text{chory})$$

to nie to samo co

$$\mathbb{P}(\text{chory} \mid \text{test dodatni}).$$

Właśnie do odwracania takich warunków służy wzór Bayesa.

Uwaga. W Bayesie mianownik to całkowite prawdopodobieństwo zaobserwowanego zdarzenia. Trzeba uwzględnić wszystkie możliwe przypadki, które mogły do niego doprowadzić.

Uwaga. Jeśli dwa zdarzenia dodatniego prawdopodobieństwa się wykluczają, to informacja o zajściu jednego całkowicie wyklucza drugie. To jest przeciwieństwo niezależności.

Uwaga. Dla trzech i więcej zdarzeń sprawdzenie każdej pary nie wystarcza. Trzeba też sprawdzić przecięcia trójek, czwórek itd.

Uwaga. Zdarzenia typu „co najmniej jeden sukces” najczęściej liczymy przez dopełnienie:

$$\mathbb{P}(\text{co najmniej jeden}) = 1 - \mathbb{P}(\text{zero}).$$

Podsumowanie.

1. Prawdopodobieństwo warunkowe:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

2. Wzór mnożenia:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B) \mathbb{P}(B).$$

3. Wzór łańcuchowy:

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \mathbb{P}(A_2 \mid A_1) \dots \mathbb{P}(A_n \mid A_1 \cap \dots \cap A_{n-1}).$$

4. Rozbicie przestrzeni: zdarzenia B_k są rozłączne i pokrywają całe Ω .

5. Prawdopodobieństwo całkowite:

$$\mathbb{P}(A) = \sum_k \mathbb{P}(A \mid B_k) \mathbb{P}(B_k).$$

6. Wzór Bayesa:

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k) \mathbb{P}(B_k)}{\sum_j \mathbb{P}(A \mid B_j) \mathbb{P}(B_j)}.$$

7. Niezależność dwóch zdarzeń:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

8. Rozłączne zdarzenia dodatniego prawdopodobieństwa zwykle nie są niezależne.

9. Niezależność parami nie oznacza automatycznie niezależności łącznej.

10. Schemat Bernoulliego:

$$\mathbb{P}(\text{dokładnie } k \text{ sukcesów}) = \binom{N}{k} p^k (1-p)^{N-k}.$$

11. Lemat Borela-Cantellego mówi, kiedy zdarzenia zachodzą nieskończenie wiele razy.

4. Zmienne losowe i ich rozkłady

4.1 Mapa tematu

Do tej pory mówiliśmy głównie o zdarzeniach: czy coś zaszło, czy nie zaszło. Teraz przechodzimy do jednego z najważniejszych pojęć w całym rachunku prawdopodobieństwa: do *zmiennej losowej*.

Intuicja. Zmienna losowa to sposób przerobienia wyniku doświadczenia losowego na liczbę.

Sam wynik doświadczenia może być czymś niewygodnym: ciągiem rzutów monetą, wylosowaną kartą, punktem w kole, układem wielu kul. Zmienna losowa wyciąga z tego wyniku jedną konkretną informację liczbową, np. liczbę orłów, sumę oczek, czas oczekiwania albo odległość punktu od środka.

W tym rozdziale nauczymy się odpowiadać na pytania:

- czym formalnie jest zmienna losowa;
- czym jest rozkład zmiennej losowej;
- jak czytać dystrybuantę;
- czym są atomy i skoki dystrybuanty;
- czym różni się zmienna dyskretna od ciągłej;
- jak wyglądają podstawowe rozkłady: dwumianowy, geometryczny, Poissona, jednostajny, wykładniczy i normalny;
- jak sprawdzać niezależność zmiennych losowych;
- skąd bierze się splot gęstości przy sumie niezależnych zmiennych.

4.2 Od zdarzeń do zmiennych losowych

4.2.1 Dlaczego samo zdarzenie czasem nie wystarcza?

Przy rzucie kostką zdarzenie typu

$$A = \{\text{wypadła liczba parzysta}\}$$

jest bardzo proste. Ale często interesuje nas nie tylko odpowiedź „tak/nie”, lecz konkretna liczba.

Na przykład przy trzech rzutach monetą możemy pytać:

- ile razy wypadł orzeł?
- ile razy z rzędu na początku wypadła reszka?
- czy liczba orłów jest większa niż liczba reszek?

Pierwsze dwa pytania naturalnie dają liczby. Takie liczbowe wielkości nazywamy zmiennymi losowymi.

Przykład 4.1: Trzy rzuty monetą. Rzucamy monetą trzy razy. Wtedy

$$\Omega = \{O, R\}^3.$$

Przykładowy wynik to

$$\omega = (O, R, O).$$


Definiujemy zmienną losową

$$X(\omega) = \text{liczba orłów w wyniku } \omega.$$

Wtedy

$$X(O, R, O) = 2, \quad X(R, R, R) = 0, \quad X(O, O, O) = 3.$$

Zmienna X nie jest nowym doświadczeniem. Ona tylko przypisuje każdemu wynikowi doświadczenia pewną liczbę.



Rysunek 4.1: Zmienna losowa zamienia wynik doświadczenia na liczbę.

4.2.2 Formalna definicja

Definicja 4.1: Zmienna losowa. Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną. Zmienną losową rzeczywistą nazywamy funkcję

$$X : \Omega \rightarrow \mathbb{R},$$

taką że dla każdego zbioru borelowskiego $B \subseteq \mathbb{R}$ zdarzenie

$$\{X \in B\} = \{\omega \in \Omega : X(\omega) \in B\}$$

należy do $\mathcal{F}$.

Jeżeli $X : \Omega \rightarrow \mathbb{R}^d$, to mówimy o d -wymiarowej zmiennej losowej albo o wektorze losowym.

Intuicja. Warunek mierzalności mówi po prostu: jeżeli pytamy, czy wartość X wpadła do jakiegoś sensownego zbioru liczb, to musi to być zdarzenie, któremu wolno przypisać prawdopodobieństwo. Czyli zdanie

$$\{X \leq 3\}$$

ma być normalnym zdarzeniem, tak samo jak

$$\{1 < X < 5\}, \quad \{X \in [0, 1]\}, \quad \{X \in B\}.$$

W większości zadań rachunkowych ten warunek działa w tle i nie trzeba się nim stresować. Warto jednak rozumieć, po co jest: żeby wszystkie pytania o X były mierzalne.

Ważne. Zapis

$$\{X \leq t\}$$

nie oznacza liczby. To jest zdarzenie:

$$\{\omega \in \Omega : X(\omega) \leq t\}.$$

Czyli pytamy: dla których wyników doświadczenia wartość zmiennej losowej jest nie większa niż t ?

4.3 Rozkład zmiennej losowej

4.3.1 Co to znaczy, że znamy rozkład?

W praktyce bardzo często nie interesuje nas już dokładnie przestrzeń Ω , tylko to, z jakimi prawdopodobieństwami zmienna losowa przyjmuje wartości.

Przykład 4.2: Dwie różne gry, ten sam rozkład. Gra A: rzucamy monetą, wypłata wynosi 1 zł za orła i 0 zł za reszkę.

Gra B: losujemy kulę z urny, w której połowa kul jest biała, połowa czarna. Wypłata wynosi 1 zł za białą kulę i 0 zł za czarną.

Sama przestrzeń wyników jest inna, ale zmienna wypłaty ma w obu przypadkach ten sam rozkład:

$$\mathbb{P}(X = 1) = \frac{1}{2}, \quad \mathbb{P}(X = 0) = \frac{1}{2}.$$

Z punktu widzenia obliczeń dotyczących samej wypłaty te dwie sytuacje są równoważne.


Definicja 4.2: Rozkład zmiennej losowej. Niech $X : \Omega \rightarrow \mathbb{R}^d$ będzie zmienną losową. Rozkładem zmiennej X nazywamy miarę probabilistyczną P_X na $\mathbb{R}^d$ daną wzorem

$$P_X(B) = \mathbb{P}(X \in B), \quad B \in \mathcal{B}(\mathbb{R}^d).$$

Intuicja. Rozkład zmiennej losowej to odpowiedź na pytanie:

z jakim prawdopodobieństwem X wpada do różnych zbiorów wartości?

Nie musimy już patrzeć na wszystkie wyniki $\omega \in \Omega$. Patrzymy tylko na wartości, które przyjmuje X .



Rysunek 4.2: Rozkład to przeniesienie prawdopodobieństwa z przestrzeni wyników na oś liczbową.

4.4 Dystrybuanta

4.4.1 Definicja i pierwsza intuicja

Definicja 4.3: Dystrybuanta. Dystrybuantą zmiennej losowej rzeczywistej X nazywamy funkcję

$$F_X : \mathbb{R} \rightarrow [0, 1]$$


daną wzorem

$$F_X(t) = \mathbb{P}(X \leq t).$$

Intuicja. Dystrybuanta odpowiada na pytanie:

ile prawdopodobieństwa leży na lewo od punktu t ?

Gdy przesuwamy t w prawo, zbieramy coraz więcej masy prawdopodobieństwa, więc dystrybuanta nie może maleć.



dystrybuanta zmiennej dyskretnej ma skoki

Rysunek 4.3: Każdy skok dystrybuanty oznacza atom, czyli dodatnie prawdopodobieństwo jednej konkretnej wartości.

Przykład 4.3: Dystrybuanta przy rzucie monetą. Rzucamy symetryczną monetą i definiujemy

$$X(O) = 1, \quad X(R) = -1.$$

Wtedy

$$F_X(t) = \mathbb{P}(X \leq t).$$

Mamy trzy przypadki:

$$F_X(t) = \begin{cases} 0, & t < -1, \\ \frac{1}{2}, & -1 \leq t < 1, \\ 1, & t \geq 1. \end{cases}$$

Dlaczego? Jeśli $t < -1$, to żadna wartość X nie jest mniejsza lub równa t . Jeśli $-1 \leq t < 1$, łapiemy tylko wartość -1 , która ma prawdopodobieństwo $1/2$. Jeśli $t \geq 1$, łapiemy już obie wartości.

4.4.2 Własności dystrybuanty

Twierdzenie 4.1: Podstawowe własności dystrybuanty. Niech X będzie rzeczywistą zmienną losową. Wtedy:

1. F_X jest niemalejąca;
2. $\lim_{t \rightarrow -\infty} F_X(t) = 0$;
3. $\lim_{t \rightarrow +\infty} F_X(t) = 1$;
4. F_X jest prawostronnie ciągła;
5. dla każdego t istnieje granica lewostronna

$$F_X(t-) = \lim_{s \uparrow t} F_X(s) = \mathbb{P}(X < t);$$

6. skok dystrybuanty w punkcie t jest równy prawdopodobieństwu wartości t :

$$\mathbb{P}(X = t) = F_X(t) - F_X(t-).$$

Intuicja. Dystrybuanta jest jak napelniający się zbiornik. Zaczyna od 0, bo daleko po lewej nie ma żadnego prawdopodobieństwa. Kończy na 1, bo po prawej stronie zebraliśmy już całe prawdopodobieństwo.

Jeżeli w jakimś punkcie jest pojedyncza dodatnia masa, dystrybuanta robi skok. Wysokość skoku to dokładnie prawdopodobieństwo tej wartości.

Ważne. Dla $a < b$ mamy:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a).$$

Jeżeli końce są domknięte albo otwarte inaczej, trzeba uważać na skoki:

$$\mathbb{P}(a \leq X \leq b) = F_X(b) - F_X(a-),$$

$$\mathbb{P}(a < X < b) = F_X(b-) - F_X(a).$$

Dla zmiennych ciągłych te subtelności znikają, bo pojedyncze punkty mają prawdopodobieństwo 0.

Przykład 4.4: Odczytywanie prawdopodobieństwa z dystrybuanty. Załóżmy, że zmienna X ma dystrybuantę

$$F_X(t) = \begin{cases} 0, & t < 0, \\ \frac{1}{4}, & 0 \leq t < 2, \\ \frac{3}{4}, & 2 \leq t < 5, \\ 1, & t \geq 5. \end{cases}$$

Wtedy:

$$\mathbb{P}(X = 0) = F_X(0) - F_X(0-) = \frac{1}{4} - 0 = \frac{1}{4},$$

$$\mathbb{P}(X = 2) = F_X(2) - F_X(2-) = \frac{3}{4} - \frac{1}{4} = \frac{1}{2},$$

$$\mathbb{P}(X = 5) = F_X(5) - F_X(5-) = 1 - \frac{3}{4} = \frac{1}{4}.$$

Czyli rozkład jest skupiony w punktach 0, 2, 5 z prawdopodobieństwami $1/4, 1/2, 1/4$.

4.5 Wektory losowe i rozkłady brzegowe

4.5.1 Wektor losowy

Definicja 4.4: Wektor losowy. Wektorem losowym nazywamy zmienną losową o wartościach w $\mathbb{R}^d$:

$$X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d.$$

Jej dystrybuanta jest funkcją

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

Przykład 4.5: Dwa rzuty kostką. Rzucamy dwa razy kostką. Niech

$$X = \text{wynik pierwszego rzutu}, \quad Y = \text{wynik drugiego rzutu}.$$

Wtedy (X, Y) jest dwuwymiarową zmienną losową. Jej wartości to pary

$$(i, j), \quad i, j \in \{1, 2, 3, 4, 5, 6\}.$$

Rozkład łączny mówi, jakie są prawdopodobieństwa wszystkich par. Rozkład brzegowy X mówi tylko, jak wygląda pierwszy rzut, a rozkład brzegowy Y tylko, jak wygląda drugi rzut.

4.5.2 Rozkłady brzegowe

Definicja 4.5: Rozkład brzegowy. Niech $X = (X_1, \dots, X_d)$ będzie wektorem losowym. Rozkładem brzegowym nazywamy rozkład wybranego podwektora, na przykład

$$X_i, \quad (X_i, X_j), \quad (X_{i_1}, \dots, X_{i_k}).$$

Uwaga. To, że znamy osobno rozkład X i osobno rozkład Y , nie mówi jeszcze, jak one są ze sobą powiązane.

Może być tak, że $Y = X$, wtedy zmienne są idealnie związane. Może być też tak, że X i Y są niezależne. W obu sytuacjach rozkłady brzegowe mogą być takie same, ale rozkład pary (X, Y) jest zupełnie inny.

Przykład 4.6: Te same brzegi, inna zależność. Niech X przyjmuje wartości 0 i 1 z prawdopodobieństwami $1/2, 1/2$.

Przypadek A: definiujemy $Y = X$. Wtedy

$$\mathbb{P}(X = 0, Y = 0) = \frac{1}{2}, \quad \mathbb{P}(X = 1, Y = 1) = \frac{1}{2}.$$

Przypadek B: losujemy X i Y niezależnie, oba z rozkładem 0/1 po połowie. Wtedy

$$\mathbb{P}(X = i, Y = j) = \frac{1}{4}, \quad i, j \in \{0, 1\}.$$

W obu przypadkach X i Y osobno mają ten sam rozkład, ale para (X, Y) ma inny rozkład.

4.6 Niezależność zmiennych losowych

4.6.1 Definicja

Definicja 4.6: Niezależność zmiennych losowych. Zmienne losowe $X_1, \dots, X_n$ są niezależne, jeśli dla dowolnych zbiorów borelowskich $B_1, \dots, B_n$ zachodzi

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i).$$

Intuicja. Zmienne są niezależne, jeśli informacja o jednej z nich nie zmienia rozkładu pozostałych. Czyli poznanie X nie pomaga przewidywać Y .

Dla rzutów kostką: wynik pierwszego rzutu nie mówi nic o wyniku drugiego rzutu. Ale jeśli $Y = X$, to poznanie X całkowicie mówi, czym jest Y .

Twierdzenie 4.2: Kryterium przez dystrybuanty. Zmienne losowe rzeczywiste $X_1, \dots, X_n$ są niezależne wtedy i tylko wtedy, gdy dla wszystkich $x_1, \dots, x_n \in \mathbb{R}$ zachodzi

$$F_{(X_1, \dots, X_n)}(x_1, \dots, x_n) = F_{X_1}(x_1) \cdots F_{X_n}(x_n).$$

Przykład 4.7: Niezależne rzuty monetą. Rzucamy monetą dwa razy. Niech

$$X = \mathbf{1}_{\{\text{w pierwszym rzucie orzeł}\}}, \quad Y = \mathbf{1}_{\{\text{w drugim rzucie orzeł}\}}.$$

Wtedy X i Y są niezależne. Na przykład

$$\mathbb{P}(X = 1, Y = 1) = \frac{1}{4}$$

oraz

$$\mathbb{P}(X = 1)\mathbb{P}(Y = 1) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Analogicznie sprawdza się pozostałe kombinacje wartości.

4.7 Zmienne dyskretne

4.7.1 Definicja i funkcja masy

Definicja 4.7: Rozkład dyskretny. Zmienna losowa X ma rozkład dyskretny, jeśli istnieje skończony lub przeliczalny zbiór $S \subseteq \mathbb{R}$ taki, że

$$\mathbb{P}(X \in S) = 1.$$

Dla $x \in S$ liczby

$$p_X(x) = \mathbb{P}(X = x)$$

nazywamy funkcją masy prawdopodobieństwa.

Ważne. Jeśli X jest dyskretna, to dla każdego zbioru $A \subseteq \mathbb{R}$ mamy

$$\mathbb{P}(X \in A) = \sum_{x \in A \cap S} \mathbb{P}(X = x).$$

Czyli sumujemy masy punktów należących do interesującego nas zbioru.

Przykład 4.8: Prosta zmienna dyskretna. Niech

$$\mathbb{P}(X = 1) = 0,2, \quad \mathbb{P}(X = 3) = 0,3, \quad \mathbb{P}(X = 10) = 0,5.$$

Wtedy

$$\mathbb{P}(X > 2) = \mathbb{P}(X = 3) + \mathbb{P}(X = 10) = 0,8.$$

Natomiast

$$\mathbb{P}(2 < X < 10) = \mathbb{P}(X = 3) = 0,3.$$

4.7.2 Najważniejsze rozkłady dyskretne

Definicja 4.8: Rozkład jednopunktowy. Mówimy, że X ma rozkład jednopunktowy skupiony w a , jeśli

$$\mathbb{P}(X = a) = 1.$$

Oznacza się to czasem przez δ_a .

Definicja 4.9: Rozkład Bernoulliego. Zmienna X ma rozkład Bernoulliego z parametrem $p \in (0, 1)$, jeśli

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Interpretacja: $X = 1$ oznacza sukces, a $X = 0$ porażkę.

Definicja 4.10: Rozkład dwumianowy. Zmienna X ma rozkład dwumianowy z parametrami n, p , co zapisujemy

$$X \sim \text{Bin}(n, p),$$

jeśli

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Interpretacja: X jest liczbą sukcesów w n niezależnych próbach Bernoulliego o prawdopodobieństwie sukcesu p .


Przykład 4.9: Rozkład dwumianowy. Rzucamy monetą 10 razy. Niech X oznacza liczbę orłów.

Dla symetrycznej monety

$$X \sim \text{Bin}\left(10, \frac{1}{2}\right).$$

Prawdopodobieństwo dokładnie 4 orłów wynosi

$$\mathbb{P}(X = 4) = \binom{10}{4} \left(\frac{1}{2}\right)^4 \left(\frac{1}{2}\right)^6 = \binom{10}{4} \left(\frac{1}{2}\right)^{10}.$$



Rysunek 4.4: Rozkład dwumianowy jest dyskretny: prawdopodobieństwo siedzi w pojedynczych punktach.

Definicja 4.11: Rozkład geometryczny. Zmienna X ma rozkład geometryczny z parametrem $p \in (0, 1)$ w wersji „liczba porażek przed pierwszym sukcesem”, jeśli

$$\mathbb{P}(X = k) = (1 - p)^k p, \quad k = 0, 1, 2, \dots$$

Ważne. Czasem rozkład geometryczny definiuje się jako czas oczekiwania na pierwszy sukces:

$$\mathbb{P}(Y = k) = (1 - p)^{k-1} p, \quad k = 1, 2, \dots$$

Wtedy

$$Y = X + 1.$$

Zawsze trzeba sprawdzić, którą konwencję przyjmuje prowadzący albo skrypt.

Definicja 4.12: Rozkład Poissona. Zmienna X ma rozkład Poissona z parametrem $\lambda > 0$, co zapisujemy

$$X \sim \text{Pois}(\lambda),$$

jeśli

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Intuicja. Rozkład Poissona opisuje liczbę rzadkich zdarzeń w ustalonym czasie albo obszarze: liczba telefonów w centrali, liczba literówek na stronie, liczba awarii w ciągu dnia. Parametr λ mówi, ile zdarzeń średnio oczekujemy.

Twierdzenie 4.3: Aproksymacja Poissona. Jeżeli n jest duże, p jest małe, a $np \approx \lambda$, to

$$\text{Bin}(n, p) \approx \text{Pois}(\lambda).$$

Dokładniej, dla ustalonego k :

$$\binom{n}{k} p^k (1 - p)^{n-k} \approx e^{-\lambda} \frac{\lambda^k}{k!}.$$

Przykład 4.10: Literówki w tekście. Załóżmy, że bardzo długi tekst ma 100000 znaków, a każdy znak jest błędny z prawdopodobieństwem 0,00002, niezależnie od pozostałych. Liczba błędów

ma dokładnie rozkład dwumianowy

$$X \sim \text{Bin}(100000, 0,00002).$$

Ponieważ

$$np = 100000 \cdot 0,00002 = 2,$$

możemy przybliżać

$$X \approx \text{Pois}(2).$$

Na przykład

$$\mathbb{P}(X = 0) \approx e^{-2}.$$

4.8 Zmienne ciągłe i gęstości

4.8.1 Gęstość jako „masa rozsmarowana”

Definicja 4.13: Rozkład ciągły i gęstość. Zmienna losowa X o wartościach w $\mathbb{R}^d$ ma rozkład ciągły z gęstością g , jeśli $g : \mathbb{R}^d \rightarrow [0, \infty)$ jest funkcją borelowską oraz dla każdego zbioru borelowskiego $B \subseteq \mathbb{R}^d$ zachodzi

$$\mathbb{P}(X \in B) = \int_B g(x) dx.$$

Intuicja. Dla zmiennej dyskretnej prawdopodobieństwo jest skupione w punktach. Dla zmiennej ciągłej prawdopodobieństwo jest rozsmarowane po osi albo po przestrzeni.

Dlatego dla zmiennej ciągłej zwykle

$$\mathbb{P}(X = a) = 0$$


dla każdego pojedynczego punktu a , mimo że wartości blisko a mogą być bardzo prawdopodobne.

Ważne. Funkcja g jest gęstością, jeśli:

1. $g(x) \geq 0$ dla każdego x ;
2. całka z g po całej przestrzeni wynosi 1:

$$\int_{\mathbb{R}^d} g(x) dx = 1.$$

Wtedy prawdopodobieństwo liczymy przez pole pod wykresem albo objętość pod powierzchnią.



Rysunek 4.5: Dla zmiennej ciągłej prawdopodobieństwo przedziału jest polem pod gęstością.

4.8.2 Dystrybuanta zmiennej ciągłej

Jeżeli X ma gęstość g , to

$$F_X(t) = \mathbb{P}(X \leq t) = \int_{-\infty}^t g(x) dx.$$

Jeżeli dodatkowo F_X jest różniczkowalna, to

$$F'_X(t) = g(t)$$

w punktach, w których pochodna istnieje.

Przykład 4.11: Gęstość z dystrybucyj. Załóżmy, że

$$F_X(t) = \begin{cases} 0, & t < 0, \\ t^2, & 0 \leq t < 1, \\ 1, & t \geq 1. \end{cases}$$

Wtedy, na przedziale $(0, 1)$,

$$g(t) = F'_X(t) = 2t.$$

Poza tym przedziałem gęstość wynosi 0. Czyli

$$g(t) = \begin{cases} 2t, & 0 < t < 1, \\ 0, & \text{poza tym.} \end{cases}$$

Sprawdzamy normalizację:

$$\int_0^1 2t dt = 1.$$

4.9 Najważniejsze rozkłady ciągłe

4.9.1 Rozkład jednostajny

Definicja 4.14: Rozkład jednostajny na przedziale. Zmienna X ma rozkład jednostajny na $[a, b]$, jeśli jej gęstość wynosi

$$g(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b], \\ 0, & x \notin [a, b]. \end{cases}$$

Piszemy wtedy

$$X \sim U([a, b]).$$

Intuicja. Rozkład jednostajny oznacza, że każdy fragment przedziału ma prawdopodobieństwo proporcjonalne do swojej długości. Nie każdy punkt ma „taką samą dodatnią szansę”, bo pojedynczy punkt ma prawdopodobieństwo 0. Równość dotyczy odcinków o tej samej długości.

Przykład 4.12: Losowanie z odcinka. Niech $X \sim U([2, 6])$. Obliczamy

$$\mathbb{P}(3 \leq X \leq 5) = \frac{|[3, 5]|}{|[2, 6]|} = \frac{2}{4} = \frac{1}{2}.$$

Tak samo dostalibyśmy z całki:

$$\mathbb{P}(3 \leq X \leq 5) = \int_3^5 \frac{1}{4} dx = \frac{1}{2}.$$

4.9.2 Rozkład wykładniczy

Definicja 4.15: Rozkład wykładniczy. Zmienna X ma rozkład wykładniczy z parametrem $\lambda > 0$, jeśli jej gęstość wynosi

$$g(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Piszemy wtedy

$$X \sim \text{Exp}(\lambda).$$

Jej dystrybuanta ma postać

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-\lambda x}, & x \geq 0. \end{cases}$$

Intuicja. Rozkład wykładniczy jest modelem czasu oczekiwania na zdarzenie, które nie ma pamięci. Jeśli czekasz już s minut i nic się nie stało, to dalszy czas oczekiwania wygląda tak samo, jakbyś zaczął czekać od nowa.

Twierdzenie 4.4: Brak pamięci. Jeżeli $X \sim \text{Exp}(\lambda)$, to dla $s, t \geq 0$ zachodzi

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

Przykład 4.13: Czas oczekiwania. Niech czas oczekiwania na autobus ma rozkład wykładniczy z parametrem $\lambda = \frac{1}{10}$. Wtedy

$$\mathbb{P}(X > 15) = e^{-15/10} = e^{-1,5}.$$

Jeśli czekamy już 20 minut, to prawdopodobieństwo, że będziemy czekać jeszcze ponad 15 minut, nadal wynosi

$$e^{-1,5}.$$

To jest właśnie własność braku pamięci.

4.9.3 Rozkład normalny

Definicja 4.16: Rozkład normalny jednowymiarowy. Zmienna X ma rozkład normalny z parametrami $m \in \mathbb{R}$ oraz $\sigma > 0$, co zapisujemy


$$X \sim N(m, \sigma^2),$$

jeśli jej gęstość wynosi

$$g(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Dla $m = 0$ i $\sigma = 1$ dostajemy standardowy rozkład normalny $N(0, 1)$.

Intuicja. Rozkład normalny to słynna krzywa dzwonowa. Parametr m przesuwą środek rozkładu, a σ decyduje o rozproszeniu. Małe σ daje wąski dzwon, duże σ daje szeroki dzwon.



rozkład normalny jest symetryczny wokół średniej

Rysunek 4.6: Schematyczny wykres gęstości normalnej.

Ważne. Jeśli

$$X \sim N(m_1, \sigma_1^2), \quad Y \sim N(m_2, \sigma_2^2)$$

i X, Y są niezależne, to

$$X + Y \sim N(m_1 + m_2, \sigma_1^2 + \sigma_2^2).$$

Dodają się średnie i wariancje, nie odchylenia standardowe.

4.10 Gęstości brzegowe i niezależność w przypadku ciągłym

4.10.1 Gęstości brzegowe

Jeżeli wektor (X, Y) ma gęstość łączną $g_{X,Y}(x, y)$, to gęstości brzegowe dostajemy przez odcałkowanie drugiej zmiennej:

$$g_X(x) = \int_{\mathbb{R}} g_{X,Y}(x, y) dy,$$

$$g_Y(y) = \int_{\mathbb{R}} g_{X,Y}(x, y) dx.$$

Intuicja. Gęstość łączna opisuje masę na płaszczyźnie. Gęstość brzegowa X powstaje, gdy „zgniatamy” całą masę pionowo na oś x . Dlatego całkujemy po y .

Przykład 4.14: Gęstość jednostajna na kwadracie. Niech (X, Y) ma rozkład jednostajny na kwadracie $[0, 1]^2$. Wtedy

$$g_{X,Y}(x, y) = \begin{cases} 1, & (x, y) \in [0, 1]^2, \\ 0, & \text{poza kwadratem.} \end{cases}$$

Gęstość brzegowa X wynosi, dla $x \in [0, 1]$,

$$g_X(x) = \int_0^1 1 dy = 1.$$

Poza $[0, 1]$ jest równa 0. Zatem $X \sim U([0, 1])$. Analogicznie $Y \sim U([0, 1])$.

4.10.2 Kryterium niezależności przez gęstości

Twierdzenie 4.5: Niezależność przez iloczyn gęstości. Jeżeli X i Y mają gęstości brzegowe g_X i g_Y , a para (X, Y) ma gęstość łączną $g_{X,Y}$, to X i Y są niezależne wtedy i tylko wtedy, gdy

$$g_{X,Y}(x, y) = g_X(x)g_Y(y)$$

dla prawie wszystkich (x, y) .

Przykład 4.15: Jednostajny kwadrat daje niezależność. Dla rozkładu jednostajnego na $[0, 1]^2$ mamy

$$g_{X,Y}(x, y) = 1_{[0,1]}(x)1_{[0,1]}(y).$$

Ale

$$g_X(x) = 1_{[0,1]}(x), \quad g_Y(y) = 1_{[0,1]}(y).$$

Zatem

$$g_{X,Y}(x, y) = g_X(x)g_Y(y),$$

więc X i Y są niezależne.

Uwaga. Jeśli (X, Y) jest jednostajny na trójkącie

$$0 \leq y \leq x \leq 1,$$

to wartości X i Y są związane warunkiem $Y \leq X$. Poznanie dużego Y wymusza duże X . Zmienne nie są niezależne.

4.11 Suma niezależnych zmiennych i splot

4.11.1 O co chodzi ze splotem?

Jeśli X i Y są niezależne i mają gęstości g_X oraz g_Y , to gęstość sumy $X + Y$ nie jest zwykłą sumą gęstości. Trzeba uwzględnić wszystkie sposoby otrzymania danej wartości.

Jeśli chcemy mieć

$$X + Y = z,$$

to można mieć

$$X = z - y, \quad Y = y.$$

Sumujemy więc po wszystkich możliwych y .

Twierdzenie 4.6: Splot gęstości. Niech X, Y będą niezależnymi zmiennymi losowymi rzeczywistymi o gęstościach g_X, g_Y . Wtedy $X + Y$ ma gęstość

$$(g_X * g_Y)(z) = \int_{\mathbb{R}} g_X(z - y)g_Y(y) dy.$$

Przykład 4.16: Suma dwóch jednostajnych. Niech X, Y będą niezależne i jednostajne na $[0, 1]$. Wtedy

$$g_X(x) = g_Y(x) = 1_{[0,1]}(x).$$

Gęstość sumy $S = X + Y$ wynosi

$$g_S(z) = \int_{\mathbb{R}} 1_{[0,1]}(z - y)1_{[0,1]}(y) dy.$$

Całkujemy długość przecięcia przedziałów


$$y \in [0, 1] \quad \text{oraz} \quad z - y \in [0, 1],$$

czyli

$$y \in [0, 1] \cap [z - 1, z].$$

Dostajemy

$$g_S(z) = \begin{cases} 0, & z < 0, \\ z, & 0 \leq z < 1, \\ 2 - z, & 1 \leq z < 2, \\ 0, & z \geq 2. \end{cases}$$



Rysunek 4.7: Suma dwóch niezależnych zmiennych jednostajnych na $[0, 1]$ ma gęstość trójkątną.

4.12 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Rzucamy kostką. Niech X oznacza liczbę oczek. Wyznacz dystrybuantę F_X .

Rozwiązanie. Mamy

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \quad \mathbb{P}(X = k) = \frac{1}{6}.$$

Dystrybuanta to

$$F_X(t) = \mathbb{P}(X \leq t).$$

Zatem

$$F_X(t) = \begin{cases} 0, & t < 1, \\ \frac{1}{6}, & 1 \leq t < 2, \\ \frac{2}{6}, & 2 \leq t < 3, \\ \frac{3}{6}, & 3 \leq t < 4, \\ \frac{4}{6}, & 4 \leq t < 5, \\ \frac{5}{6}, & 5 \leq t < 6, \\ 1, & t \geq 6. \end{cases}$$

Każdy skok ma wysokość $1/6$, bo każda liczba oczek ma prawdopodobieństwo $1/6$.

Zadanie z rozwiązaniem. Rzucamy monetą 5 razy. Niech X oznacza liczbę orłów. Oblicz $\mathbb{P}(X \geq 4)$.

Rozwiązanie. Mamy schemat Bernoulliego z parametrami

$$n = 5, \quad p = \frac{1}{2}.$$

Zatem

$$X \sim \text{Bin}\left(5, \frac{1}{2}\right).$$

Liczymy

$$\mathbb{P}(X \geq 4) = \mathbb{P}(X = 4) + \mathbb{P}(X = 5).$$

Stąd

$$\begin{aligned} \mathbb{P}(X = 4) &= \binom{5}{4} \left(\frac{1}{2}\right)^5 = \frac{5}{32}, \\ \mathbb{P}(X = 5) &= \binom{5}{5} \left(\frac{1}{2}\right)^5 = \frac{1}{32}. \end{aligned}$$

Ostatecznie

$$\mathbb{P}(X \geq 4) = \frac{6}{32} = \frac{3}{16}.$$

Zadanie z rozwiązaniem. Rzucamy monetą, dla której prawdopodobieństwo orła wynosi p . Niech X oznacza liczbę reszek przed pierwszym orłem. Oblicz $\mathbb{P}(X = 3)$ oraz $\mathbb{P}(X \leq 3)$.

Rozwiązanie. Zmienna X ma rozkład geometryczny w wersji liczby porażek przed pierwszym sukcesem:

$$\mathbb{P}(X = k) = (1 - p)^k p.$$

Zatem

$$\mathbb{P}(X = 3) = (1 - p)^3 p.$$

Dalej

$$\mathbb{P}(X \leq 3) = \sum_{k=0}^3 (1 - p)^k p.$$

To jest suma geometryczna:

$$\mathbb{P}(X \leq 3) = p \frac{1 - (1 - p)^4}{1 - (1 - p)} = 1 - (1 - p)^4.$$

Można też zauważyć prościej: $X \leq 3$ oznacza, że pierwszy orzeł pojawił się wśród pierwszych czterech rzutów. Dopełnienie to cztery reszki z rzędu, o prawdopodobieństwie $(1 - p)^4$.

Zadanie z rozwiązaniem. Niech zmienna X ma gęstość

$$g(x) = \begin{cases} 2x, & 0 \leq x \leq 1, \\ 0, & \text{poza tym.} \end{cases}$$

Oblicz $\mathbb{P}(X \leq 1/2)$.

Rozwiązanie. Liczymy całkę:

$$\mathbb{P}(X \leq 1/2) = \int_0^{1/2} 2x \, dx.$$

Stąd

$$\int_0^{1/2} 2x \, dx = [x^2]_0^{1/2} = \frac{1}{4}.$$

Zatem

$$\mathbb{P}(X \leq 1/2) = \frac{1}{4}.$$

Zadanie z rozwiązaniem. Niech (X, Y) ma gęstość

$$g(x, y) = \begin{cases} 2, & 0 < y < x < 1, \\ 0, & \text{poza tym.} \end{cases}$$

Wyznacz gęstość brzegową X .

Rozwiązanie. Dla ustalonego x warunek $0 < y < x < 1$ oznacza, że $0 < x < 1$ oraz $0 < y < x$. Dlatego

$$g_X(x) = \int_{\mathbb{R}} g(x, y) \, dy.$$

Jeśli $0 < x < 1$, to

$$g_X(x) = \int_0^x 2 \, dy = 2x.$$

Jeśli $x \notin (0, 1)$, to gęstość jest równa 0. Zatem

$$g_X(x) = \begin{cases} 2x, & 0 < x < 1, \\ 0, & \text{poza tym.} \end{cases}$$

Zadanie z rozwiązaniem. Dla gęstości z poprzedniego zadania sprawdź, czy X i Y są niezależne.

Rozwiązanie. Już intuicyjnie widać problem: skoro $0 < Y < X < 1$, to informacja o Y ogranicza możliwe wartości X . To sugeruje brak niezależności.

Policzmy formalnie. Z poprzedniego zadania

$$g_X(x) = 2x, \quad 0 < x < 1.$$

Analogicznie

$$g_Y(y) = \int_y^1 2 \, dx = 2(1 - y), \quad 0 < y < 1.$$

Gdyby X i Y były niezależne, mielibyśmy

$$g(x, y) = g_X(x)g_Y(y) = 4x(1 - y)$$

na odpowiednim obszarze. Ale faktycznie

$$g(x, y) = 2$$

na trójkącie $0 < y < x < 1$. To nie jest to samo. Zatem X i Y nie są niezależne.

4.13 Najczęstsze błędy

Uwaga. Zmienna losowa X jest funkcją. Zdarzeniem jest na przykład

$$\{X \leq 3\}, \quad \{X = 0\}, \quad \{X \in B\}.$$

Nie piszemy sensownie $\mathbb{P}(X)$, tylko $\mathbb{P}(X \in B)$ albo $\mathbb{P}(X \leq t)$.

Uwaga. Dla zmiennej ciągłej $g(a)$ nie jest prawdopodobieństwem punktu a . Zwykle

$$\mathbb{P}(X = a) = 0.$$

Prawdopodobieństwa liczymy z całek:

$$\mathbb{P}(a < X < b) = \int_a^b g(x) \, dx.$$

Uwaga. Dla zmiennej dyskretnej ma znaczenie, czy przedział jest otwarty czy domknięty, bo punkty mogą mieć dodatnią masę. Dlatego

$$\mathbb{P}(a \leq X \leq b) = F(b) - F(a-),$$

a nie zawsze $F(b) - F(a)$.

Uwaga. Znajomość rozkładu X i rozkładu Y osobno nie wyznacza rozkładu pary (X, Y) . Do tego trzeba znać zależność między nimi albo mieć założenie niezależności.

Uwaga. Gęstość $X + Y$ dla niezależnych zmiennych to splot:

$$g_{X+Y}(z) = \int_{\mathbb{R}} g_X(z - y)g_Y(y) dy,$$

a nie zwykła suma $g_X(z) + g_Y(z)$.

Podsumowanie.

1. Zmienna losowa to mierzalna funkcja

$$X : \Omega \rightarrow \mathbb{R}^d.$$

2. Zapis $\{X \in B\}$ oznacza zdarzenie

$$\{\omega : X(\omega) \in B\}.$$

3. Rozkład zmiennej losowej:

$$P_X(B) = \mathbb{P}(X \in B).$$

4. Dystrybuanta zmiennej rzeczywistej:

$$F_X(t) = \mathbb{P}(X \leq t).$$

5. Skok dystrybuanty:

$$\mathbb{P}(X = t) = F_X(t) - F_X(t-).$$

6. Dla zmiennej dyskretnej:

$$\mathbb{P}(X \in A) = \sum_{x \in A} \mathbb{P}(X = x).$$

7. Rozkład dwumianowy:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

8. Rozkład geometryczny:

$$\mathbb{P}(X = k) = (1 - p)^k p, \quad k = 0, 1, 2, \dots$$

9. Rozkład Poissona:

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}.$$

10. Dla zmiennej ciągłej z gęstością g :

$$\mathbb{P}(X \in B) = \int_B g(x) dx.$$

11. Rozkład jednostajny na $[a, b]$ ma gęstość $1/(b - a)$.

12. Rozkład wykładniczy ma gęstość $\lambda e^{-\lambda x}$ dla $x \geq 0$.

13. Rozkład normalny ma gęstość dzwonową

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2/(2\sigma^2)}.$$

14. Niezależność przez gęstości:

$$g_{X,Y}(x, y) = g_X(x)g_Y(y).$$

15. Gęstość sumy niezależnych zmiennych to splot:

$$g_{X+Y}(z) = \int_{\mathbb{R}} g_X(z - y)g_Y(y) dy.$$

5. Wartość oczekiwana, wariancja i parametry rozkładu

5.1 Mapa tematu

W poprzednim rozdziale nauczyliśmy się opisywać cały rozkład zmiennej losowej: przez funkcję masy, gęstość albo dystrybuantę. To jest bardzo pełna informacja, ale czasem zbyt ciężka. W praktyce często chcemy odpowiedzieć na prostsze pytania:

- jaka jest przeciętna wartość zmiennej losowej?
- jak bardzo wyniki rozrzucają się wokół średniej?
- czy dwie zmienne rosną razem, czy raczej jedna rośnie, gdy druga maleje?
- jak dobrze jedną zmienną można przewidzieć liniowo z drugiej?

Na te pytania odpowiadają parametry rozkładu: wartość oczekiwana, wariancja, odchylenie standardowe, kowariancja, korelacja i macierz kowariancji.

Intuicja. Rozkład zmiennej losowej jest jak pełna mapa miasta. Wartość oczekiwana, wariancja i korelacja są jak kilka najważniejszych informacji z tej mapy: gdzie jest centrum, jak duży jest rozrzut i w którą stronę rzeczy się razem poruszają.

5.2 Wartość oczekiwana: średnia ważona

Najpierw myślimy o zmiennej dyskretnej. Załóżmy, że zmienna losowa X przyjmuje wartości

$$x_1, x_2, \dots, x_k$$

z prawdopodobieństwami

$$p_1, p_2, \dots, p_k.$$

Wtedy wartość oczekiwana to

$$\mathbb{E}X = x_1p_1 + x_2p_2 + \dots + x_kp_k.$$

Intuicja. Wartość oczekiwana to średnia, ale nie zwykła średnia arytmetyczna wartości. To średnia ważona prawdopodobieństwami. Wartości bardziej prawdopodobne mają większy wpływ na wynik.

Przykład 5.1: Rzut kostką. Niech X oznacza liczbę oczek wyrzuconą na uczciwej kostce. Wtedy

$$\mathbb{P}(X = 1) = \mathbb{P}(X = 2) = \dots = \mathbb{P}(X = 6) = \frac{1}{6}.$$

Zatem


$$\mathbb{E}X = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6}.$$

Czyli

$$\mathbb{E}X = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = \frac{21}{6} = 3,5.$$

Uwaga: wynik 3,5 nigdy nie wypada na kostce. Wartość oczekiwana nie musi być możliwą wartością zmiennej losowej.

Uwaga. Jeśli X oznacza wynik rzutu kostką, to $\mathbb{E}X = 3,5$, chociaż kostka nigdy nie pokaże 3,5. Wartość oczekiwana oznacza środek ciężkości rozkładu, a nie koniecznie najbardziej prawdopodobny wynik.



5.3 Formalna definicja wartości oczekiwanej

Definicja 5.1: Wartość oczekiwana. Niech X będzie rzeczywistą zmienną losową na przestrzeni probabilistycznej $(\Omega, \mathcal{F}, \mathbb{P})$. Jeżeli istnieje całka

$$\int_{\Omega} X(\omega) d\mathbb{P}(\omega),$$

to nazywamy ją wartością oczekiwaną zmiennej X i oznaczamy

$$\mathbb{E}X.$$

Jeżeli $\mathbb{E}|X| < \infty$, to mówimy, że X jest całkowalna i zapisujemy

$$X \in L^1.$$

W praktyce najczęściej używamy prostszych wzorów zależnych od typu rozkładu.

Ważne. Wartość oczekiwana zależy tylko od rozkładu zmiennej losowej. To znaczy: jeżeli dwie zmienne losowe mają ten sam rozkład, to mają tę samą wartość oczekiwaną, o ile ta wartość istnieje.

5.4 Wartość oczekiwana dla zmiennej dyskretnej

Twierdzenie 5.1: Wzór dyskretny. Jeżeli zmienna losowa X ma rozkład dyskretny i zbiór wartości S_X , to

$$\mathbb{E}X = \sum_{x \in S_X} x\mathbb{P}(X = x),$$

o ile szereg jest zbieżny bezwzględnie, czyli

$$\sum_{x \in S_X} |x|\mathbb{P}(X = x) < \infty.$$

Dla funkcji f mamy ogólniej

$$\mathbb{E}f(X) = \sum_{x \in S_X} f(x)\mathbb{P}(X = x),$$

o ile prawa strona ma sens.

Przykład 5.2: Rozkład dwupunktowy. Niech

$$\mathbb{P}(X = a) = p, \quad \mathbb{P}(X = b) = 1 - p.$$

Wtedy

$$\mathbb{E}X = ap + b(1 - p).$$

Jeżeli $a = 1$, $b = 0$, to dostajemy zmienną Bernoulliego i

$$\mathbb{E}X = p.$$

Przykład 5.3: Liczba sukcesów w schemacie Bernoulliego. Niech $X \sim B(n, p)$, czyli X oznacza liczbę sukcesów w n niezależnych próbach, każda z prawdopodobieństwem sukcesu p . Najłatwiej zapisać

$$X = X_1 + X_2 + \cdots + X_n,$$

gdzie

$$X_i = \begin{cases} 1, & \text{jeśli w } i\text{-tej próbie był sukces,} \\ 0, & \text{jeśli w } i\text{-tej próbie była porażka.} \end{cases}$$

Wtedy $\mathbb{E}X_i = p$, więc z liniowości

$$\mathbb{E}X = \mathbb{E}X_1 + \cdots + \mathbb{E}X_n = np.$$

Intuicja. Wzór $\mathbb{E}X = np$ mówi coś bardzo naturalnego. Jeśli robimy n prób, a w każdej sukces ma szansę p , to przeciętnie spodziewamy się około np sukcesów. Na przykład w 100 rzutach symetryczną monetą spodziewamy się około $100 \cdot \frac{1}{2} = 50$ orłów.

5.5 Wartość oczekiwana dla zmiennej ciągłej

Twierdzenie 5.2: Wzór dla gęstości. Jeżeli zmienna losowa X ma gęstość g , to

$$\mathbb{E}X = \int_{\mathbb{R}} xg(x) dx,$$

o ile całka istnieje. Ogólniej, dla funkcji borelowskiej f :

$$\mathbb{E}f(X) = \int_{\mathbb{R}} f(x)g(x) dx.$$

Przykład 5.4: Rozkład jednostajny na odcinku. Niech $X \sim U([a, b])$. Gęstość wynosi

$$g(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x).$$

Zatem

$$\mathbb{E}X = \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \cdot \frac{b^2 - a^2}{2} = \frac{a+b}{2}.$$

Czyli średnia rozkładu jednostajnego na odcinku to środek odcinka.

Przykład 5.5: Rozkład wykładniczy. Niech $X \sim \text{Exp}(\lambda)$, czyli

$$g(x) = \lambda e^{-\lambda x} \mathbf{1}_{[0,\infty)}(x).$$

Wtedy

$$\mathbb{E}X = \int_0^\infty x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

Interpretacja: jeśli X opisuje czas oczekiwania, to średni czas oczekiwania wynosi $1/\lambda$.

Przykład 5.6: Rozkład normalny. Jeżeli $X \sim N(m, \sigma^2)$, to

$$\mathbb{E}X = m.$$

Parametr m w oznaczeniu rozkładu normalnego naprawdę jest średnią rozkładu.

5.6 Kiedy wartość oczekiwana nie istnieje?

Nie każda zmienna losowa ma wartość oczekiwaną. To jest bardzo ważne, bo czasem intuicja podpowiada: „przecież jakaś średnia powinna być”. Nie zawsze.

Przykład 5.7: Rozkład Cauchy’ego. Niech X ma rozkład Cauchy’ego o gęstości

$$g(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}.$$

Wtedy

$$\mathbb{E}|X| = \int_{\mathbb{R}} |x| \frac{1}{\pi(1+x^2)} dx = \infty.$$

To oznacza, że X nie jest całkowalna i wartość oczekiwana $\mathbb{E}X$ nie istnieje w sensie używanym w tym kursie.

Uwaga. Rozkład Cauchy’ego jest symetryczny względem zera, więc można mieć pokusę napisania $\mathbb{E}X = 0$. To jest błąd. Aby mówić o wartości oczekiwanej, musimy mieć całkowalność części dodatniej i ujemnej w sensowny sposób. W rozkładzie Cauchy’ego ogony są zbyt ciężkie.

5.7 Liniowość wartości oczekiwanej

Twierdzenie 5.3: Liniowość wartości oczekiwanej. Jeżeli $X_1, \dots, X_n$ są całkowalne, a $a_1, \dots, a_n \in \mathbb{R}$, to

$$\mathbb{E}(a_1X_1 + \dots + a_nX_n) = a_1\mathbb{E}X_1 + \dots + a_n\mathbb{E}X_n.$$

Ważne. Liniowość wartości oczekiwanej nie wymaga niezależności. To jest jedna z najczęściej używanych własności w zadaniach.

Przykład 5.8: Suma oczek w kilku rzutach. Rzucamy kostką 10 razy. Niech S oznacza sumę wyrzuconych oczek. Zapisujemy

$$S = X_1 + X_2 + \dots + X_{10},$$

gdzie X_i jest wynikiem i -tego rzutu. Wiemy, że

$$\mathbb{E}X_i = 3,5.$$

Zatem

$$\mathbb{E}S = \mathbb{E}X_1 + \dots + \mathbb{E}X_{10} = 10 \cdot 3,5 = 35.$$

5.8 Momenty i przestrzenie L^p

Definicja 5.2: Moment rzędu p . Dla $p > 0$ liczbę

$$\mathbb{E}|X|^p$$

nazywamy p -tym momentem zmiennej losowej X , o ile ta wartość istnieje.

Jeżeli

$$\mathbb{E}|X|^p < \infty,$$

to mówimy, że X należy do L^p i piszemy

$$X \in L^p.$$

Najczęściej spotykamy:

- L^1 – zmienne całkowalne, czyli mające skończoną wartość oczekiwaną z modułu;
- L^2 – zmienne całkowalne z kwadratem, potrzebne do wariancji i kowariancji;
- L^∞ – zmienne ograniczone prawie na pewno.

Ważne. Jeżeli $X \in L^2$, to automatycznie $X \in L^1$. W zadaniach oznacza to, że jeśli zmienna ma skończony drugi moment, to ma też sensowną wartość oczekiwaną.

5.9 Nierówność Czebyszewa i Markowa

Twierdzenie 5.4: Nierówność Markowa/Czebyszewa w wersji ogólnej. Niech X będzie zmienną losową, a $f : [0, \infty) \rightarrow [0, \infty)$ funkcją niemalejącą taką, że $f(\lambda) > 0$ dla $\lambda > 0$. Wtedy

$$\mathbb{P}(|X| \geq \lambda) \leq \frac{\mathbb{E}f(|X|)}{f(\lambda)}.$$

W szczególności, dla $p > 0$:

$$\mathbb{P}(|X| \geq \lambda) \leq \frac{\mathbb{E}|X|^p}{\lambda^p}.$$

Intuicja. Jeżeli zmienna ma mały moment, to nie może zbyt często przyjmować ogromnych wartości. Nierówność Markowa/Czebyszewa zamienia informację o średniej albo wariancji na oszacowanie prawdopodobieństwa dużego odchylenia.

Przykład 5.9: Proste oszacowanie ogona. Załóżmy, że $X \geq 0$ oraz $\mathbb{E}X = 10$. Co możemy powiedzieć o prawdopodobieństwie, że $X \geq 50$?

Z nierówności Markowa:

$$\mathbb{P}(X \geq 50) \leq \frac{\mathbb{E}X}{50} = \frac{10}{50} = \frac{1}{5}.$$

Nie wiemy dokładnie, ile wynosi to prawdopodobieństwo, ale wiemy, że nie przekracza 0,2.

5.10 Wariancja i odchylenie standardowe


Definicja 5.3: Wariancja. Jeżeli $X \in L^2$, to wariancją zmiennej losowej X nazywamy liczbę

$$\text{Var } X = \mathbb{E}(X - \mathbb{E}X)^2.$$

Odchyleniem standardowym nazywamy

$$\sigma_X = \sqrt{\text{Var } X}.$$

Intuicja. Wartość oczekiwana mówi, gdzie jest środek rozkładu. Wariancja mówi, jak szeroko wyniki rozrzucają się wokół tego środka. Mała wariancja oznacza skupienie blisko średniej. Duża wariancja oznacza duży rozrzut.



Twierdzenie 5.5: Podstawowe własności wariancji. Jeżeli $X \in L^2$, to:

1.

$$\text{Var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2.$$

2.

$$\text{Var } X \geq 0.$$

3. $\text{Var } X = 0$ wtedy i tylko wtedy, gdy X jest stała prawie na pewno.4. Dla $a, b \in \mathbb{R}$:

$$\text{Var}(aX + b) = a^2 \text{Var } X.$$

Przykład 5.10: Wariancja rozkładu Bernoulliego. Niech $X \sim \text{Bernoulli}(p)$, czyli

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

Wiemy, że

$$\mathbb{E}X = p.$$

Ponieważ X przyjmuje tylko wartości 0 i 1, mamy $X^2 = X$. Zatem

$$\mathbb{E}X^2 = \mathbb{E}X = p.$$

Stąd

$$\text{Var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = p - p^2 = p(1 - p).$$

Przykład 5.11: Wariancja rozkładu dwumianowego. Jeżeli $X \sim B(n, p)$, to

$$X = X_1 + \cdots + X_n,$$

gdzie X_i są niezależne i mają rozkład Bernoulliego z parametrem p . Dla każdej z nich

$$\text{Var } X_i = p(1 - p).$$

Ponieważ zmienne są niezależne, wariancje się dodają:

$$\text{Var } X = np(1 - p).$$

5.11 Nierówność Czebyszewa dla wariancji

Twierdzenie 5.6: Nierówność Czebyszewa. Jeżeli $X \in L^2$, to dla każdego $\lambda > 0$:

$$\mathbb{P}(|X - \mathbb{E}X| \geq \lambda) \leq \frac{\text{Var } X}{\lambda^2}.$$

Intuicja. Jeżeli wariancja jest mała, to zmienna rzadko oddala się mocno od swojej średniej. To jest jeden z pierwszych mostów między parametrami rozkładu a prawdopodobieństwami zdarzeń.**Przykład 5.12: Kontrola odchylenia od średniej.** Załóżmy, że $\mathbb{E}X = 100$ oraz $\text{Var } X = 25$. Oszacujmy

$$\mathbb{P}(|X - 100| \geq 10).$$

Z nierówności Czebyszewa:

$$\mathbb{P}(|X - 100| \geq 10) \leq \frac{25}{10^2} = \frac{1}{4}.$$

Czyli prawdopodobieństwo odchylenia od średniej o co najmniej 10 jest nie większe niż 0,25.

5.12 Najważniejsze średnie i wariancje rozkładów

Rozkład	Zapis	Wartość oczekiwana	Wariancja
Bernoulliego	$\text{Bern}(p)$	p	$p(1-p)$
Dwumianowy	$B(n, p)$	np	$np(1-p)$
Poissona	$\text{Pois}(\lambda)$	λ	λ
Jednostajny	$U([a, b])$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Wykładniczy	$\text{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normalny	$N(m, \sigma^2)$	m	σ^2

Ważne. Tabela jest bardzo przydatna, ale nie zastępuje rozumienia. W zadaniach często najpierw trzeba rozpoznać rozkład, a dopiero potem skorzystać ze wzoru.

5.13 Iloczyn wartości oczekiwanych i niezależność

Twierdzenie 5.7: Wartość oczekiwana iloczynu niezależnych zmiennych. Jeżeli $X_1, \dots, X_n$ są niezależne i całkowalne, to

$$\mathbb{E}(X_1 X_2 \cdots X_n) = \mathbb{E}X_1 \cdot \mathbb{E}X_2 \cdots \mathbb{E}X_n.$$

Uwaga. Z tego, że

$$\mathbb{E}(XY) = \mathbb{E}X \mathbb{E}Y,$$

nie wynika jeszcze, że X i Y są niezależne. Niezależność jest znacznie silniejszym warunkiem.

5.14 Kowariancja

Definicja 5.4: Kowariancja. Niech $X, Y \in L^2$. Kowariancją zmiennych X i Y nazywamy liczbę

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Jeżeli

$$\text{Cov}(X, Y) = 0,$$

to mówimy, że X i Y są nieskorelowane.

Intuicja. Kowariancja mierzy wspólny kierunek zmian. Jeśli X jest powyżej swojej średniej zwykle wtedy, gdy Y też jest powyżej swojej średniej, kowariancja jest dodatnia. Jeśli jedna zmienna jest powyżej średniej wtedy, gdy druga zwykle jest poniżej, kowariancja jest ujemna.

Twierdzenie 5.8: Własności kowariancji. Dla zmiennych całkowalnych z kwadratem zachodzi:

1.

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y.$$

2.

$$\text{Cov}(X, X) = \text{Var } X.$$

3.

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

4. Kowariancja jest dwuliniowa, np.

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z).$$

5. Jeżeli X i Y są niezależne, to są nieskorelowane.

Uwaga. Niezależność implikuje nieskorelowanie, ale nieskorelowanie nie musi implikować niezależności. Warunek $\text{Cov}(X, Y) = 0$ mówi tylko o braku zależności liniowej, a nie o braku każdej zależności.

Przykład 5.13: Zależność bez korelacji. Niech X przyjmuje wartości $-1, 0, 1$ z prawdopodobieństwami $1/3, 1/3, 1/3$ i niech

$$Y = X^2.$$

Wtedy Y jest całkowicie wyznaczone przez X , więc zmienne są zależne. Jednak

$$\mathbb{E}X = 0, \quad \mathbb{E}(XY) = \mathbb{E}(X^3) = 0,$$

więc

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y = 0.$$

Zatem zmienne są zależne, ale nieskorelowane.

5.15 Wariancja sumy

Twierdzenie 5.9: Wariancja sumy. Jeżeli $X_1, \dots, X_n \in L^2$, to

$$\text{Var}(X_1 + \dots + X_n) = \sum_{k=1}^n \text{Var} X_k + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

W szczególności, jeśli zmienne są parami nieskorelowane, to

$$\text{Var}(X_1 + \dots + X_n) = \text{Var} X_1 + \dots + \text{Var} X_n.$$

Intuicja. Średnie zawsze dodają się liniowo. Wariancje dodają się tylko wtedy, gdy nie ma wspólnego liniowego ruchu między zmiennymi. Jeśli zmienne są dodatnio skorelowane, suma ma większy rozrzut. Jeśli ujemnie, rozrzut może się częściowo znosić.

Przykład 5.14: Dwa rzuty kostką. Niech X i Y oznaczają wyniki dwóch niezależnych rzutów kostką. Wiemy, że

$$\text{Var} X = \text{Var} Y = \frac{35}{12}.$$

Ponieważ rzuty są niezależne,

$$\text{Cov}(X, Y) = 0.$$

Dlatego

$$\text{Var}(X + Y) = \text{Var} X + \text{Var} Y = \frac{35}{6}.$$

5.16 Współczynnik korelacji

Definicja 5.5: Korelacja. Jeżeli $\text{Var} X > 0$ i $\text{Var} Y > 0$, to współczynnikiem korelacji zmiennych X, Y nazywamy


$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var} X \text{Var} Y}}.$$

Twierdzenie 5.10: Własności korelacji. Jeżeli $\text{Var } X > 0$ i $\text{Var } Y > 0$, to

$$-1 \leq \rho(X, Y) \leq 1.$$

Ponadto:

- $\rho(X, Y) > 0$ oznacza dodatnią zależność liniową,
- $\rho(X, Y) < 0$ oznacza ujemną zależność liniową,
- $\rho(X, Y) = 0$ oznacza nieskorelowanie,
- $|\rho(X, Y)| = 1$ oznacza zależność liniową prawie na pewno.



5.17 Wektor wartości oczekiwanej i macierz kowariancji

Definicja 5.6: Wartość oczekiwana wektora losowego. Jeżeli

$$X = (X_1, \dots, X_d)$$

i każda współrzędna jest całkowalna, to wartością oczekiwaną wektora losowego X nazywamy wektor

$$\mathbb{E}X = (\mathbb{E}X_1, \dots, \mathbb{E}X_d).$$

Definicja 5.7: Macierz kowariancji. Jeżeli $X = (X_1, \dots, X_d)$ ma współrzędne całkowalne z kwadratem, to macierzą kowariancji nazywamy macierz

$$\Lambda = \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \cdots & \text{Cov}(X_d, X_d) \end{pmatrix}.$$

Twierdzenie 5.11: Własności macierzy kowariancji. Macierz kowariancji jest symetryczna i nieujemnie określona, czyli dla każdego $t \in \mathbb{R}^d$:

$$t^T \Lambda t \geq 0.$$

Intuicja. Macierz kowariancji opisuje kształt chmury punktów. Wariancje na przekątnej mówią, jak duży jest rozrzut w poszczególnych kierunkach współrzędnych. Kowariancje poza przekątną mówią, czy współrzędne poruszają się razem.

Ważne. Jeżeli współrzędne $X_1, \dots, X_d$ są niezależne, to macierz kowariancji jest diagonalna. Odwrotna implikacja nie jest prawdziwa w ogólności. Dla rozkładu normalnego wielowymiarowego zachodzi jednak ważny wyjątek: nieskorelowanie współrzędnych jest równoważne ich niezależności.

5.18 Regresja liniowa: najlepsze liniowe przybliżenie

Założmy, że mamy zmienne losowe $X, Y \in L^2$. Chcemy przewidywać Y na podstawie X za pomocą wyrażenia liniowego

$$aX + b.$$

Szukamy takich a, b , żeby średni błąd kwadratowy

$$\mathbb{E}(Y - aX - b)^2$$

był jak najmniejszy.

Twierdzenie 5.12: Najlepsza regresja liniowa. Jeżeli $\text{Var } X > 0$, to najlepsze liniowe przybliżenie Y przez $aX + b$ w sensie średniokwadratowym otrzymujemy dla

$$a = \frac{\text{Cov}(X, Y)}{\text{Var } X},$$

$$b = \mathbb{E}Y - a\mathbb{E}X.$$

Intuicja. Współczynnik a mówi, jak mocno zmienia się przewidywana wartość Y , gdy X rośnie o jedną jednostkę. Jeśli kowariancja jest dodatnia, prosta regresji rośnie. Jeśli jest ujemna, maleje. Jeśli kowariancja jest zerowa, najlepszą liniową prognozą jest po prostu stała $\mathbb{E}Y$.

5.19 Schematy rozwiązywania zadań

Ważne.

1. Sprawdź, czy zmienna jest dyskretna czy ciągła.
2. Jeżeli dyskretna, użyj

$$\mathbb{E}X = \sum_x x\mathbb{P}(X = x).$$

3. Jeżeli ciągła z gęstością g , użyj

$$\mathbb{E}X = \int_{\mathbb{R}} xg(x) dx.$$

4. Jeżeli zmienna jest sumą prostych składników, często łatwiej użyć liniowości:

$$\mathbb{E}(X_1 + \dots + X_n) = \mathbb{E}X_1 + \dots + \mathbb{E}X_n.$$

Ważne. Najczęściej używaj wzoru

$$\text{Var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2.$$

Czyli:

1. policz $\mathbb{E}X$,
2. policz $\mathbb{E}X^2$,
3. odejmij kwadrat średniej.

Jeśli X jest sumą niezależnych albo nieskorelowanych składników, można użyć dodawania wariancji.

Ważne. Pamiętaj o wzorze

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y.$$

Zatem w zadaniach zwykle liczysz trzy rzeczy:

$$\mathbb{E}(XY), \quad \mathbb{E}X, \quad \mathbb{E}Y.$$

Jeśli X i Y są niezależne, od razu masz $\text{Cov}(X, Y) = 0$.

5.20 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Niech X oznacza wynik rzutu uczciwą kostką. Oblicz $\mathbb{E}X$ oraz $\text{Var } X$.

Rozwiązanie. Mamy

$$\mathbb{E}X = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = \frac{7}{2}.$$

Dalej

$$\mathbb{E}X^2 = \frac{1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2}{6} = \frac{91}{6}.$$

Zatem

$$\text{Var } X = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{35}{12}.$$

Zadanie z rozwiązaniem. Rzucamy symetryczną monetą 100 razy. Niech X oznacza liczbę orłów. Oblicz $\mathbb{E}X$ i $\text{Var } X$.

Rozwiązanie. Mamy

$$X \sim B(100, 1/2).$$

Zatem

$$\mathbb{E}X = np = 100 \cdot \frac{1}{2} = 50,$$

$$\text{Var } X = np(1 - p) = 100 \cdot \frac{1}{2} \cdot \frac{1}{2} = 25.$$

Odchylenie standardowe wynosi

$$\sigma_X = \sqrt{25} = 5.$$

Zadanie z rozwiązaniem. Niech X ma gęstość

$$g(x) = 2x\mathbf{1}_{[0,1]}(x).$$

Oblicz $\mathbb{E}X$.

Rozwiązanie. Korzystamy ze wzoru dla gęstości:

$$\mathbb{E}X = \int_{\mathbb{R}} xg(x) dx = \int_0^1 x \cdot 2x dx = 2 \int_0^1 x^2 dx = \frac{2}{3}.$$

Zadanie z rozwiązaniem. Niech $X, Y \in L^2$ oraz

$$\mathbb{E}X = 2, \quad \mathbb{E}Y = 3, \quad \mathbb{E}(XY) = 10.$$

Oblicz $\text{Cov}(X, Y)$.

Rozwiązanie. Korzystamy ze wzoru

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y.$$

Stąd

$$\text{Cov}(X, Y) = 10 - 2 \cdot 3 = 4.$$

Kowariancja jest dodatnia, więc zmienne mają dodatni wspólny trend liniowy.

Zadanie z rozwiązaniem. Niech $X, Y \in L^2$ oraz

$$\operatorname{Var} X = 4, \quad \operatorname{Var} Y = 9, \quad \operatorname{Cov}(X, Y) = -2.$$

Oblicz $\operatorname{Var}(X + Y)$.

Rozwiązanie. Dla dwóch zmiennych

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y + 2 \operatorname{Cov}(X, Y).$$

Zatem

$$\operatorname{Var}(X + Y) = 4 + 9 + 2 \cdot (-2) = 9.$$

Ujemna kowariancja zmniejszyła wariancję sumy.

5.21 Najczęstsze błędy

Uwaga. Wartość oczekiwana to średnia ważona, niekoniecznie moda. Dla kostki $\mathbb{E}X = 3,5$, chociaż żadna ściana nie ma wartości 3,5.

Uwaga. Nie każda zmienna losowa ma wartość oczekiwaną. Przed użyciem $\mathbb{E}X$ trzeba mieć pewność, że wyrażenie istnieje.

Uwaga. Nie wolno pisać w ogólności

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y.$$

Poprawny wzór to

$$\operatorname{Var}(X + Y) = \operatorname{Var} X + \operatorname{Var} Y + 2 \operatorname{Cov}(X, Y).$$

Dodawanie wariancji działa przy nieskorelowaniu, w szczególności przy niezależności.

Uwaga. Jeżeli zmienne są niezależne, to są nieskorelowane. Ale jeśli są nieskorelowane, to nie muszą być niezależne.

Uwaga. Wariancja ma jednostkę kwadratową. Dlatego często łatwiej interpretować odchylenie standardowe $\sqrt{\operatorname{Var} X}$, które ma tę samą jednostkę co X .

Podsumowanie.

1. Wartość oczekiwana zmiennej dyskretnej:

$$\mathbb{E}X = \sum_x x \mathbb{P}(X = x).$$

2. Wartość oczekiwana zmiennej z gęstością:

$$\mathbb{E}X = \int_{\mathbb{R}} x g(x) dx.$$

3. Ogólny wzór:

$$\mathbb{E}f(X) = \sum_x f(x) \mathbb{P}(X = x)$$

albo

$$\mathbb{E}f(X) = \int f(x)g(x) dx.$$

4. Liniowość:

$$\mathbb{E}(aX + bY) = a\mathbb{E}X + b\mathbb{E}Y.$$

5. Wariancja:

$$\text{Var } X = \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2.$$

6. Przesunięcie nie zmienia wariancji, a mnożenie przez a mnoży wariancję przez a^2 :

$$\text{Var}(aX + b) = a^2 \text{Var } X.$$

7. Nierówność Czebyszewa:

$$\mathbb{P}(|X - \mathbb{E}X| \geq \lambda) \leq \frac{\text{Var } X}{\lambda^2}.$$

8. Kowariancja:

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y.$$

9. Wariancja sumy:

$$\text{Var}(X_1 + \dots + X_n) = \sum_k \text{Var } X_k + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

10. Korelacja:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var } X \text{Var } Y}}, \quad -1 \leq \rho(X, Y) \leq 1.$$

11. Wektor wartości oczekiwanej:

$$\mathbb{E}(X_1, \dots, X_d) = (\mathbb{E}X_1, \dots, \mathbb{E}X_d).$$

12. Macierz kowariancji ma na przekątnej wariancje, a poza przekątną kowariancje.

6. Różne rodzaje zbieżności zmiennych losowych

6.1 Mapa tematu

W poprzednich rozdziałach nauczyliśmy się opisywać pojedyncze zmienne losowe: ich rozkład, dystrybuantę, gęstość, wartość oczekiwaną i wariancję. Teraz zaczynamy patrzeć na **ciągi zmiennych losowych**

$$X_1, X_2, X_3, \dots$$

i pytamy:

Co znaczy, że X_n dąży do X ?

W analizie zwykły ciąg liczbowy ma jedną naturalną definicję granicy. W rachunku prawdopodobieństwa sytuacja jest bogatsza, bo X_n nie jest pojedynczą liczbą, tylko funkcją zależną od losu ω . Dlatego istnieje kilka sensownych typów zbieżności.

W tym rozdziale poznamy przede wszystkim:

1. zbieżność prawie na pewno,
2. zbieżność według prawdopodobieństwa,
3. zbieżność w L^p ,
4. zależności między tymi zbieżnościami,
5. jednostajną całkowalność, czyli warunek kontrolujący “uciekające masy”.

Intuicja. Najprostsza intuicja jest taka:

- zbieżność prawie na pewno mówi: “dla prawie każdego losu ω zwykły ciąg liczbowy $X_n(\omega)$ ma granicę”,
- zbieżność według prawdopodobieństwa mówi: “prawdopodobieństwo dużego błędu dąży do zera”,
- zbieżność w L^p mówi: “średni błąd rzędu p dąży do zera”.

Czyli każda zbieżność patrzy na błąd $X_n - X$ z trochę innej strony.

6.2 Dlaczego w ogóle jest kilka zbieżności?

Niech

$$X_n : \Omega \rightarrow \mathbb{R}$$

będzie zmienną losową. Dla każdego konkretnego wyniku losowego ω dostajemy zwykłą liczbę

$$X_n(\omega).$$

Zatem ciąg zmiennych losowych można oglądać na dwa sposoby.

Ważne. Punkt widzenia 1: po ustaleniu losu.

Ustalamy ω i patrzymy na zwykły ciąg liczbowy

$$X_1(\omega), X_2(\omega), X_3(\omega), \dots$$

Możemy pytać, czy ten ciąg zbiega do $X(\omega)$.

Punkt widzenia 2: globalnie, przez prawdopodobieństwo.

Nie wymagamy, żeby zbieżność zachodziła dla każdego ω . Patrzymy raczej, czy zbiór złych losów, dla których błąd jest duży, ma coraz mniejsze prawdopodobieństwo.

To prowadzi do różnych definicji.

6.3 Zbieżność prawie na pewno

Definicja 6.1: Zbieżność prawie na pewno. Niech $(X_n)_{n \geq 1}$ będzie ciągiem zmiennych losowych oraz niech X będzie zmienną losową. Mówimy, że

$$X_n \rightarrow X \quad \text{prawie na pewno,}$$

jeżeli

$$\mathbb{P}(\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\}) = 1.$$

Piszemy też

$$X_n \xrightarrow{p.n.} X.$$

Intuicja. Zbieżność prawie na pewno oznacza, że jeśli wylosujemy jedno ω i potem będziemy patrzeć na liczby

$$X_1(\omega), X_2(\omega), X_3(\omega), \dots,$$

to dla prawie każdego ω ten zwykły ciąg liczbowy będzie zbieżny do $X(\omega)$.

Słowo “prawie” oznacza, że można zignorować zbiór wyjątkowy o prawdopodobieństwie zero.

Przykład 6.1: Przykład: coraz mniejszy przedział. Weźmy przestrzeń probabilistyczną

$$\Omega = [0, 1]$$

z miarą Lebesgue’a. Niech

$$X_n(\omega) = \mathbf{1}_{[0, 1/n]}(\omega).$$

Czyli X_n przyjmuje wartość 1, jeśli $\omega \in [0, 1/n]$, oraz 0 poza tym przedziałem.

Dla każdego $\omega > 0$ od pewnego miejsca mamy $\omega > 1/n$, więc

$$X_n(\omega) = 0$$

dla wszystkich dużych n . Dla $\omega = 0$ mamy zawsze $X_n(0) = 1$, ale pojedynczy punkt ma prawdopodobieństwo zero.

Zatem

$$X_n \xrightarrow{p.n.} 0.$$

Uwaga. Nie. Zbieżność prawie na pewno dopuszcza wyjątki, ale tylko na zbiorze o prawdopodobieństwie zero.

Na przykład na odcinku $[0, 1]$ pojedynczy punkt można zignorować probabilistycznie, bo ma miarę zero.

6.4 Zbieżność według prawdopodobieństwa

Definicja 6.2: Zbieżność według prawdopodobieństwa. Mówimy, że

$$X_n \rightarrow X \quad \text{według prawdopodobieństwa,}$$

jeżeli dla każdego $\varepsilon > 0$ zachodzi

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0.$$

Piszemy

$$X_n \xrightarrow{\mathbb{P}} X.$$

Intuicja. Zbieżność według prawdopodobieństwa nie mówi, że dla prawie każdego ω ciąg $X_n(\omega)$ musi się ładnie uspokoić. Mówi tylko, że dla dużych n coraz trudniej trafić na taki los ω , dla którego błąd $|X_n - X|$ jest większy niż ustalony próg ε .

Można to zapamiętać bardzo krótko:

$$X_n \xrightarrow{\mathbb{P}} X \iff \text{duży błąd ma coraz mniejsze prawdopodobieństwo.}$$

Przykład 6.2: Ten sam przykład: $\mathbf{1}_{[0,1/n]}$. Dla

$$X_n = \mathbf{1}_{[0,1/n]}$$

mamy dla $0 < \varepsilon < 1$

$$\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_n = 1) = \frac{1}{n} \rightarrow 0.$$

Zatem

$$X_n \xrightarrow{\mathbb{P}} 0.$$

W tym przykładzie mamy nawet silniejszą zbieżność, bo wcześniej pokazaliśmy zbieżność prawie na pewno.

6.5 Zbieżność prawie na pewno implikuje zbieżność według prawdopodobieństwa

Twierdzenie 6.1: Zbieżność p.n. daje zbieżność według prawdopodobieństwa. Jeżeli

$$X_n \xrightarrow{p.n.} X,$$

to

$$X_n \xrightarrow{\mathbb{P}} X.$$

Dowód - idea. Jeśli dla prawie każdego ω liczby $X_n(\omega)$ zbliżają się do $X(\omega)$, to dla ustalonego $\varepsilon > 0$ zdarzenia

$$\{|X_n - X| > \varepsilon\}$$

powinny być coraz rzadsze. Formalnie używa się ciągłości miary probabilistycznej dla ciągów zstępujących. Intuicja jest jednak dokładnie taka: jeśli prawie wszędzie błąd ostatecznie znika, to prawdopodobieństwo dużego błędu musi dążyć do zera.

Uwaga. Ze zbieżności według prawdopodobieństwa nie wynika zbieżność prawie na pewno. Zbieżność według prawdopodobieństwa pozwala, aby “zły obszar” przesuwał się po przestrzeni Ω . W każdym kroku ma małe prawdopodobieństwo, ale pojedynczy punkt ω może wpadać w złe obszary nieskończenie wiele razy.

6.6 Przykład: zbieżność według prawdopodobieństwa, ale nie prawie na pewno

Na $\Omega = [0, 1]$ bierzemy kolejno wskaźniki przedziałów dyadycznych:

$$[0, 1),$$

$$[0, 1/2), [1/2, 1),$$

$$[0, 1/4), [1/4, 1/2), [1/2, 3/4), [3/4, 1),$$

i tak dalej. Niech X_n będzie wskaźnikiem kolejnego takiego przedziału.

W każdym kolejnym bloku długości przedziałów są coraz mniejsze, więc

$$\mathbb{P}(X_n = 1) \rightarrow 0.$$

Stąd

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Ale dla ustalonego punktu $\omega \in [0, 1)$ w każdym bloku dokładnie jeden przedział zawiera ω . Oznacza to, że ciąg

$$X_1(\omega), X_2(\omega), X_3(\omega), \dots$$


ma nieskończenie wiele jedynek i nieskończenie wiele zer. Nie może więc zbiegać do 0.

Zatem

$$X_n \xrightarrow{\mathbb{P}} 0,$$

ale nie mamy

$$X_n \xrightarrow{p.n.} 0.$$



6.7 Zbieżność w L^p

Definicja 6.3: Zbieżność w L^p . Niech $p \geq 1$. Mówimy, że

$$X_n \rightarrow X \quad \text{w } L^p,$$

jeżeli

$$\mathbb{E}|X_n - X|^p \rightarrow 0.$$

Równoważnie:

$$\|X_n - X\|_p \rightarrow 0,$$

gdzie

$$\|Y\|_p = (\mathbb{E}|Y|^p)^{1/p}.$$

Najważniejsze przypadki:

- L^1 : średni błąd bezwzględny dąży do zera,
- L^2 : średni błąd kwadratowy dąży do zera,
- L^∞ : błąd jest kontrolowany prawie jednostajnie, czyli przez istotne supremum.

Intuicja. Zbieżność w L^p jest mocniejsza niż zbieżność według prawdopodobieństwa, bo nie patrzy tylko na to, czy błąd jest duży, ale też jak duży może być.

Zbieżność według prawdopodobieństwa ignoruje bardzo wysokie, bardzo rzadkie piki. Zbieżność w L^p może ich nie ignorować, bo takie piki mocno wpływają na wartość oczekiwaną $\mathbb{E}|X_n - X|^p$.

Twierdzenie 6.2: L^p implikuje zbieżność według prawdopodobieństwa. Jeżeli

$$X_n \rightarrow X \quad \text{w } L^p,$$

to

$$X_n \xrightarrow{\mathbb{P}} X.$$

Dowód. Dla każdego $\varepsilon > 0$ z nierówności Markowa dostajemy

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{P}(|X_n - X|^p > \varepsilon^p) \leq \frac{\mathbb{E}|X_n - X|^p}{\varepsilon^p}.$$

Jeśli $X_n \rightarrow X$ w L^p , to licznik dąży do zera, więc całość też dąży do zera. Zatem

$$X_n \xrightarrow{\mathbb{P}} X.$$

Przykład 6.3: Piki: zbieżność według prawdopodobieństwa bez zbieżności w L^p . Na $[0, 1]$ z miarą Lebesgue'a definiujemy

$$X_n(\omega) = n^{1/p} \mathbf{1}_{[0, 1/n]}(\omega).$$

Dla każdego $\varepsilon > 0$ mamy

$$\mathbb{P}(|X_n| > \varepsilon) \leq \frac{1}{n} \rightarrow 0,$$

więc

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Ale

$$\mathbb{E}|X_n|^p = \int_0^{1/n} n \, d\omega = 1.$$

Zatem


$$\mathbb{E}|X_n - 0|^p \not\rightarrow 0,$$

czyli X_n nie zbiega do zera w L^p .

To jest klasyczny przykład rzadkiego, ale wysokiego piku.

6.8 Relacje między zbieżnościami

Najważniejsze implikacje można zapamiętać z diagramu.



Strzałka oznacza: zbieżność u góry lub z lewej pociąga za sobą zbieżność wskazaną strzałką. Odwrotne strzałki zwykle nie działają.

Ważne.

$$X_n \xrightarrow{p.n.} X \implies X_n \xrightarrow{\mathbb{P}} X.$$

$$X_n \rightarrow X \text{ w } L^p \implies X_n \xrightarrow{\mathbb{P}} X.$$

Jeśli $q > p$, to

$$X_n \rightarrow X \text{ w } L^q \implies X_n \rightarrow X \text{ w } L^p.$$

Uwaga. Nie wolno automatycznie odwracać strzałek. W szczególności:

- zbieżność według prawdopodobieństwa nie musi dawać zbieżności prawie na pewno,
- zbieżność według prawdopodobieństwa nie musi dawać zbieżności w L^p ,
- zbieżność prawie na pewno nie musi dawać zbieżności w L^p .

6.9 Zbieżność w L^q daje zbieżność w L^p dla $q > p$

Twierdzenie 6.3: Silniejszy moment kontroluje słabszy moment. Jeżeli $1 \leq p < q$ oraz

$$X_n \rightarrow X \text{ w } L^q,$$

to

$$X_n \rightarrow X \text{ w } L^p.$$

Intuicyjnie. Na przestrzeni probabilistycznej mamy $\mathbb{P}(\Omega) = 1$. Jeśli kontrolujemy średnią z większej potęgi błędu, to tym bardziej kontrolujemy średnią z mniejszej potęgi błędu.

Formalnie można użyć nierówności Höldera albo nierówności

$$\|Y\|_p \leq \|Y\|_q$$

dla $p < q$ na przestrzeni probabilistycznej.

6.10 Warunek Cauchy'ego według prawdopodobieństwa

W analizie zwykły ciąg liczbowy jest zbieżny wtedy i tylko wtedy, gdy jest ciągiem Cauchy'ego. Podobny fakt działa dla zbieżności według prawdopodobieństwa.

Definicja 6.4: Ciąg Cauchy'ego według prawdopodobieństwa. Mówimy, że (X_n) jest ciągiem Cauchy'ego według prawdopodobieństwa, jeśli dla każdego $\varepsilon > 0$ i $\delta > 0$ istnieje N , takie że dla wszystkich $m, n \geq N$

$$\mathbb{P}(|X_n - X_m| > \varepsilon) < \delta.$$

Twierdzenie 6.4: Kryterium Cauchy'ego. Ciąg (X_n) jest zbieżny według prawdopodobieństwa wtedy i tylko wtedy, gdy jest ciągiem Cauchy'ego według prawdopodobieństwa.

Intuicja. Jeśli X_n ma mieć granicę w sensie prawdopodobieństwa, to dla dużych indeksów n, m zmienne X_n i X_m powinny być bardzo blisko z dużym prawdopodobieństwem. Czyli nie musimy znać granicy, żeby podejrzewać zbieżność.

6.11 Podciąg zbieżny prawie na pewno

Bardzo użyteczny fakt mówi, że ze zbieżności według prawdopodobieństwa można wybrać podciąg zbieżny prawie na pewno.

Twierdzenie 6.5: Podciąg zbieżny prawie na pewno. Jeżeli

$$X_n \xrightarrow{\mathbb{P}} X,$$

to istnieje podciąg $(X_{n_k})_{k \geq 1}$ taki, że

$$X_{n_k} \xrightarrow{p.n.} X.$$

Idea dowodu. Skoro $X_n \rightarrow X$ według prawdopodobieństwa, to możemy wybierać indeksy n_k tak duże, żeby

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) < 2^{-k}.$$

Suma prawdopodobieństw po prawej stronie jest skończona:

$$\sum_{k=1}^{\infty} 2^{-k} < \infty.$$

Z lematu Borela-Cantellego wynika, że zdarzenia

$$\{|X_{n_k} - X| > 2^{-k}\}$$

zajdą tylko skończenie wiele razy. To oznacza, że od pewnego miejsca

$$|X_{n_k} - X| \leq 2^{-k},$$

a więc $X_{n_k} \rightarrow X$ prawie na pewno.

6.12 Jednostajna całkowalność

Zbieżność według prawdopodobieństwa nie kontroluje bardzo wysokich pików. Żeby przejść od zbieżności według prawdopodobieństwa do zbieżności w L^1 lub L^p , potrzebujemy dodatkowego warunku. Tym warunkiem jest **jednostajna całkowalność**.

Definicja 6.5: Jednostajna całkowalność. Rodzina całkowalnych zmiennych losowych $(X_i)_{i \in I}$ jest jednostajnie całkowalna, jeśli

$$\sup_{i \in I} \mathbb{E}(|X_i| \mathbf{1}_{\{|X_i| \geq r\}}) \rightarrow 0$$

gdy $r \rightarrow \infty$.

Intuicja. Jednostajna całkowalność mówi:

ogony wszystkich zmiennych z rodziny są małe jednocześnie.

Nie wystarczy, że każda pojedyncza zmienna ma mały ogon dla dużego r . Próg r musi działać wspólnie dla całej rodziny.

Przykład 6.4: Rodzina zdominowana przez zmienną całkowalną. Jeśli istnieje zmienna całkowalna Y taka, że

$$|X_i| \leq Y$$

dla wszystkich i , to rodzina (X_i) jest jednostajnie całkowalna.

Dlaczego? Bo wtedy

$$|X_i| \mathbf{1}_{\{|X_i| \geq r\}}$$

nie może mieć większych ogonów niż całkowalna zmienna dominująca. Intuicyjnie: jeden wspólny parasol Y kontroluje wszystkie zmienne naraz.

Przykład 6.5: Piki, które psują jednostajną całkowalność. Niech

$$X_n = n \mathbf{1}_{[0, 1/n]}.$$

Wtedy

$$\mathbb{E}X_n = n \cdot \frac{1}{n} = 1.$$

Zmienna X_n jest równa zero prawie wszędzie, ale na bardzo małym przedziale ma bardzo dużą wartość.

Dla dużego progu r możemy wybrać $n \geq r$. Wtedy na zbiorze $[0, 1/n]$ mamy $X_n = n \geq r$, więc

$$\mathbb{E}(|X_n| \mathbf{1}_{\{|X_n| \geq r\}}) = 1.$$

Supremum po n nie dąży do zera. Rodzina nie jest jednostajnie całkowalna.

6.13 Zbieżność w L^p a jednostajna całkowalność

Twierdzenie 6.6: Kryterium zbieżności w L^p . Niech $p \geq 1$. Wtedy

$$X_n \rightarrow X \quad \text{w } L^p$$

wtedy i tylko wtedy, gdy

$$X_n \xrightarrow{\mathbb{P}} X$$

oraz rodzina

$$\{|X_n|^p : n \geq 1\}$$

jest jednostajnie całkowalna.

Intuicja. To twierdzenie jest bardzo ważne, bo mówi, czego brakuje zbieżności według prawdopodobieństwa, aby stała się zbieżnością w L^p .

Zbieżność według prawdopodobieństwa mówi: “duże błędy są coraz rzadsze”.

Jednostajna całkowalność mówi: “nawet jeśli pojawiają się rzadkie duże wartości, to ich wkład do średniej jest pod kontrolą”.

Razem dają zbieżność w średnim sensie.

6.14 Krótka uwaga o zbieżności według rozkładu

W wielu kursach pojawia się jeszcze słabsza zbieżność: zbieżność według rozkładu. Przyda się później przy twierdzeniach granicznych.

Definicja 6.6: Zbieżność według rozkładu. Niech F_n będzie dystrybucją X_n , a F dystrybucją X . Mówimy, że

$$X_n \rightarrow X \quad \text{według rozkładu,}$$

jeżeli

$$F_n(t) \rightarrow F(t)$$

dla każdego punktu ciągłości dystrybucji F .

Ważne. Zbieżność według prawdopodobieństwa implikuje zbieżność według rozkładu:

$$X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{d} X.$$

Zbieżność według rozkładu jest zwykle słabsza. Mówi, że rozkłady zmiennych robią się podobne, ale niekoniecznie że same zmienne są blisko na tej samej przestrzeni probabilistycznej.

6.15 Jak rozpoznawać typowe zadania?

Ważne. Najczęściej bierzesz dowolne $\varepsilon > 0$ i liczysz albo szacujesz

$$\mathbb{P}(|X_n - X| > \varepsilon).$$

Jeśli to dąży do zera, to koniec.

Bardzo często używa się nierówności Markowa lub Czebyszewa:

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^p}{\varepsilon^p}.$$

Ważne. Liczysz

$$\mathbb{E}|X_n - X|^p$$

i sprawdzasz, czy dąży do zera.

Jeśli zmienne mają gęstości, często będzie to całka. Jeśli są dyskretne, często będzie to suma.

Ważne. Wystarczy pokazać, że

$$\mathbb{E}|X_n - X|^p$$

nie dąży do zera. Typowe kontrprzykłady to wysokie piki na coraz mniejszych zbiorach.

Ważne. Jeżeli dla typowego ω wartości $X_n(\omega)$ skaczą nieskończenie wiele razy i nie stabilizują się, to zbieżność prawie na pewno nie zachodzi.

Czasem pomaga lemat Borela-Cantellego: jeśli zdarzenia złego zachowania występują nieskończenie często z dodatnim prawdopodobieństwem, to nie ma zbieżności p.n.

6.16 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Na $[0, 1]$ z miarą Lebesgue'a niech

$$X_n = \mathbf{1}_{[0, 1/n]}.$$

Zbadaj zbieżność X_n do zera prawie na pewno, według prawdopodobieństwa i w L^p dla $p \geq 1$.

Rozwiązanie. Jak wcześniej, dla każdego $\omega > 0$ mamy od pewnego miejsca $\omega > 1/n$, więc $X_n(\omega) = 0$. Jedyny problem jest w punkcie $\omega = 0$, ale ma on prawdopodobieństwo zero. Zatem

$$X_n \xrightarrow{p.n.} 0.$$

Stąd automatycznie

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Sprawdźmy jeszcze L^p :

$$\mathbb{E}|X_n|^p = \int_0^1 |\mathbf{1}_{[0, 1/n]}(x)|^p dx = \int_0^{1/n} 1 dx = \frac{1}{n} \rightarrow 0.$$

Zatem

$$X_n \rightarrow 0 \quad \text{w } L^p$$

dla każdego $p \geq 1$.

Zadanie z rozwiązaniem. Na $[0, 1]$ niech

$$X_n = n\mathbf{1}_{[0, 1/n]}.$$

Pokaż, że $X_n \rightarrow 0$ według prawdopodobieństwa, ale nie w L^1 .

Rozwiązanie. Dla dowolnego $\varepsilon > 0$ i dużych n mamy $n > \varepsilon$, więc

$$\mathbb{P}(|X_n| > \varepsilon) = \mathbb{P}([0, 1/n]) = \frac{1}{n} \rightarrow 0.$$

Czyli

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Natomiast

$$\mathbb{E}|X_n| = \int_0^{1/n} n dx = 1.$$

To nie dąży do zera, więc nie ma zbieżności w L^1 .

Zadanie z rozwiązaniem. Załóżmy, że

$$\mathbb{E}|X_n - X|^2 \rightarrow 0.$$

Pokaż, że

$$X_n \xrightarrow{\mathbb{P}} X.$$

Rozwiązanie. Dla dowolnego $\varepsilon > 0$ używamy nierówności Czebyszewa:

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^2}{\varepsilon^2}.$$

Licznik dąży do zera, a mianownik jest stały dodatni. Zatem

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0.$$

To dokładnie oznacza zbieżność według prawdopodobieństwa.

Zadanie z rozwiązaniem. Niech $X_1, X_2, \dots$ będą niezależnymi zmiennymi Rademachera, czyli

$$\mathbb{P}(X_n = 1) = \mathbb{P}(X_n = -1) = \frac{1}{2}.$$

Czy (X_n) jest zbieżny według prawdopodobieństwa?

Rozwiązanie. Gdyby (X_n) był zbieżny według prawdopodobieństwa, to byłby ciągiem Cauchy'ego według prawdopodobieństwa.

Dla $m \neq n$ zmienne X_m i X_n są niezależne. Mamy

$$\mathbb{P}(X_n \neq X_m) = \frac{1}{2}.$$

Jeżeli $X_n \neq X_m$, to

$$|X_n - X_m| = 2.$$

Zatem dla $\varepsilon = 1$:

$$\mathbb{P}(|X_n - X_m| > 1) = \frac{1}{2}$$

dla wszystkich $m \neq n$. To nie może być mniejsze od dowolnego δ , np. od $\delta = 1/4$.

Warunek Cauchy'ego według prawdopodobieństwa nie jest spełniony, więc (X_n) nie jest zbieżny według prawdopodobieństwa.

Zadanie z rozwiązaniem. Niech $X_1, X_2, \dots$ będą parami nieskorelowane, niech

$$\mathbb{E}X_n = m$$

dla każdego n oraz załóżmy, że

$$\sup_n \text{Var}(X_n) < \infty.$$

Pokaż, że

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{\mathbb{P}} m.$$

Rozwiązanie. Oznaczmy

$$S_n = X_1 + \dots + X_n.$$

Wtedy

$$\mathbb{E}\left(\frac{S_n}{n}\right) = m.$$

Ponieważ zmienne są parami nieskorelowane,

$$\text{Var}(S_n) = \sum_{k=1}^n \text{Var}(X_k).$$

Jeśli $C = \sup_k \text{Var}(X_k)$, to

$$\text{Var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2} \text{Var}(S_n) \leq \frac{1}{n^2} \cdot nC = \frac{C}{n}.$$

Z nierówności Czebyszewa:

$$\mathbb{P}\left(\left|\frac{S_n}{n} - m\right| > \varepsilon\right) \leq \frac{C}{n\varepsilon^2} \rightarrow 0.$$

Zatem

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} m.$$

To jest podstawowa forma słabego prawa wielkich liczb.

6.17 Najczęstsze błędy

Uwaga. Zbieżność prawie na pewno jest silniejsza. Jeśli masz zbieżność p.n., to masz zbieżność według prawdopodobieństwa. Ale odwrotnie nie zawsze.

Uwaga. Nie wystarczy, że zbiór, na którym X_n jest duże, ma małe prawdopodobieństwo. Trzeba jeszcze kontrolować wysokość wartości X_n . Przykład $n\mathbf{1}_{[0,1/n]}$ pokazuje, że mały zbiór może nieść duży wkład do wartości oczekiwanej.

Uwaga. Zbieżność punktowa dla każdego ω jest zbyt mocna i często niepotrzebna. W probabilistyce zwykle wystarcza zbieżność poza zbiorem miary zero, czyli prawie na pewno.

Uwaga. Żeby mówić o zbieżności w L^p , zmienne muszą mieć skończone momenty rzędu p .

Uwaga. Zbieżność według rozkładu mówi o rozkładach, a niekoniecznie o tym, że $X_n(\omega)$ jest blisko $X(\omega)$ dla tych samych ω .

Podsumowanie.

1. Zbieżność prawie na pewno:

$$\mathbb{P}(\lim_{n \rightarrow \infty} X_n = X) = 1.$$

2. Zbieżność według prawdopodobieństwa:

$$\forall \varepsilon > 0 \quad \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0.$$

3. Zbieżność w L^p :

$$\mathbb{E}|X_n - X|^p \rightarrow 0.$$

4. Zbieżność p.n. implikuje zbieżność według prawdopodobieństwa:

$$X_n \xrightarrow{p.n.} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X.$$

5. Zbieżność w L^p implikuje zbieżność według prawdopodobieństwa:

$$X_n \rightarrow X \text{ w } L^p \Rightarrow X_n \xrightarrow{\mathbb{P}} X.$$

6. Jeśli $q > p$, to

$$X_n \rightarrow X \text{ w } L^q \Rightarrow X_n \rightarrow X \text{ w } L^p.$$

7. Ze zbieżności według prawdopodobieństwa można wybrać podciąg zbieżny p.n.

8. Jednostajna całkowalność kontroluje ogony całej rodziny zmiennych.

9. Kryterium:

$$X_n \rightarrow X \text{ w } L^p$$

wtedy i tylko wtedy, gdy $X_n \rightarrow X$ według prawdopodobieństwa oraz $\{|X_n|^p\}$ jest jednostajnie całkowalna.

10. Typowy kontrprzykład do L^p to wysoki pik na małym zbiorze:

$$X_n = n^{1/p} \mathbf{1}_{[0,1/n]}.$$

7. Prawa wielkich liczb

7.1 Mapa tematu

W poprzednim rozdziale poznaliśmy różne rodzaje zbieżności zmiennych losowych. Teraz zobaczymy jedno z najważniejszych miejsc, w których te pojęcia naprawdę zaczynają pracować: **prawa wielkich liczb**.

Interesuje nas średnia arytmetyczna zmiennych losowych:


$$\bar{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

Pytanie jest proste: czy średnia z wielu losowych obserwacji stabilizuje się wokół wartości oczekiwanej?

Intuicja. Prawo wielkich liczb jest matematycznym uzasadnieniem zdania: im więcej powtórzeń doświadczenia, tym bardziej średnia empiryczna przypomina średnią teoretyczną. Jeśli rzucamy uczciwą monetą i zapisujemy 1 za orła oraz 0 za reszkę, to średnia

$$\frac{X_1 + \cdots + X_n}{n}$$

jest częstością orłów. Prawo wielkich liczb mówi, że ta częstość dąży do $1/2$.



7.2 Średnia empiryczna i średnia teoretyczna

Definicja 7.1: Średnia empiryczna. Dla zmiennych losowych $X_1, X_2, \dots$ definiujemy średnią empiryczną z pierwszych n obserwacji jako

$$\bar{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

Słowo *empiryczna* oznacza tutaj: liczona z danych, z obserwacji, z wyników doświadczenia. Jeśli wszystkie zmienne mają tę samą wartość oczekiwaną

$$\mathbb{E}X_i = m,$$

to naturalnie spodziewamy się, że

$$\bar{X}_n \approx m$$

dla dużych n .

Przykład 7.1: Rzuty monetą jako średnia. Niech

$$X_i = \begin{cases} 1, & \text{jeśli w } i\text{-tym rzucie wypadł orzeł,} \\ 0, & \text{jeśli w } i\text{-tym rzucie wypadła reszka.} \end{cases}$$

Wtedy $X_1 + \dots + X_n$ to liczba orłów w pierwszych n rzutach, a

$$\frac{X_1 + \dots + X_n}{n}$$

to częstość orłów. Jeżeli moneta jest uczciwa, to

$$\mathbb{E}X_i = 1 \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} = \frac{1}{2}.$$

Prawo wielkich liczb mówi więc, że częstość orłów stabilizuje się przy $1/2$.

7.3 Słabe prawo wielkich liczb

Najpierw sformułujemy wersję słabą. Słowo *słabe* nie oznacza, że wynik jest mało ważny. Oznacza tylko, że zbieżność zachodzi **według prawdopodobieństwa**, a niekoniecznie prawie na pewno.

Twierdzenie 7.1: Słabe prawo wielkich liczb w wersji z wariancją. Niech $X_1, X_2, \dots$ będą zmiennymi losowymi całkowalnymi z kwadratem. Załóżmy, że:

1. zmienne X_i są nieskorelowane,
2. ich wariancje są wspólnie ograniczone, czyli istnieje $C < \infty$ takie, że $\text{Var}(X_i) \leq C$ dla każdego i .

Wtedy

$$\frac{X_1 + \dots + X_n - \mathbb{E}(X_1 + \dots + X_n)}{n} \xrightarrow{\mathbb{P}} 0.$$

W szczególności, jeśli wszystkie X_i mają tę samą wartość oczekiwaną m , to

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{\mathbb{P}} m.$$

Intuicja. Średnia losowych błędów ma coraz mniejszą wariancję. Jeśli pojedyncze obserwacje mają ograniczoną zmienność, to po uśrednieniu przez n ta zmienność spada mniej więcej jak $1/n$. Dlatego średnia przestaje mocno odchyłać się od swojej wartości oczekiwanej.

7.3.1 Dowód słabego prawa krok po kroku

Oznaczmy

$$S_n = X_1 + X_2 + \dots + X_n.$$

Chcemy pokazać, że

$$\frac{S_n - \mathbb{E}S_n}{n} \rightarrow 0$$

według prawdopodobieństwa.

Ponieważ zmienne są nieskorelowane, wariancja sumy jest sumą wariancji:

$$\text{Var}(S_n) = \sum_{k=1}^n \text{Var}(X_k).$$

Z założenia $\text{Var}(X_k) \leq C$, więc

$$\text{Var}(S_n) \leq nC.$$

Teraz liczymy wariancję średniej:

$$\text{Var}\left(\frac{S_n - \mathbb{E}S_n}{n}\right) = \frac{1}{n^2} \text{Var}(S_n) \leq \frac{1}{n^2} \cdot nC = \frac{C}{n}.$$

Korzystamy z nierówności Czebyszewa:

$$\mathbb{P}\left(\left|\frac{S_n - \mathbb{E}S_n}{n}\right| \geq \varepsilon\right) \leq \frac{\text{Var}\left(\frac{S_n - \mathbb{E}S_n}{n}\right)}{\varepsilon^2} \leq \frac{C}{n\varepsilon^2}.$$

Ponieważ prawa strona dąży do zera, dostajemy zbieżność według prawdopodobieństwa.

Ważne. Ten dowód jest jednym z najważniejszych schematów:

wariancja średniej $\rightarrow 0$ + Czebyszew $\implies$ zbieżność według prawdopodobieństwa.

7.4 Przykład: częstość sukcesów w schemacie Bernoulliego

Niech X_i oznacza wynik i -tej próby Bernoulliego:

$$X_i = \begin{cases} 1, & \text{sukces,} \\ 0, & \text{porażka.} \end{cases}$$

Niech

$$\mathbb{P}(X_i = 1) = p, \quad \mathbb{P}(X_i = 0) = 1 - p.$$

Wtedy

$$\mathbb{E}X_i = p, \quad \text{Var}(X_i) = p(1 - p).$$

Zmienna $S_n = X_1 + \dots + X_n$ liczy liczbę sukcesów w n próbach, a S_n/n to częstość sukcesów. Ze słabego prawa wielkich liczb:

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} p.$$

Przykład 7.2: Moneta uczciwa. Dla uczciwej monety $p = 1/2$. Jeśli S_n oznacza liczbę orłów w n rzutach, to

$$\frac{S_n}{n} \xrightarrow{\mathbb{P}} \frac{1}{2}.$$

To znaczy, że dla każdego $\varepsilon > 0$:

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \frac{1}{2}\right| > \varepsilon\right) \rightarrow 0.$$

Na przykład dla $\varepsilon = 0.05$ prawdopodobieństwo tego, że częstość orłów będzie poza przedziałem $(0.45, 0.55)$, dąży do zera.

Uwaga. Słabe prawo nie mówi, że od pewnego momentu wszystkie średnie będą blisko m . Ono mówi, że prawdopodobieństwo dużego odchylenia w chwili n dąży do zera. To jest zbieżność według prawdopodobieństwa, a nie jeszcze zbieżność prawie na pewno.

7.5 Mocne prawo wielkich liczb

Mocne prawo wielkich liczb mówi więcej: średnia zbiega do wartości oczekiwanej **prawie na pewno**.

Twierdzenie 7.2: Mocne prawo wielkich liczb Kołmogorowa. Niech $X_1, X_2, \dots$ będą niezależnymi zmiennymi losowymi o tym samym rozkładzie. Jeśli


$$\mathbb{E}|X_1| < \infty$$

oraz $m = \mathbb{E}X_1$, to

$$\frac{X_1 + X_2 + \dots + X_n}{n} \rightarrow m$$

prawie na pewno.

Intuicja. Słabe prawo mówi: dla dużego n rzadko widzę duże odchylenie. Mocne prawo mówi: dla prawie każdego konkretnego przebiegu doświadczenia średnia naprawdę stabilizuje się do m . To jest silniejszy rodzaj stabilizacji.



7.5.1 Dlaczego mocne prawo jest trudniejsze?

W słabym prawie badamy pojedyncze prawdopodobieństwo:

$$\mathbb{P}(|\bar{X}_n - m| > \varepsilon).$$

Dla każdego n patrzymy osobno. W mocnym prawie chcemy kontrolować całe nieskończone zachowanie:

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = m\right) = 1.$$

To jest dużo mocniejsze, bo musimy wykluczyć scenariusze, w których średnia co jakiś czas wraca daleko od m nieskończenie wiele razy.

7.6 Nierówność Kołmogorowa

Nierówność Kołmogorowa to narzędzie do kontrolowania największego wychylenia sum częściowych.

Twierdzenie 7.3: Nierówność Kołmogorowa. Niech $X_1, \dots, X_n$ będą niezależnymi, scentrowanymi zmiennymi losowymi całkowalnymi z kwadratem, czyli $\mathbb{E}X_k = 0$. Niech

$$S_k = X_1 + \dots + X_k.$$

Wtedy dla każdego $\alpha > 0$:

$$\mathbb{P}\left(\max_{1 \leq k \leq n} |S_k| \geq \alpha\right) \leq \frac{1}{\alpha^2} \text{Var}(S_n).$$

Intuicja. Nierówność Czebyszewa kontroluje jedno odchylenie $|S_n|$. Nierówność Kołmogorowa kontroluje naraz wszystkie wcześniejsze sumy:

$$|S_1|, |S_2|, \dots, |S_n|.$$

Czyli odpowiada na pytanie: jaka jest szansa, że proces gdzieś po drodze przekroczy poziom α ?



7.7 Idea dowodu mocnego prawa

Pełny dowód mocnego prawa jest techniczny, ale jego logika jest bardzo pouczająca.

7.7.1 Wersja łatwiejsza: zmienne z drugim momentem

Żałómy najpierw, że X_i są niezależne, mają ten sam rozkład oraz

$$\mathbb{E}X_i = m, \quad \mathbb{E}X_i^2 < \infty.$$

Patrzmy na zmienne scentrowane $Y_i = X_i - m$. Chcemy pokazać, że

$$\frac{Y_1 + \dots + Y_n}{n} \rightarrow 0$$

prawie na pewno.

W klasycznym dowodzie używa się faktu, że jeśli szereg

$$\sum_{n=1}^{\infty} \frac{Y_n}{n}$$

jest zbieżny prawie na pewno, to z lematu Kroneckera wynika

$$\frac{Y_1 + \dots + Y_n}{n} \rightarrow 0.$$

Dlaczego szereg $\sum Y_n/n$ jest zbieżny? Bo

$$\sum_{n=1}^{\infty} \text{Var} \left(\frac{Y_n}{n} \right) = \sum_{n=1}^{\infty} \frac{\text{Var}(Y_n)}{n^2} < \infty.$$

Skończoność szeregu wariancji pozwala zastosować kryterium zbieżności szeregów niezależnych zmiennych losowych.

Ważne. W wersji z drugim momentem najważniejsza idea jest taka:

$$\sum_{n=1}^{\infty} \frac{1}{n^2} < \infty.$$

Dzielenie przez n jest na tyle mocne, że wariancje wyrazów Y_n/n sumują się do skończonej liczby.

7.7.2 Wersja ogólna: tylko całkowalność

W ogólnym MPWL zakładamy tylko $\mathbb{E}|X_1| < \infty$. Nie musimy mieć skończonej wariancji. Wtedy dowód wymaga obcięcia dużych wartości.

Definiuje się zmienne obcięte:

$$X'_n = X_n \mathbf{1}_{\{|X_n| < n\}}.$$

Czyli zostawiamy X_n , jeśli nie jest zbyt duże, a zerujemy ekstremalne wartości.

Potem rozkładamy błąd średniej na trzy części:

$$\frac{X_1 + \cdots + X_n}{n} - m = I_n + II_n + III_n,$$

gdzie:

$$\begin{aligned} I_n &= \frac{(X_1 + \cdots + X_n) - (X'_1 + \cdots + X'_n)}{n}, \\ II_n &= \frac{(X'_1 + \cdots + X'_n) - (\mathbb{E}X'_1 + \cdots + \mathbb{E}X'_n)}{n}, \\ III_n &= \frac{\mathbb{E}X'_1 + \cdots + \mathbb{E}X'_n}{n} - m. \end{aligned}$$

Każdy składnik znika z innego powodu:

1. $I_n \rightarrow 0$ p.n., bo bardzo duże wartości pojawiają się tylko skończenie wiele razy; używa się lematu Borela-Cantellego.
2. $II_n \rightarrow 0$ p.n., bo zmienne obcięte mają wystarczająco dobre wariancje.
3. $III_n \rightarrow 0$, bo $\mathbb{E}X'_n \rightarrow \mathbb{E}X_1$ z twierdzenia Lebesgue'a o zbieżności zmajoryzowanej.

Intuicja. Obcinanie to matematyczna wersja zdania: ekstremalne obserwacje mogą się zdarzyć, ale jeśli zmienna ma skończoną wartość oczekiwaną, to nie pojawiają się na tyle często i mocno, aby zepsuć średnią w granicy.

7.8 Co jeśli zmienna nie jest całkowalna?

Warunek $\mathbb{E}|X_1| < \infty$ nie jest tylko technicznym kaprysem. Jeśli zmienna nie jest całkowalna, średnie mogą się nie stabilizować.

Uwaga. Wartość oczekiwana jest punktem, do którego ma dążyć średnia. Jeśli $\mathbb{E}|X| = \infty$, to średnia teoretyczna nie jest dobrze kontrolowana. Wtedy pojedyncze ogromne obserwacje mogą dominować sumę nawet dla bardzo dużych n .

7.9 Dystrybuanta empiryczna

Prawa wielkich liczb można stosować nie tylko do zwykłych średnich. Bardzo ważnym przykładem jest dystrybuanta empiryczna.

Załóżmy, że $X_1, X_2, \dots$ są niezależne i mają ten sam rozkład z dystrybuantą F .

Definicja 7.2: Dystrybuanta empiryczna. n -tą dystrybuantą empiryczną nazywamy funkcję

$$F_n(t) = \frac{\mathbf{1}_{\{X_1 \leq t\}} + \mathbf{1}_{\{X_2 \leq t\}} + \cdots + \mathbf{1}_{\{X_n \leq t\}}}{n}.$$

Dla ustalonego t zmienna $\mathbf{1}_{\{X_i \leq t\}}$ przyjmuje wartość 1, jeśli obserwacja X_i jest nie większa niż t , oraz 0 w przeciwnym razie. Zatem

$$F_n(t) = \frac{\text{liczba obserwacji nie większych niż } t}{n}.$$

Przykład 7.3: Dystrybuenta empiryczna z danych. Załóżmy, że mamy dane:

$$2.1, \quad 0.7, \quad 1.4, \quad 3.0, \quad 1.2.$$

Dla $t = 1.5$ obserwacje nie większe niż 1.5 to 0.7, 1.4, 1.2. Są trzy takie obserwacje z pięciu, więc

$$F_5(1.5) = \frac{3}{5}.$$

Dla ustalonego t z MPWL dostajemy:

$$F_n(t) \rightarrow F(t)$$

prawie na pewno, ponieważ

$$\mathbb{E}\mathbf{1}_{\{X_1 \leq t\}} = \mathbb{P}(X_1 \leq t) = F(t).$$

Twierdzenie 7.4: Twierdzenie Gliwienki-Cantellego. Jeśli $X_1, X_2, \dots$ są niezależne i mają ten sam rozkład z dystrybuentą F , a F_n jest dystrybuentą empiryczną, to

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \rightarrow 0$$

prawie na pewno.

Intuicja. Dla jednego ustalonego progu t prawo wielkich liczb mówi, że częstość obserwacji poniżej t dąży do prawdopodobieństwa $\mathbb{P}(X \leq t)$. Twierdzenie Gliwienki-Cantellego mówi dużo więcej: cała funkcja F_n zbliża się do F jednostajnie.

7.10 Jak rozpoznawać zadania z praw wielkich liczb?

Ważne. Jeśli widzisz wyrażenie

$$\frac{X_1 + \dots + X_n}{n}$$

i zmienne są niezależne oraz identycznie rozłożone, to od razu myśl o MPWL:

$$\frac{X_1 + \dots + X_n}{n} \rightarrow \mathbb{E}X_1$$

prawie na pewno, o ile $\mathbb{E}|X_1| < \infty$.

Ważne. Jeśli masz zdarzenia A_i i liczysz częstość ich zajścia, zapisz

$$X_i = \mathbf{1}_{A_i}.$$

Wtedy

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i}$$

to częstość zdarzeń, a $\mathbb{E}\mathbf{1}_{A_i} = \mathbb{P}(A_i)$. Dla niezależnych prób o tym samym prawdopodobieństwie p dostajesz zbieżność częstości do p .

Ważne. Jeśli zadanie prosi o zbieżność według prawdopodobieństwa, często wystarczy pokazać:

$$\text{Var}(\bar{X}_n) \rightarrow 0.$$

Potem stosujesz Czebyszewa:

$$\mathbb{P}(|\bar{X}_n - \mathbb{E}\bar{X}_n| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2}.$$

7.11 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Zadanie 1. Rzucamy uczciwą monetą niezależnie nieskończenie wiele razy. Niech S_n oznacza liczbę orłów w pierwszych n rzutach. Pokaż, że

$$\frac{S_n}{n} \rightarrow \frac{1}{2}$$

prawie na pewno.

Rozwiązanie. Definiujemy

$$X_i = \begin{cases} 1, & \text{jeśli w } i\text{-tym rzucie wypadł orzeł,} \\ 0, & \text{jeśli w } i\text{-tym rzucie wypadła reszka.} \end{cases}$$

Wtedy zmienne X_i są niezależne i mają ten sam rozkład. Ponadto $\mathbb{E}X_i = 1/2$ oraz $S_n = X_1 + \dots + X_n$. Z mocnego prawa wielkich liczb:

$$\frac{S_n}{n} = \frac{X_1 + \dots + X_n}{n} \rightarrow \mathbb{E}X_1 = \frac{1}{2}$$

prawie na pewno.

Zadanie z rozwiązaniem. Zadanie 2. Niech $X_1, X_2, \dots$ będą niezależne i mają rozkład wykładniczy z parametrem $\lambda > 0$. Wyznacz granicę

$$\frac{X_1 + \dots + X_n}{n}.$$

Rozwiązanie. Dla rozkładu wykładniczego z parametrem λ mamy

$$\mathbb{E}X_1 = \frac{1}{\lambda}.$$

Ponieważ zmienne są niezależne i identycznie rozłożone oraz $\mathbb{E}|X_1| < \infty$, z MPWL:

$$\frac{X_1 + \dots + X_n}{n} \rightarrow \frac{1}{\lambda}$$

prawie na pewno.

Zadanie z rozwiązaniem. Zadanie 3. Niech $X_1, X_2, \dots$ będą nieskorelowane, całkowalne z kwadratem i niech $\text{Var}(X_i) \leq 7$ dla każdego i . Pokaż, że

$$\frac{X_1 + \dots + X_n - \mathbb{E}(X_1 + \dots + X_n)}{n} \xrightarrow{\mathbb{P}} 0.$$

Rozwiązanie. Oznaczamy $S_n = X_1 + \dots + X_n$. Ponieważ zmienne są nieskorelowane,

$$\text{Var}(S_n) = \sum_{i=1}^n \text{Var}(X_i) \leq 7n.$$

Zatem

$$\text{Var}\left(\frac{S_n - \mathbb{E}S_n}{n}\right) = \frac{1}{n^2} \text{Var}(S_n) \leq \frac{7}{n}.$$

Z nierówności Czebyszewa dla każdego $\varepsilon > 0$:

$$\mathbb{P}\left(\left|\frac{S_n - \mathbb{E}S_n}{n}\right| > \varepsilon\right) \leq \frac{7}{n\varepsilon^2} \rightarrow 0.$$

To oznacza zbieżność według prawdopodobieństwa.

Zadanie z rozwiązaniem. Zadanie 4. Niech $A_1, A_2, \dots$ będą niezależnymi zdarzeniami o tym samym prawdopodobieństwie p . Pokaż, że częstość zajścia tych zdarzeń dąży do p prawie na pewno.

Rozwiązanie. Wprowadzamy zmienne wskaźnikowe $X_i = \mathbf{1}_{A_i}$. Wtedy

$$\frac{X_1 + \dots + X_n}{n}$$

to częstość zajścia zdarzeń $A_1, \dots, A_n$. Ponieważ zdarzenia są niezależne, zmienne X_i są niezależne. Ponieważ $\mathbb{P}(A_i) = p$, mamy

$$\mathbb{E}X_i = \mathbb{E}\mathbf{1}_{A_i} = \mathbb{P}(A_i) = p.$$

Z MPWL:

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i} \rightarrow p$$

prawie na pewno.

7.12 Najczęstsze błędy

Uwaga. SPWL daje zbieżność według prawdopodobieństwa:

$$\overline{X}_n \xrightarrow{\mathbb{P}} m.$$

MPWL daje zbieżność prawie na pewno:

$$\overline{X}_n \rightarrow m \quad p.n.$$

Druga zbieżność jest silniejsza.

Uwaga. W standardowym MPWL zakładamy niezależność zmiennych. Bez niezależności średnia może zachowywać się zupełnie inaczej.

Uwaga. Warunek $\mathbb{E}|X_1| < \infty$ jest kluczowy. Jeżeli zmienna ma bardzo ciężki ogon i nie jest całkowalna, pojedyncze ogromne wartości mogą psuć średnią.

Uwaga. Prawo wielkich liczb mówi o średniej z wielu obserwacji, a nie o tym, jaka wartość pojawia się najczęściej w pojedynczym losowaniu.

Podsumowanie.

1. Średnia empiryczna:

$$\overline{X}_n = \frac{X_1 + \dots + X_n}{n}.$$

2. Słabe prawo wielkich liczb mówi o zbieżności według prawdopodobieństwa.

3. Jeśli zmienne są nieskorelowane i mają wspólnie ograniczoną wariancję, to

$$\frac{X_1 + \cdots + X_n - \mathbb{E}(X_1 + \cdots + X_n)}{n} \xrightarrow{\mathbb{P}} 0.$$

4. Jeśli wszystkie mają tę samą wartość oczekiwaną m , to

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{\mathbb{P}} m.$$

5. Mocne prawo wielkich liczb mówi, że dla niezależnych identycznie rozłożonych zmiennych całkowalnych:

$$\frac{X_1 + \cdots + X_n}{n} \rightarrow \mathbb{E}X_1$$

prawie na pewno.

6. Dla częstości sukcesów w próbach Bernoulliego:

$$\frac{S_n}{n} \rightarrow p$$

prawie na pewno.

7. Nierówność Kołmogorowa kontroluje maksimum sum częściowych:

$$\mathbb{P} \left(\max_{1 \leq k \leq n} |S_k| \geq \alpha \right) \leq \frac{\text{Var}(S_n)}{\alpha^2}.$$

8. Dystrybuenta empiryczna:

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq t\}}.$$

9. Twierdzenie Gliwienki-Cantellego mówi, że

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \rightarrow 0$$

prawie na pewno.

10. Najważniejsza intuicja: średnia z dużej liczby niezależnych obserwacji stabilizuje się wokół wartości oczekiwanej.

8. Twierdzenie de Moivre’a-Laplace’a i przybliżenie normalne

8.1 Mapa tematu

W poprzednim rozdziale prawa wielkich liczb mówiły nam, że częstość sukcesów stabilizuje się wokół prawdopodobieństwa sukcesu. Jeżeli

$$S_n = X_1 + \cdots + X_n,$$

gdzie X_i oznacza wynik i -tej próby Bernoulliego, to

$$\frac{S_n}{n} \rightarrow p.$$

To odpowiada na pytanie: *gdzie mniej więcej znajduje się liczba sukcesów?*

Teraz chcemy zadać pytanie dokładniejsze:

Jak duże są typowe odchylenia liczby sukcesów od średniej np ?

Okazuje się, że po odpowiednim przeskalowaniu rozkład dwumianowy zaczyna wyglądać jak rozkład normalny. To właśnie opisuje twierdzenie de Moivre’a-Laplace’a.

Intuicja. Jeśli rzucamy monetą 10 razy, liczba orłów może dość mocno skakać. Jeśli rzucamy monetą 10000 razy, liczba orłów jest zwykle blisko 5000, ale nie dokładnie równa 5000. Typowe odchylenie nie jest rzędu n , tylko rzędu $\sqrt{n}$.

Dlatego zamiast patrzeć na

$$S_n - np,$$

patrzymy na zmienną wystandaryzowaną:

$$\frac{S_n - np}{\sqrt{npq}}, \quad q = 1 - p.$$

Po takim przeskalowaniu dostajemy obiekt, który dla dużego n zachowuje się jak zmienna normalna $N(0, 1)$.

8.2 Przypomnienie: rozkład Bernoulliego i rozkład dwumianowy

Definicja 8.1: Próba Bernoulliego. Próba Bernoulliego nazywamy doświadczenie, w którym są tylko dwa wyniki:

sukces albo porażka.

Jeśli prawdopodobieństwo sukcesu wynosi p , to prawdopodobieństwo porażki wynosi

$$q = 1 - p.$$

Zmienna losowa opisująca pojedynczą próbę ma postać

$$X = \begin{cases} 1, & \text{gdy zaszedł sukces,} \\ 0, & \text{gdy zaszła porażka.} \end{cases}$$

Wtedy

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = q.$$

Definicja 8.2: Rozkład dwumianowy. Niech $X_1, \dots, X_n$ będą niezależnymi zmiennymi Bernoulliego z tym samym prawdopodobieństwem sukcesu p . Wtedy

$$S_n = X_1 + \dots + X_n$$

oznacza liczbę sukcesów w n próbach. Mówimy, że S_n ma rozkład dwumianowy z parametrami n, p i piszemy

$$S_n \sim B(n, p).$$

Dla $k = 0, 1, \dots, n$ mamy

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k q^{n-k}.$$

Przykład 8.1: Rzuty monetą. Rzucamy symetryczną monetą 100 razy. Niech S_{100} oznacza liczbę orłów. Wtedy

$$S_{100} \sim B\left(100, \frac{1}{2}\right).$$

Na przykład

$$\mathbb{P}(S_{100} = 50) = \binom{100}{50} \left(\frac{1}{2}\right)^{100}.$$

To jest dokładna odpowiedź, ale rachunkowo niezbyt wygodna. Twierdzenie de Moivre'a-Laplace'a pozwoli nam przybliżać takie liczby wzorami z rozkładu normalnego.

8.3 Dlaczego pojawia się rozkład normalny?

W rozkładzie dwumianowym mamy dwa najważniejsze parametry:

$$\mathbb{E}S_n = np,$$

$$\text{Var}(S_n) = npq.$$

Odchylenie standardowe wynosi więc

$$\sigma_n = \sqrt{npq}.$$


To oznacza, że naturalną skalą odchyłeń od średniej jest $\sqrt{npq}$, a nie npq ani n .

Ważne. Jeżeli chcemy porównywać różne rozkłady dwumianowe z rozkładem normalnym $N(0, 1)$, musimy odjąć średnią i podzielić przez odchylenie standardowe:

$$Z_n = \frac{S_n - np}{\sqrt{npq}}.$$

To jest dokładnie taki sam zabieg jak przy dowolnej zmiennej losowej:

$$Z = \frac{X - \mathbb{E}X}{\sqrt{\text{Var}(X)}}.$$



Słupki rozkładu dwumianowego, po standaryzacji, układają się coraz bardziej jak krzywa normalna.

8.4 Lokalne twierdzenie de Moivre'a-Laplace'a

Najpierw patrzymy na prawdopodobieństwo dokładnie jednej wartości:

$$\mathbb{P}(S_n = k).$$

To jest wersja lokalna, bo pytamy o jeden punkt k .

Twierdzenie 8.1: Lokalne twierdzenie de Moivre'a-Laplace'a – wersja intuicyjna. Niech

$$S_n \sim B(n, p), \quad q = 1 - p.$$

Jeżeli n jest duże, a k leży niedaleko średniej np , to

$$\mathbb{P}(S_n = k) \approx \frac{1}{\sqrt{npq}} g\left(\frac{k - np}{\sqrt{npq}}\right),$$

gdzie

$$g(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

jest gęstością standardowego rozkładu normalnego.

Po podstawieniu g do wzoru dostajemy równoważny zapis:

$$\mathbb{P}(S_n = k) \approx \frac{1}{\sqrt{2\pi npq}} \exp\left(-\frac{(k - np)^2}{2npq}\right).$$

Intuicja. Ten wzór mówi, że masa punktowa rozkładu dwumianowego w punkcie k jest w przybliżeniu równa:

wysokość krzywej normalnej w odpowiednim punkcie $\times$ szerokość jednego słupka.

Po standaryzacji szerokość jednego słupka to mniej więcej

$$\frac{1}{\sqrt{npq}}.$$

Przykład 8.2: Przybliżenie prawdopodobieństwa dokładnie 50 orłów. Rzucamy symetryczną monetą 100 razy. Niech S_{100} oznacza liczbę orłów. Chcemy przybliżyć

$$\mathbb{P}(S_{100} = 50).$$

Mamy

$$n = 100, \quad p = q = \frac{1}{2}, \quad np = 50, \quad npq = 25.$$

Zatem

$$\frac{k - np}{\sqrt{npq}} = \frac{50 - 50}{5} = 0.$$

Korzystamy z lokalnego przybliżenia:

$$\mathbb{P}(S_{100} = 50) \approx \frac{1}{\sqrt{npq}} g(0) = \frac{1}{5} \cdot \frac{1}{\sqrt{2\pi}}.$$

Czyli

$$\mathbb{P}(S_{100} = 50) \approx \frac{1}{5\sqrt{2\pi}} \approx 0,0798.$$

Dokładna wartość jest bardzo bliska tej liczbie.

8.5 Integralne twierdzenie de Moivre'a-Laplace'a

W praktyce dużo częściej pytamy nie o dokładnie jedną wartość, ale o przedział:

$$\mathbb{P}(a \leq S_n \leq b).$$

Na przykład:

- jaka jest szansa, że w 1000 rzutach monetą liczba orłów będzie między 480 a 520?
- jaka jest szansa, że wśród 10000 noworodków liczba chłopców nie przekroczy liczby dziewcząt?
- jaka jest szansa, że liczba wadliwych produktów będzie większa niż ustalony limit?

Twierdzenie 8.2: Integralne twierdzenie de Moivre'a-Laplace'a – wersja użytkowa.

Niech

$$S_n \sim B(n, p), \quad q = 1 - p.$$

Dla dużego n mamy przybliżenie

$$\mathbb{P}(a \leq S_n \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - np}{\sqrt{npq}}\right) - \Phi\left(\frac{a - \frac{1}{2} - np}{\sqrt{npq}}\right),$$

gdzie Φ jest dystrybucją standardowego rozkładu normalnego $N(0, 1)$.

Ważne. We wzorze pojawiają się liczby


$$a - \frac{1}{2} \quad \text{oraz} \quad b + \frac{1}{2}.$$

To jest tak zwana *poprawka ciągłości*.

Dlaczego? Bo S_n jest zmienną dyskretną i przyjmuje wartości całkowite, a rozkład normalny jest ciągły. Punkt k w rozkładzie dyskretnym odpowiada mniej więcej przedziałowi

$$\left[k - \frac{1}{2}, k + \frac{1}{2}\right]$$

w rozkładzie ciągłym.



8.6 Jak używać twierdzenia w zadaniach?

Ważne. Jeżeli w zadaniu pojawia się liczba sukcesów w dużej liczbie prób, najczęściej robimy tak:

1. Rozpoznajemy, że

$$S_n \sim B(n, p).$$

2. Obliczamy

$$np, \quad npq, \quad \sqrt{npq}.$$

3. Zamieniamy warunek na S_n na przedział.

4. Dodajemy poprawkę ciągłości.

5. Standaryzujemy:

$$z = \frac{x - np}{\sqrt{npq}}.$$

6. Wynik zapisujemy przez dystrybuantę Φ .

Przykład 8.3: Od 480 do 520 orłów w 1000 rzutach. Rzucamy symetryczną monetą 1000 razy. Przybliżymy prawdopodobieństwo

$$\mathbb{P}(480 \leq S_{1000} \leq 520).$$

Mamy

$$n = 1000, \quad p = q = \frac{1}{2},$$

więc

$$np = 500, \quad npq = 250, \quad \sqrt{npq} = \sqrt{250} = 5\sqrt{10}.$$

Stosujemy poprawkę ciągłości:

$$480 \leq S_{1000} \leq 520$$

zastępujemy przez

$$479,5 \leq Y \leq 520,5,$$

gdzie Y ma w przybliżeniu rozkład normalny $N(500, 250)$.

Standaryzujemy końce przedziału:

$$z_1 = \frac{479,5 - 500}{\sqrt{250}} = \frac{-20,5}{\sqrt{250}} \approx -1,296,$$

$$z_2 = \frac{520,5 - 500}{\sqrt{250}} = \frac{20,5}{\sqrt{250}} \approx 1,296.$$

Zatem

$$\mathbb{P}(480 \leq S_{1000} \leq 520) \approx \Phi(1,296) - \Phi(-1,296).$$

Ponieważ rozkład normalny jest symetryczny,

$$\Phi(-x) = 1 - \Phi(x),$$

więc

$$\Phi(1,296) - \Phi(-1,296) = 2\Phi(1,296) - 1.$$

8.7 Przykłady z pełnym rozwiązaniem

Zadanie z rozwiązaniem. Prawdopodobieństwo urodzenia chłopca wynosi 0,517. Jakie jest przybliżone prawdopodobieństwo, że wśród 10000 noworodków liczba chłopców nie przewyższy liczby dziewcząt?

Rozwiązanie. Niech S oznacza liczbę chłopców wśród 10000 noworodków. Wtedy

$$S \sim B(10000, 0,517).$$

Mamy

$$p = 0,517, \quad q = 0,483,$$

$$np = 10000 \cdot 0,517 = 5170,$$

$$npq = 10000 \cdot 0,517 \cdot 0,483 \approx 2497,11.$$

Zdarzenie „liczba chłopców nie przewyższy liczby dziewcząt” oznacza

$$S \leq 5000.$$

Z poprawką ciągłości:

$$\mathbb{P}(S \leq 5000) \approx \Phi\left(\frac{5000,5 - 5170}{\sqrt{2497,11}}\right).$$

Liczymy

$$\sqrt{2497,11} \approx 49,97,$$

$$\frac{5000,5 - 5170}{49,97} \approx -3,39.$$

Zatem

$$\mathbb{P}(S \leq 5000) \approx \Phi(-3,39).$$

To jest bardzo mała liczba, około

$$0,00035.$$

Czyli przy tych parametrach jest bardzo mało prawdopodobne, że chłopców będzie nie więcej niż dziewczynek.

Zadanie z rozwiązaniem. Rzucamy 4500 razy kostką, dla której prawdopodobieństwo wypadnięcia szóstki wynosi $1/6$. Obliczyć przybliżone prawdopodobieństwo, że liczba wyrzuconych szóstek przekroczy 450.

Rozwiązanie. Niech S oznacza liczbę wyrzuconych szóstek. Wtedy

$$S \sim B\left(4500, \frac{1}{6}\right).$$

Mamy

$$p = \frac{1}{6}, \quad q = \frac{5}{6}.$$

Stąd

$$\begin{aligned}np &= 4500 \cdot \frac{1}{6} = 750, \\npq &= 4500 \cdot \frac{1}{6} \cdot \frac{5}{6} = 625, \\ \sqrt{npq} &= 25.\end{aligned}$$

Szukamy

$$\mathbb{P}(S > 450) = \mathbb{P}(S \geq 451).$$

Z poprawką ciągłości:

$$\mathbb{P}(S \geq 451) \approx \mathbb{P}(Y \geq 450,5),$$

gdzie $Y \sim N(750, 625)$. Standaryzujemy:

$$z = \frac{450,5 - 750}{25} = \frac{-299,5}{25} = -11,98.$$

Zatem

$$\mathbb{P}(S > 450) \approx 1 - \Phi(-11,98).$$

Ponieważ $-11,98$ jest ekstremalnie daleko w lewo,

$$\Phi(-11,98) \approx 0,$$

więc

$$\mathbb{P}(S > 450) \approx 1.$$

To ma sens: oczekiwana liczba szóstek to 750, więc próg 450 leży bardzo daleko poniżej średniej.

Zadanie z rozwiązaniem. W pewnym doświadczeniu prawdopodobieństwo zajścia zdarzenia A wynosi 0,7. Ile razy trzeba powtórzyć doświadczenie, aby z prawdopodobieństwem około 0,9 częstość zajścia A różniła się od 0,7 o nie więcej niż 0,1?

Rozwiązanie. Niech S_n oznacza liczbę zajść zdarzenia A w n niezależnych powtórzeniach. Wtedy

$$S_n \sim B(n, 0,7).$$

Częstość zajścia zdarzenia to

$$\frac{S_n}{n}.$$

Chcemy, żeby

$$\mathbb{P}\left(\left|\frac{S_n}{n} - 0,7\right| \leq 0,1\right) \approx 0,9.$$

Przekształcamy nierówność:

$$\left|\frac{S_n}{n} - 0,7\right| \leq 0,1$$

to znaczy

$$0,6 \leq \frac{S_n}{n} \leq 0,8,$$

czyli

$$0,6n \leq S_n \leq 0,8n.$$

Średnia wynosi

$$np = 0,7n,$$

a odchylenie standardowe

$$\sqrt{npq} = \sqrt{n \cdot 0,7 \cdot 0,3} = \sqrt{0,21n}.$$

Interesujący nas przedział jest symetryczny względem średniej:

$$0,7n - 0,1n \leq S_n \leq 0,7n + 0,1n.$$

Po standaryzacji dostajemy mniej więcej

$$\mathbb{P}\left(|Z| \leq \frac{0,1n}{\sqrt{0,21n}}\right) = \mathbb{P}\left(|Z| \leq \frac{0,1\sqrt{n}}{\sqrt{0,21}}\right),$$

gdzie $Z \sim N(0, 1)$. Chcemy, aby to było około 0,9. Dla rozkładu normalnego

$$\mathbb{P}(|Z| \leq 1,645) \approx 0,9.$$

Zatem wymagamy

$$\frac{0,1\sqrt{n}}{\sqrt{0,21}} \approx 1,645.$$

Stąd

$$\sqrt{n} \approx \frac{1,645\sqrt{0,21}}{0,1}.$$

Ponieważ

$$\sqrt{0,21} \approx 0,458,$$

otrzymujemy

$$\sqrt{n} \approx \frac{1,645 \cdot 0,458}{0,1} \approx 7,53,$$

więc

$$n \approx 56,7.$$

Odpowiedź: potrzeba około

$$57$$

powtórzeń.

8.8 Kiedy przybliżenie normalne działa dobrze?

Ważne. Przybliżenie normalne dla rozkładu $B(n, p)$ zwykle jest sensowne, gdy

$$np \quad \text{ i } \quad nq$$

są dość duże. W praktycznych zadaniach często używa się luźnej reguły:

$$np \geq 5 \quad \text{ oraz } \quad nq \geq 5,$$

a czasem bardziej ostrożnie:

$$np \geq 10 \quad \text{ oraz } \quad nq \geq 10.$$

Jeżeli p jest bardzo małe, a n duże, to czasem lepsze jest przybliżenie Poissona:

$$B(n, p) \approx \text{Pois}(np).$$

Uwaga. Jeżeli p jest bardzo małe i np też nie jest duże, rozkład dwumianowy jest mocno asymetryczny. Wtedy rozkład normalny może dawać słabe przybliżenie, a czasem nawet absurdalne wartości, na przykład dodatnią szansę na ujemną liczbę sukcesów.

Uwaga. Dla zdarzenia

$$\mathbb{P}(a \leq S_n \leq b)$$

nie podstawiamy po prostu a i b . Lepsze przybliżenie daje

$$a - \frac{1}{2}, \quad b + \frac{1}{2}.$$

Poprawka ciągłości bywa szczególnie ważna, gdy n nie jest bardzo duże.

Uwaga. Dla $S_n \sim B(n, p)$ mamy

$$\text{Var}(S_n) = npq,$$

ale w mianowniku standaryzacji stoi odchylenie standardowe:

$$\sqrt{npq}.$$

Nie wolno dzielić przez npq .

8.9 Związek z centralnym twierdzeniem granicznym

Twierdzenie de Moivre'a-Laplace'a jest szczególnym przypadkiem dużo ogólniejszej zasady: sumy wielu niezależnych drobnych składników często mają rozkład zbliżony do normalnego.

W naszym przypadku składnikami są zmienne Bernoulliego:

$$X_i \in \{0, 1\}.$$

Ich suma to

$$S_n = X_1 + \dots + X_n.$$

Po odjęciu średniej i podzieleniu przez odchylenie standardowe dostajemy

$$\frac{S_n - np}{\sqrt{npq}}.$$

Twierdzenie de Moivre'a-Laplace'a mówi, że ta zmienna ma w granicy rozkład standardowy normalny:

$$\frac{S_n - np}{\sqrt{npq}} \xrightarrow{d} N(0, 1).$$

Intuicja. Rozkład normalny pojawia się dlatego, że suma składa się z wielu małych, niezależnych losowych wkładów. Pojedyncza próba Bernoulliego jest bardzo prosta i skokowa, ale suma wielu takich prób, po odpowiednim przeskalowaniu, wygładza się i zaczyna przypominać dzwon Gaussa.

8.10 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Rzucamy symetryczną monetą 1000 razy. Przybliżyć prawdopodobieństwo, że wypadnie co najmniej 520 orłów.

Rozwiązanie. Niech $S \sim B(1000, 1/2)$. Mamy

$$np = 500, \quad npq = 250, \quad \sqrt{npq} = \sqrt{250}.$$

Szukamy

$$\mathbb{P}(S \geq 520).$$

Z poprawką ciągłości:

$$\mathbb{P}(S \geq 520) \approx \mathbb{P}(Y \geq 519,5),$$

gdzie $Y \sim N(500, 250)$. Standaryzujemy:

$$z = \frac{519,5 - 500}{\sqrt{250}} \approx \frac{19,5}{15,81} \approx 1,23.$$

Zatem

$$\mathbb{P}(S \geq 520) \approx 1 - \Phi(1,23).$$

Zadanie z rozwiązaniem. Niech $S_n \sim B(n, p)$. Wyjaśnij intuicyjnie, dlaczego przedział

$$np - 3\sqrt{npq} \leq S_n \leq np + 3\sqrt{npq}$$

ma dla dużego n prawdopodobieństwo około 0,997.

Rozwiązanie. Standaryzujemy:

$$Z_n = \frac{S_n - np}{\sqrt{npq}}.$$

Warunek

$$np - 3\sqrt{npq} \leq S_n \leq np + 3\sqrt{npq}$$

jest równoważny

$$-3 \leq Z_n \leq 3.$$

Z twierdzenia de Moivre'a-Laplace'a

$$Z_n \xrightarrow{d} N(0, 1).$$

Zatem dla dużych n

$$\mathbb{P}(-3 \leq Z_n \leq 3) \approx \Phi(3) - \Phi(-3).$$

Dla standardowego rozkładu normalnego ta liczba wynosi około

$$0,997.$$

To jest znana reguła trzech sigm.

8.11 Miniściąga

Podsumowanie.

1. Jeśli $S_n \sim B(n, p)$, to

$$\mathbb{E}S_n = np, \quad \text{Var}(S_n) = npq, \quad q = 1 - p.$$

2. Naturalna standaryzacja to

$$Z_n = \frac{S_n - np}{\sqrt{npq}}.$$

3. Dla dużego n :

$$Z_n \approx N(0, 1).$$

4. Lokalne przybliżenie:

$$\mathbb{P}(S_n = k) \approx \frac{1}{\sqrt{npq}} g\left(\frac{k - np}{\sqrt{npq}}\right).$$

5. Integralne przybliżenie:

$$\mathbb{P}(a \leq S_n \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - np}{\sqrt{npq}}\right) - \Phi\left(\frac{a - \frac{1}{2} - np}{\sqrt{npq}}\right).$$

6. Poprawka ciągłości:

$$a \mapsto a - \frac{1}{2}, \quad b \mapsto b + \frac{1}{2}.$$

7. Przybliżenie normalne działa najlepiej, gdy np i nq są duże.

8. Gdy p jest bardzo małe, warto rozważyć przybliżenie Poissona.

9. Twierdzenie de Moivre'a-Laplace'a jest specjalnym przypadkiem centralnego twierdzenia granicznego.

10. Najważniejsza intuicja: rozkład liczby sukcesów, po przesunięciu o średnią i przeskalowaniu przez odchylenie standardowe, robi się dzwonowaty.

9. Warunkowa wartość oczekiwana

9.1 Mapa tematu

Do tej pory warunkowanie wyglądało dość prosto. Jeśli znaliśmy zdarzenie B i chcieliśmy policzyć prawdopodobieństwo zdarzenia A pod warunkiem B , pisaliśmy

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

To działa świetnie, gdy warunkujemy po jednym zdarzeniu o dodatnim prawdopodobieństwie.

Teraz pojawia się naturalne pytanie: co zrobić, gdy informacja, którą dostajemy, nie jest jednym zdarzeniem, tylko całą zmienną losową albo całym zbiorem obserwacji?

Na przykład:

- znamy wynik pierwszego rzutu kostką i chcemy przewidzieć sumę dwóch rzutów;
- znamy liczbę zgłoszeń w sklepie i chcemy przewidzieć liczbę reklamacji;
- znamy zmienną Y i chcemy najlepsze przybliżenie zmiennej X na podstawie tej wiedzy;
- znamy wszystkie informacje z pewnego eksperymentu, ale nie znamy pełnego wyniku.

Warunkowa wartość oczekiwana odpowiada na pytanie:

Jaka jest średnia wartość zmiennej X , gdy mamy daną pewną informację?

Intuicja. Najprostsza intuicja jest taka: $\mathbb{E}(X | Y)$ to nowa zmienna losowa, która dla każdej obserwowanej wartości Y podaje najlepszą prognozę wartości X . Nie musi zgadywać dokładnie X . Ma tylko używać informacji zawartej w Y .

9.2 Najpierw przykład bez formalizmu

Przykład 9.1: Dwie kostki i informacja o pierwszej. Rzucamy dwiema uczciwymi kostkami. Niech

X = suma oczek z obu kostek, Y = wynik pierwszej kostki.

Chcemy zrozumieć $\mathbb{E}(X | Y)$.

Jeżeli wiemy, że $Y = 1$, to pierwsza kostka dała 1, a druga ma średnio

$$\frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3,5.$$

Zatem

$$\mathbb{E}(X | Y = 1) = 1 + 3,5 = 4,5.$$

Jeżeli wiemy, że $Y = 4$, to

$$\mathbb{E}(X | Y = 4) = 4 + 3,5 = 7,5.$$


Ogólnie, jeśli $Y = y$, to

$$\mathbb{E}(X | Y = y) = y + 3,5.$$

Czyli jako zmienna losowa

$$\mathbb{E}(X | Y) = Y + 3,5.$$

Ważne. Zwróć uwagę na bardzo ważną rzecz: $\mathbb{E}(X | Y)$ nie jest jedną liczbą. To jest zmienna losowa zależna od Y . Dopiero po zobaczeniu wartości Y dostajemy konkretną liczbę.



9.3 Warunkowanie względem skończonego podziału

Zanim przejdziemy do formalnej definicji przez σ -ciała, zobaczmy najprostszy model. Załóżmy, że przestrzeń wyników jest podzielona na kilka rozłącznych przypadków:

$$B_1, B_2, \dots, B_m,$$

gdzie

$$B_i \cap B_j = \emptyset \quad (i \neq j), \quad B_1 \cup \dots \cup B_m = \Omega, \quad \mathbb{P}(B_i) > 0.$$


Jeżeli wiemy tylko, który z bloków B_i zaszedł, to najlepszą prognozą X na bloku B_i jest średnia warunkowa

$$\mathbb{E}(X | B_i) = \frac{\mathbb{E}(X \mathbf{1}_{B_i})}{\mathbb{P}(B_i)}.$$

Definicja 9.1: Warunkowa wartość oczekiwana względem skończonego podziału. Niech $B_1, \dots, B_m$ będzie skończonym podziałem Ω na zdarzenia o dodatnim prawdopodobieństwie. Warunkową wartością oczekiwaną zmiennej całkowalnej X względem tego podziału nazywamy zmienną

$$\mathbb{E}(X | B_1, \dots, B_m) = \sum_{i=1}^m \mathbb{E}(X | B_i) \mathbf{1}_{B_i}.$$

Intuicja. To jest funkcja schodkowa. Na każdym kawałku podziału przyjmuje jedną wartość: średnią X w tym kawałku. Czyli zamiast znać pełny wynik ω , znamy tylko numer pudełka, do którego ω wpadł.



9.4 Czym jest informacja w probabilistyce?

W rachunku prawdopodobieństwa informację opisuje się za pomocą σ -ciała. To brzmi abstrakcyjnie, ale idea jest dość prosta.

Intuicja. σ -ciało $\mathcal{G}$ to lista pytań, na które umiemy odpowiedzieć na podstawie dostępnej informacji. Jeśli zdarzenie A należy do $\mathcal{G}$, to po otrzymaniu tej informacji wiemy, czy A zaszło, czy nie.

Przykładowo, jeśli rzucamy dwiema kostkami i znamy tylko wynik pierwszej kostki Y , to znamy zdarzenia typu:

$$\{Y = 1\}, \quad \{Y \in \{2, 4, 6\}\}, \quad \{Y \leq 3\}.$$

Nie znamy natomiast zdarzenia:

$$\{\text{suma oczek wynosi } 10\},$$

bo do tego potrzebowalibyśmy także drugiej kostki.

Formalnie informację zawartą w zmiennej losowej Y opisuje σ -ciało

$$\sigma(Y),$$

czyli najmniejsze σ -ciało, względem którego Y jest mierzalna.

9.5 Formalna definicja

Definicja 9.2: Warunkowa wartość oczekiwana względem σ -ciała. Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną, niech $\mathcal{G} \subseteq \mathcal{F}$ będzie pod- σ -ciałem oraz niech X będzie zmienną losową całkowalną, czyli

$$\mathbb{E}|X| < \infty.$$

Warunkową wartością oczekiwaną X względem $\mathcal{G}$ nazywamy taką zmienną losową Z , że:

1. Z jest $\mathcal{G}$ -mierzalna, czyli zależy tylko od informacji zawartej w $\mathcal{G}$;
2. dla każdego $A \in \mathcal{G}$ zachodzi

$$\int_A Z \, d\mathbb{P} = \int_A X \, d\mathbb{P}.$$

Zmienną Z oznaczamy przez

$$Z = \mathbb{E}(X \mid \mathcal{G}).$$

Ważne. Ta definicja mówi dwie rzeczy naraz:

- $\mathbb{E}(X \mid \mathcal{G})$ wolno używać tylko informacji z $\mathcal{G}$;
- na każdym zdarzeniu widocznym w $\mathcal{G}$ ma ona dawać tę samą średnią masę co X .

Uwaga. Nie należy myśleć, że $\mathbb{E}(X \mid \mathcal{G})$ jest zwykłą liczbą. To jest zmienna losowa. Liczbą jest dopiero $\mathbb{E}(X \mid B)$, gdy warunkujemy po pojedynczym zdarzeniu B o dodatnim prawdopodobieństwie.

9.6 Jak czytać warunek całkowy?

Warunek

$$\int_A \mathbb{E}(X \mid \mathcal{G}) \, d\mathbb{P} = \int_A X \, d\mathbb{P} \quad \text{dla każdego } A \in \mathcal{G}$$

może na początku wyglądać dziwnie. Intuicyjnie oznacza:

Na każdym zdarzeniu, które umiemy rozróżnić, prognoza ma tę samą średnią co oryginalna zmienna.

Jeżeli $\mathcal{G}$ odpowiada podziałowi na $B_1, \dots, B_m$, to wystarczy sprawdzić bloki B_i . Na bloku B_i zmienna $\mathbb{E}(X \mid \mathcal{G})$ jest stała i równa średniej X po tym bloku.

Przykład 9.2: Powrót do podziału. Niech $\Omega = B_1 \cup B_2 \cup B_3$ i niech $\mathcal{G}$ rozróżnia tylko te trzy bloki. Wtedy

$$\mathbb{E}(X \mid \mathcal{G}) = m_1 \mathbf{1}_{B_1} + m_2 \mathbf{1}_{B_2} + m_3 \mathbf{1}_{B_3},$$

gdzie

$$m_i = \frac{\mathbb{E}(X \mathbf{1}_{B_i})}{\mathbb{P}(B_i)}.$$

Sprawdzamy warunek całkowity dla B_i :

$$\int_{B_i} \mathbb{E}(X \mid \mathcal{G}) d\mathbb{P} = \int_{B_i} m_i d\mathbb{P} = m_i \mathbb{P}(B_i) = \mathbb{E}(X \mathbf{1}_{B_i}) = \int_{B_i} X d\mathbb{P}.$$

9.7 Warunkowanie względem zmiennej losowej

Najczęściej nie piszemy $\mathbb{E}(X \mid \sigma(Y))$, tylko krócej:

$$\mathbb{E}(X \mid Y).$$

To oznacza:

$$\mathbb{E}(X \mid Y) := \mathbb{E}(X \mid \sigma(Y)).$$

Intuicja. $\mathbb{E}(X \mid Y)$ to najlepsza prognoza X , jeśli znamy wartość Y . Ponieważ prognoza może korzystać tylko z Y , musi być funkcją Y . Czyli zwykle istnieje funkcja g , taka że

$$\mathbb{E}(X \mid Y) = g(Y).$$

Twierdzenie 9.1: Lemat o faktoryzacji. Jeżeli zmienna losowa Z jest mierzalna względem $\sigma(Y)$, to istnieje funkcja borelowska g , taka że

$$Z = g(Y).$$

W szczególności

$$\mathbb{E}(X \mid Y) = g(Y)$$

dla pewnej funkcji g .

Nie zawsze łatwo znaleźć g , ale w typowych przykładach istnieją gotowe wzory.

9.8 Przypadek dyskretny

Założmy, że zmienne X, Y są dyskretne. Jeżeli znamy rozkład łączny, to możemy liczyć warunkową wartość oczekiwaną dokładnie tak, jak zwykłą średnią, ale z warunkowymi prawdopodobieństwami.

Twierdzenie 9.2: Wzór dyskretny. Jeżeli X przyjmuje wartości x_i , a Y przyjmuje wartości y_j , to dla tych y , dla których $\mathbb{P}(Y = y) > 0$, mamy

$$\mathbb{E}(X \mid Y = y) = \sum_i x_i \mathbb{P}(X = x_i \mid Y = y).$$

Stąd

$$\mathbb{E}(X \mid Y) = g(Y),$$

gdzie

$$g(y) = \sum_i x_i \mathbb{P}(X = x_i \mid Y = y).$$

Przykład 9.3: Tabela wspólnego rozkładu. Niech X, Y mają rozkład dany tabelą:

	$Y = 0$	$Y = 1$
$X = 0$	0,2	0,1
$X = 1$	0,3	0,4

Najpierw liczymy rozkład Y :

$$\mathbb{P}(Y = 0) = 0,2 + 0,3 = 0,5, \quad \mathbb{P}(Y = 1) = 0,1 + 0,4 = 0,5.$$

Dla $Y = 0$:

$$\mathbb{P}(X = 1 \mid Y = 0) = \frac{0,3}{0,5} = 0,6,$$

więc

$$\mathbb{E}(X \mid Y = 0) = 0 \cdot 0,4 + 1 \cdot 0,6 = 0,6.$$

Dla $Y = 1$:

$$\mathbb{P}(X = 1 \mid Y = 1) = \frac{0,4}{0,5} = 0,8,$$

więc

$$\mathbb{E}(X \mid Y = 1) = 0,8.$$

Ostatecznie

$$\mathbb{E}(X \mid Y) = 0,6\mathbf{1}_{\{Y=0\}} + 0,8\mathbf{1}_{\{Y=1\}}.$$

9.9 Przypadek ciągły i gęstość warunkowa

Jeżeli para (X, Y) ma gęstość łączną $f_{X,Y}(x, y)$, to najpierw wyznaczamy gęstość brzegową Y :

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx.$$

Dla takich y , że $f_Y(y) > 0$, gęstość warunkowa X przy danym $Y = y$ wynosi

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Wtedy

$$\mathbb{E}(X \mid Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx.$$

Twierdzenie 9.3: Wzór ciągły. Jeżeli para (X, Y) ma gęstość łączną $f_{X,Y}$, to

$$\mathbb{E}(X \mid Y) = g(Y),$$

gdzie

$$g(y) = \int_{\mathbb{R}} x \frac{f_{X,Y}(x, y)}{f_Y(y)} dx$$

dla $f_Y(y) > 0$.

Przykład 9.4: Rozkład jednostajny na trójkącie. Niech (X, Y) ma rozkład jednostajny na trójkącie

$$T = \{(x, y) : 0 < y < x < 1\}.$$

Pole trójkąta wynosi $1/2$, więc gęstość łączna wynosi

$$f_{X,Y}(x, y) = 2\mathbf{1}_{\{0 < y < x < 1\}}.$$

Wyznaczamy gęstość brzegową Y :

$$f_Y(y) = \int_y^1 2 dx = 2(1 - y), \quad 0 < y < 1.$$

Zatem dla $0 < y < 1$


$$f_{X|Y=y}(x) = \frac{2}{2(1-y)} = \frac{1}{1-y}, \quad y < x < 1.$$

Czyli przy ustalonym $Y = y$, zmienna X jest jednostajna na odcinku $(y, 1)$. Jej średnia to środek odcinka:

$$\mathbb{E}(X | Y = y) = \frac{y+1}{2}.$$

Stąd

$$\mathbb{E}(X | Y) = \frac{Y+1}{2}.$$



9.10 Najważniejsze własności

W praktyce warunkową wartość oczekiwaną liczymy nie tylko z definicji, ale głównie przez własności.

Twierdzenie 9.4: Podstawowe własności warunkowej wartości oczekiwanej. Niech X, Y będą całkowalne, a $\mathcal{G} \subseteq \mathcal{F}$ będzie pod- σ -ciałem. Wtedy:

1. Zachowanie średniej:

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G})) = \mathbb{E}X.$$

2. Liniowość:

$$\mathbb{E}(aX + bY | \mathcal{G}) = a\mathbb{E}(X | \mathcal{G}) + b\mathbb{E}(Y | \mathcal{G}).$$

3. Monotoniczność: jeśli $X \leq Y$ p.n., to

$$\mathbb{E}(X | \mathcal{G}) \leq \mathbb{E}(Y | \mathcal{G}) \quad \text{p.n.}$$

4. Jeśli X jest $\mathcal{G}$ -mierzalna, to

$$\mathbb{E}(X | \mathcal{G}) = X.$$

5. Jeśli X jest niezależna od $\mathcal{G}$, to

$$\mathbb{E}(X | \mathcal{G}) = \mathbb{E}X.$$

6. Jeśli Y jest $\mathcal{G}$ -mierzalna i XY jest całkowalna, to

$$\mathbb{E}(XY | \mathcal{G}) = Y\mathbb{E}(X | \mathcal{G}).$$

7. Własność wieży: jeśli $\mathcal{G}_1 \subseteq \mathcal{G}_2 \subseteq \mathcal{F}$, to

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}_2) | \mathcal{G}_1) = \mathbb{E}(X | \mathcal{G}_1).$$

9.10.1 Zachowanie średniej

Wzór

$$\mathbb{E}(\mathbb{E}(X \mid \mathcal{G})) = \mathbb{E}X$$

oznacza, że warunkowanie nie zmienia globalnej średniej. Ono tylko rozkłada średnią na kawałki zgodne z informacją.

Przykład 9.5: Średnia średnich. W klasie są dwie grupy. W pierwszej średnia punktów wynosi 70, w drugiej 85. Jeśli grupy mają po tyle samo osób, to ogólna średnia wynosi

$$\frac{70 + 85}{2} = 77,5.$$

Jeśli grupy mają różne rozmiary, to trzeba brać średnią ważoną. Dokładnie to samo robi wzór

$$\mathbb{E}(\mathbb{E}(X \mid \mathcal{G})) = \mathbb{E}X.$$

9.10.2 Jeśli coś już wiemy, to nie uśredniamy tego ponownie

Jeżeli X jest $\mathcal{G}$ -mierzalna, to znaczy, że informacja $\mathcal{G}$ już dokładnie zna X . Wtedy

$$\mathbb{E}(X \mid \mathcal{G}) = X.$$

Przykład 9.6: Znamy pierwszą kostkę. Rzucamy dwiema kostkami. Niech Y będzie wynikiem pierwszej kostki. Wtedy

$$\mathbb{E}(Y \mid Y) = Y.$$

To jest logiczne: jeśli znamy Y , to najlepsza prognoza Y to po prostu Y .

9.10.3 Jeśli czegoś nie widać, zostaje zwykła średnia

Jeżeli X jest niezależna od $\mathcal{G}$, to informacja $\mathcal{G}$ nic nie mówi o X . Wtedy

$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X.$$

Przykład 9.7: Druga kostka niezależna od pierwszej. Rzucamy dwiema niezależnymi kostkami. Niech X będzie wynikiem drugiej kostki, a Y wynikiem pierwszej. Wtedy

$$\mathbb{E}(X \mid Y) = \mathbb{E}X = 3,5.$$

Znajomość pierwszej kostki nie zmienia przewidywania drugiej.

9.11 Własność wyciągania znanego czynnika

Jedna z najczęściej używanych własności brzmi:

$$\mathbb{E}(XY \mid \mathcal{G}) = Y\mathbb{E}(X \mid \mathcal{G}),$$

gdy Y jest $\mathcal{G}$ -mierzalna.

Intuicja. Jeśli Y jest znane przy informacji $\mathcal{G}$, to w warunkowym uśrednianiu traktujemy Y jak stałą. Tak samo jak w zwykłej całce stałą można wyciągnąć przed znak całki.

Przykład 9.8: Wyciąganie znanej zmiennej. Niech Y będzie obserwowalną ceną produktu, a X losową liczbą sprzedanych sztuk, której jeszcze nie znamy. Przychód to XY . Jeżeli cena Y jest już znana, to

$$\mathbb{E}(XY \mid Y) = Y\mathbb{E}(X \mid Y).$$


Czyli prognozowany przychód to znana cena razy prognozowana sprzedaż.

9.12 Własność wieży

Własność wieży mówi, że jeśli najpierw uśrednimy względem większej informacji, a potem względem mniejszej, to tak jakbyśmy od razu uśrednili względem mniejszej:

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}_2) | \mathcal{G}_1) = \mathbb{E}(X | \mathcal{G}_1), \quad \mathcal{G}_1 \subseteq \mathcal{G}_2.$$

Intuicja. Większa informacja daje dokładniejszą prognozę. Jeśli potem ją „zamazujemy” do mniejszej informacji, to dostajemy prognozę opartą tylko na tej mniejszej informacji.



9.13 Warunkowa wartość oczekiwana jako najlepsza prognoza

Jedna z najładniejszych interpretacji pojawia się w przestrzeni L^2 . Załóżmy, że X jest całkowalna z kwadratem. Chcemy przybliżyć X zmienną, która zależy tylko od informacji $\mathcal{G}$.

Szukamy najlepszej prognozy Z mierzalnej względem $\mathcal{G}$.

Najlepszej w sensie błędu średniokwadratowego:


$$\mathbb{E}(X - Z)^2.$$

Twierdzenie 9.5: Interpretacja jako rzut ortogonalny. Jeżeli $X \in L^2$, to $\mathbb{E}(X | \mathcal{G})$ jest najlepszym przybliżeniem X spośród wszystkich zmiennych $\mathcal{G}$ -mierzalnych w sensie średniokwadratowym:

$$\mathbb{E}(X - \mathbb{E}(X | \mathcal{G}))^2 \leq \mathbb{E}(X - Z)^2$$

dla każdej $\mathcal{G}$ -mierzalnej zmiennej $Z \in L^2$.

Intuicja. To jest probabilistyczna wersja rzutu prostopadłego. Zmienna X jest punktem w ogromnej przestrzeni, a zmienne mieralne względem $\mathcal{G}$ tworzą podprzestrzeń „tego, co da się zobaczyć”. Warunkowa wartość oczekiwana jest cieniem X na tej podprzestrzeni.



9.14 Regresja nieliniowa

Jeżeli obserwujemy zmienną Y i chcemy przewidzieć X za pomocą funkcji Y , to szukamy funkcji h , dla której błąd

$$\mathbb{E}(X - h(Y))^2$$

jest jak najmniejszy.

Twierdzenie 9.6: Warunkowa wartość oczekiwana jako najlepsza funkcja obserwacji. Jeżeli $X, Y \in L^2$, to najlepszym przybliżeniem X postaci $h(Y)$ jest

$$h(Y) = \mathbb{E}(X | Y).$$

Innymi słowy,

$$\mathbb{E}(X - \mathbb{E}(X | Y))^2 \leq \mathbb{E}(X - h(Y))^2$$

dla każdej funkcji borelowskiej h , dla której $h(Y) \in L^2$.

Ważne. Regresja liniowa szuka najlepszego przybliżenia postaci $aY + b$. Warunkowa wartość oczekiwana szuka najlepszego przybliżenia postaci dowolnej funkcji $h(Y)$. Dlatego jest naturalną, nieliniową wersją regresji.

9.15 Nierówność Jensena warunkowa

Zwykła nierówność Jensena mówi, że dla funkcji wypukłej φ zachodzi

$$\varphi(\mathbb{E}X) \leq \mathbb{E}\varphi(X).$$

Istnieje też wersja warunkowa.

Twierdzenie 9.7: Warunkowa nierówność Jensena. Jeżeli φ jest funkcją wypukłą oraz odpowiednie wartości oczekiwane istnieją, to

$$\varphi(\mathbb{E}(X | \mathcal{G})) \leq \mathbb{E}(\varphi(X) | \mathcal{G}) \quad \text{p.n.}$$

Dla $\varphi(x) = |x|^p$, gdzie $p \geq 1$, dostajemy

$$|\mathbb{E}(X | \mathcal{G})|^p \leq \mathbb{E}(|X|^p | \mathcal{G}).$$

Po wzięciu wartości oczekiwanej:

$$\mathbb{E}|\mathbb{E}(X | \mathcal{G})|^p \leq \mathbb{E}|X|^p.$$

Czyli operator warunkowej wartości oczekiwanej nie powiększa normy L^p :

$$\|\mathbb{E}(X | \mathcal{G})\|_p \leq \|X\|_p.$$

9.16 Typowe schematy liczenia

Ważne.

1. Wypisz możliwe wartości Y .
2. Dla każdej wartości y policz rozkład warunkowy X pod warunkiem $Y = y$.
3. Policz średnią:

$$g(y) = \sum_x x \mathbb{P}(X = x \mid Y = y).$$

4. Zapisz wynik jako

$$\mathbb{E}(X \mid Y) = g(Y).$$

Ważne.

1. Zaczynij od gęstości łącznej $f_{X,Y}(x, y)$.
2. Policz gęstość brzegową:

$$f_Y(y) = \int f_{X,Y}(x, y) dx.$$

3. Zapisz gęstość warunkową:

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

4. Policz

$$g(y) = \int x f_{X|Y=y}(x) dx.$$

5. Odpowiedź:

$$\mathbb{E}(X \mid Y) = g(Y).$$

Ważne. Zanim zaczniesz całkować albo sumować, sprawdź, czy działa jedna z prostych zasad:

- jeśli X jest znane przy danej informacji, to $\mathbb{E}(X \mid \mathcal{G}) = X$;
- jeśli X jest niezależne od informacji, to $\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X$;
- znany czynnik można wyciągnąć przed warunkową wartość oczekiwaną;
- czasem trzeba użyć własności wieży.

9.17 Najczęstsze błędy

Uwaga. Błąd 1: traktowanie $\mathbb{E}(X \mid Y)$ jak liczby.

$\mathbb{E}(X \mid Y)$ jest zmienną losową, zwykle funkcją Y . Liczbami są wartości $\mathbb{E}(X \mid Y = y)$.

Uwaga. Błąd 2: zapominanie o mianowniku w gęstości warunkowej.

W przypadku ciągłym nie wolno pisać po prostu $f_{X|Y=y} = f_{X,Y}$. Trzeba podzielić przez gęstość brzegową $f_Y(y)$.

Uwaga. Błąd 3: warunkowanie po zdarzeniu o prawdopodobieństwie zero.

Wyrażenie $\mathbb{P}(A \mid B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$ wymaga $\mathbb{P}(B) > 0$. W zmiennych ciągłych często $\mathbb{P}(Y = y) = 0$, dlatego używamy gęstości warunkowych albo definicji przez σ -ciała.

Uwaga. Błąd 4: mylenie niezależności z brakiem korelacji.

Jeśli X jest niezależna od Y , to $\mathbb{E}(X \mid Y) = \mathbb{E}X$. Ale sama zerowa korelacja zwykle nie wystarcza do takiego wniosku.

9.18 Zadania z rozwiązaniami

Zadanie z rozwiązaniem. Rzucamy dwiema uczciwymi kostkami. Niech

$$X = \text{suma oczek}, \quad Y = \text{wynik pierwszej kostki}.$$

Wyznaczyć $\mathbb{E}(X | Y)$.

Rozwiązanie. Mamy

$$X = Y + Z,$$

gdzie Z jest wynikiem drugiej kostki. Zmienna Z jest niezależna od Y , więc

$$\mathbb{E}(Z | Y) = \mathbb{E}Z = 3,5.$$

Zatem

$$\mathbb{E}(X | Y) = \mathbb{E}(Y + Z | Y) = \mathbb{E}(Y | Y) + \mathbb{E}(Z | Y) = Y + 3,5.$$

Zadanie z rozwiązaniem. Rzucamy dwiema uczciwymi kostkami. Niech

$$X = YZ,$$

gdzie Y jest wynikiem pierwszej kostki, a Z wynikiem drugiej. Wyznaczyć $\mathbb{E}(X | Y)$.

Rozwiązanie. Ponieważ Y jest znane przy warunkowaniu po Y , możemy je wyciągnąć:

$$\mathbb{E}(YZ | Y) = Y\mathbb{E}(Z | Y).$$

Zmienna Z jest niezależna od Y , więc

$$\mathbb{E}(Z | Y) = \mathbb{E}Z = 3,5.$$

Stąd

$$\mathbb{E}(X | Y) = 3,5Y.$$

Zadanie z rozwiązaniem. Niech X, Y mają rozkład

	$Y = 0$	$Y = 1$
$X = -1$	0,1	0,2
$X = 2$	0,4	0,3

Wyznaczyć $\mathbb{E}(X | Y)$.

Rozwiązanie. Liczymy rozkład Y :

$$\mathbb{P}(Y = 0) = 0,1 + 0,4 = 0,5, \quad \mathbb{P}(Y = 1) = 0,2 + 0,3 = 0,5.$$

Dla $Y = 0$:

$$\mathbb{P}(X = -1 | Y = 0) = \frac{0,1}{0,5} = 0,2, \quad \mathbb{P}(X = 2 | Y = 0) = \frac{0,4}{0,5} = 0,8.$$

Zatem

$$\mathbb{E}(X | Y = 0) = (-1) \cdot 0,2 + 2 \cdot 0,8 = 1,4.$$

Dla $Y = 1$:

$$\mathbb{P}(X = -1 | Y = 1) = \frac{0,2}{0,5} = 0,4, \quad \mathbb{P}(X = 2 | Y = 1) = \frac{0,3}{0,5} = 0,6.$$

Zatem

$$\mathbb{E}(X \mid Y = 1) = (-1) \cdot 0,4 + 2 \cdot 0,6 = 0,8.$$

Odpowiedź:

$$\mathbb{E}(X \mid Y) = 1,4\mathbf{1}_{\{Y=0\}} + 0,8\mathbf{1}_{\{Y=1\}}.$$

Zadanie z rozwiązaniem. Niech (X, Y) ma rozkład jednostajny na trójkącie

$$T = \{(x, y) : 0 < x < y < 1\}.$$

Wyznaczyć $\mathbb{E}(X \mid Y)$.

Rozwiązanie. Pole trójkąta wynosi $1/2$, więc gęstość łączna to

$$f_{X,Y}(x, y) = 2\mathbf{1}_{\{0 < x < y < 1\}}.$$

Dla $0 < y < 1$ liczymy gęstość brzegową Y :

$$f_Y(y) = \int_0^y 2 \, dx = 2y.$$

Zatem

$$f_{X|Y=y}(x) = \frac{2}{2y} = \frac{1}{y}, \quad 0 < x < y.$$

Czyli przy znanym $Y = y$ zmienna X jest jednostajna na $(0, y)$. Jej średnia wynosi

$$\frac{0 + y}{2} = \frac{y}{2}.$$

Stąd

$$\mathbb{E}(X \mid Y) = \frac{Y}{2}.$$

Zadanie z rozwiązaniem. Niech $\mathcal{G}_1 \subseteq \mathcal{G}_2 \subseteq \mathcal{F}$ oraz X będzie całkowalna. Uzasadnij intuicyjnie wzór

$$\mathbb{E}(\mathbb{E}(X \mid \mathcal{G}_2) \mid \mathcal{G}_1) = \mathbb{E}(X \mid \mathcal{G}_1).$$

Rozwiązanie. Zmienna $\mathbb{E}(X \mid \mathcal{G}_2)$ jest najlepszą prognozą X przy większej informacji $\mathcal{G}_2$. Jeśli teraz warunkujemy ją względem mniejszej informacji $\mathcal{G}_1$, to tracimy szczegóły dostępne w $\mathcal{G}_2$. Zostaje dokładnie taka prognoza, jaką moglibyśmy zrobić od razu, mając tylko $\mathcal{G}_1$.

Formalnie obie strony są $\mathcal{G}_1$ -mieralne i dla każdego $A \in \mathcal{G}_1$ mamy, ponieważ $A \in \mathcal{G}_2$,

$$\int_A \mathbb{E}(\mathbb{E}(X \mid \mathcal{G}_2) \mid \mathcal{G}_1) d\mathbb{P} = \int_A \mathbb{E}(X \mid \mathcal{G}_2) d\mathbb{P} = \int_A X d\mathbb{P}.$$

To jest dokładnie własność definiująca $\mathbb{E}(X \mid \mathcal{G}_1)$.

9.19 Miniściągą

Podsumowanie.

1. $\mathbb{E}(X \mid \mathcal{G})$ to najlepsza prognoza X przy informacji $\mathcal{G}$.
2. Formalnie $Z = \mathbb{E}(X \mid \mathcal{G})$ spełnia:

$$Z \text{ jest } \mathcal{G}\text{-mieralna,} \quad \int_A Z d\mathbb{P} = \int_A X d\mathbb{P} \quad (A \in \mathcal{G}).$$

3. $\mathbb{E}(X \mid Y)$ oznacza $\mathbb{E}(X \mid \sigma(Y))$.

4. Jeśli X jest dyskretna, to

$$\mathbb{E}(X \mid Y = y) = \sum_x x \mathbb{P}(X = x \mid Y = y).$$

5. Jeśli para (X, Y) ma gęstość, to

$$\mathbb{E}(X \mid Y = y) = \int x \frac{f_{X,Y}(x, y)}{f_Y(y)} dx.$$

6. Jeśli X jest $\mathcal{G}$ -mierzalna, to

$$\mathbb{E}(X \mid \mathcal{G}) = X.$$

7. Jeśli X jest niezależna od $\mathcal{G}$, to

$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X.$$

8. Znany czynnik można wyciągnąć:

$$\mathbb{E}(XY \mid \mathcal{G}) = Y \mathbb{E}(X \mid \mathcal{G}),$$

gdy Y jest $\mathcal{G}$ -mierzalna.

9. Własność wieży:

$$\mathbb{E}(\mathbb{E}(X \mid \mathcal{G}_2) \mid \mathcal{G}_1) = \mathbb{E}(X \mid \mathcal{G}_1), \quad \mathcal{G}_1 \subseteq \mathcal{G}_2.$$

10. W L^2 warunkowa wartość oczekiwana jest najlepszym przybliżeniem opartym na dostępnej informacji.